ECPE 白皮书中文译本

本文件是本仓库中两份 ECPE（欧洲电力电子中心）白皮书的中文译本：

1. 白皮书一：电力电子中的人工智能——机遇、挑战与未来方向（原文：`ECPE_White_Paper_Artificial_Intelligence_in_Power_Electronics_Sept_2026.pdf`）
2. 白皮书二：AI 支持的电力电子教育（原文：`ECPE_White_Paper_AI-supported_Power_Electronics_Education_Oct_2026.pdf`）

译注：

- 本译文为非官方翻译，仅供参考；如有出入，以英文原文为准。原文以 CC BY 4.0 许可发布。
- 人名、机构名、软件/工具名、标准编号及参考文献保留原文；专业术语在首次出现时尽量附注英文缩写。
- 原文中的图片无法在 Markdown 中直接复现，译文保留了图题，并对结构较复杂的示意图以文字形式概述其内容。
- 正文中的 [n] 为原文参考文献编号，参考文献列表保留英文原文。

白皮书一：电力电子中的人工智能——机遇、挑战与未来方向

> 原文：*ECPE White Paper — Artificial Intelligence in Power Electronics: A perspective on opportunities, challenges, and future directions*，1.0 版，2026 年 10 月 ECPE 欧洲电力电子中心（ECPE European Center for Power Electronics e.V.），德国纽伦堡

出版与版本说明

项目	内容
出版方	ECPE 欧洲电力电子中心（ECPE European Center for Power Electronics e.V.），Ostendstr. 181, 90482 Nuremberg, Germany
作者	作者名单见下一页
出版日期	2026 年 10 月
版本	1.0 版
标识符	DOI 10.5281/zenodo.23081943
推荐引用格式	ECPE e.V., Artificial Intelligence in Power Electronics: A perspective on opportunities, challenges, and future directions, White Paper, Nuremberg, Germany, October 2026, DOI 10.5281/zenodo.23081943.
版权	知识共享署名 4.0 国际许可协议（CC BY 4.0）
免责声明	文中观点反映的是作者们的集体评估，并不一定代表 ECPE 或其所属机构的官方立场。对于所提供信息的正确性或完整性不作任何保证。部分书稿借助基于 AI 的语言软件进行了校对，以改进语法、清晰度和可读性。作者审阅并批准了所有修改，并对书稿内容承担全部责任。

原文使用 LaTeX 和 KOMA-Script（scrreprt 文档类）排版。

作者及单位

名单按姓氏字母顺序排列。

- Dr. Davide Barlini —— 三菱电机欧洲研发中心（Mitsubishi Electric R&D Centre Europe），法国
- Vasilij Baumann —— InstruNEXT，德国（SG 3 组长）
- Prof. Dr. Frede Blaabjerg —— 奥尔堡大学（Aalborg University），丹麦
- Jannes Briese —— 布伦瑞克工业大学（TU Braunschweig），德国
- Dr. Raul Carreira Rufato —— 赛峰技术（Safran Tech），法国
- Dr. Ilknur Colak —— 施耐德电气（Schneider Electric），法国

- Johannes Drechsel —— 弗劳恩霍夫陶瓷技术与系统研究所（Fraunhofer IKTS），德国
- Prof. Dr. Uwe W. Drofenik —— 维也纳工业大学（Technical University of Vienna），奥地利（SG 1 组长）
- Dr. Maximilian Götzinger —— 施耐德电气（Schneider Electric），奥地利
- Prof. Dr. Norbert Grass —— 纽伦堡欧姆应用科学大学（Ohm Univ. of Applied Sciences Nuremberg），德国
- Thomas Harder —— ECPE，德国（工作组协调人）
- Prof. Dr. Rolf Hellinger —— 西门子（Siemens），德国
- Kevin Hermanns —— PE Systems，德国（SG 2 组长）
- Leonhard Hertenstein —— 梅赛德斯-奔驰（Mercedes Benz），德国
- Ingmar Kallfass —— 斯图加特大学（University of Stuttgart），德国
- Prof. Dr. Nando Kaminski —— 不来梅大学（Univ. of Bremen），德国
- Robert Keilmann —— 布伦瑞克工业大学（TU Braunschweig），德国
- Felix Keppner —— 西门子（Siemens），德国
- Dr. Mohammed Ali Khan —— 南丹麦大学森讷堡校区（SDU Sønderborg），丹麦（SG 4 组长）
- Prof. Dr. Johann W. Kolar —— 苏黎世联邦理工学院（ETH Zurich），瑞士（SG 1 组长）
- Dr. Ivana Kovacevic-Badstuebner —— 苏黎世联邦理工学院（ETH Zurich），瑞士
- Dr. Varaha S. Bharath Kurukuru —— 奥地利硅实验室（SAL Silicon Austria Labs），奥地利（SG 4 组长）
- Prof. Dr. Leo Lorenz —— ECPE，德国
- Dr. Ingo Luedke —— 化合物半导体应用弹射中心（CSA Catapult），英国
- Prof. Dr. Paolo Mattavelli —— 帕多瓦大学（University of Padova），意大利
- Sven Meier —— 埃尔朗根-纽伦堡大学 FAPS 研究所（FAPS/Friedrich-Alexander Univ. Erlangen-Nuremberg），德国（SG 3 组长）
- Dr. Anton Miric —— 贺利氏电子（Heraeus Electronics），德国
- Dr. Christoph Raab —— 西门子（Siemens），德国
- Dr. Lars Rebenklau —— 弗劳恩霍夫陶瓷技术与系统研究所（Fraunhofer IKTS），德国
- Dr. Claudio Rivetta —— 阿拉贡技术研究所（Inst. Tecnológico de Aragón），西班牙
- Dr. Andreas Rosskopf —— 弗劳恩霍夫集成系统与器件技术研究所（Fraunhofer IISB），德国
- Prof. Dr. Subham Sahoo —— 奥尔堡大学（Aalborg University），丹麦
- Dr. Yanfeng Shen —— 赛米控丹佛斯（Semikron Danfoss），德国
- Dr. Nima Tashakor —— 大众汽车（Volkswagen），德国（SG 2 组长）
- Ali Tfaily —— 施耐德电气（Schneider Electric），法国
- Dr. Muhammad Usama —— 三菱电机欧洲研发中心（Mitsubishi Electric R&D Centre Europe），法国
- Prof. Dr. Oliver Wallscheid —— 锡根大学（University of Siegen），德国（SG 4 组长）
- Prof. Dr. Huai Wang —— 奥尔堡大学（Aalborg University），丹麦

- Prof. Dr. Shuai Zhao —— 奥尔堡大学（Aalborg University），丹麦

通讯机构：ECPE 欧洲电力电子中心，德国纽伦堡。

目录

- 前言
- 1 引言
  - 1.1 基于机器学习和深度神经网络的模式识别
  - 1.2 作为设计助手的大语言模型
  - 1.3 用于探索性变换器开发的强化学习
  - 1.4 小结
- 2 AI 在电力电子设计中的范围与作用
  - 2.1 权衡与挑战
    - 2.1.1 设计应用中 AI 潜力的决策矩阵
    - 2.1.2 设计应用中常用的 AI 架构和模型
  - 2.2 AI 支持的拓扑与架构探索
    - 2.2.1 自动拓扑发现
    - 2.2.2 强化学习：自动拓扑探索的关键使能技术
    - 2.2.3 维度问题
    - 2.2.4 控制对系统架构或元件设计的影响
  - 2.3 多物理场与 AI 增强的协同设计与优化（元件级）
    - 2.3.1 半导体、磁性元件和无源元件的代理模型
    - 2.3.2 用于电-热-机械耦合设计的 ML–物理混合求解器
    - 2.3.3 元件、EMC 滤波器和版图的进化优化
  - 2.4 AI 加速的仿真、可靠性预测、设计确认与验证
    - 2.4.1 代理模型与物理信息模型
    - 2.4.2 虚拟孪生和/或数字影子
    - 2.4.3 对所交付结果的验证/确认
  - 2.5 展望与研究需求
    - 2.5.1 总结——集成设计–仿真–鉴定的数字孪生
    - 2.5.2 大语言模型对设计流程的影响
    - 2.5.3 行动呼吁：技能缺口以及科研与产业需求
- 3 AI 在电力电子制造中的应用
  - 3.1 电力电子制造中 AI 用例与方法的系统化梳理
    - 3.1.1 认知维度：从可见性到自主性

        - 3.1.2 结构维度：应用范围
    - 3.2 从洞察到实施：选择合适的模型
    - 3.3 典型 AI 应用及成功实施的最佳实践
        - 3.3.1 基于局部放电数据的 AI 驱动剩余使用寿命预测
        - 3.3.2 批量生产中用于键合线检测的无监督异常检测
    - 3.4 "会思考的工厂"：生成式 AI 与自主 AI 智能体的新兴应用
        - 3.4.1 从分析型 AI 到智能体 AI 的转变
        - 3.4.2 按自主程度与影响对用例进行分类
- 4 AI 在电力电子运行中的应用
    - 4.1 产品运行期间的典型任务
        - 4.1.1 控制
        - 4.1.2 模型辨识（含数字孪生）
        - 4.1.3 状态估计
        - 4.1.4 故障检测
        - 4.1.5 预测性维护
    - 4.2 工业部署挑战
        - 4.2.1 网络安全与数据隐私
        - 4.2.2 功能安全/生产部署
        - 4.2.3 嵌入式硬件要求
        - 4.2.4 数据要求与系统激励
    - 4.3 未来研究展望
    - 4.4 结论
- 参考文献

前言

人工智能（AI）是当下的热门话题，围绕它无疑存在大量炒作，但它确实正在给我们的生活和工作方式带来持久的改变。正因如此，我们 ECPE 网络一直在思考：AI 的使用如今已经对电力电子（PE）产生了哪些影响？未来的 AI 应用中又蕴藏着哪些进一步的潜力？

通过这份 ECPE 白皮书，我们希望提高业界对这一主题的认识，为电力电子界的讨论提供一个平台，并加强产业界与学术界之间的合作。

什么是电力电子？ 电力电子是电气与电子工程的一个重要分支，研究如何应用电子技术对电能进行控制和变换。电力电子是一个交叉性且无处不在的领域，它涵盖众多学科，包括材料科学、半导体物理与功率器件、组装与互连技术、电路拓扑以及控制，适用于从毫瓦级低功率到吉瓦级功率范围内所有涉及电能的系统和应用。

为什么要在电力电子中使用 AI? 在电力电子中使用 AI，其面向未来的关键潜力在于速度——进而在于成本。这包括缩短开发和测试时间，从而缩短上市时间；通过减少故障和废品来优化生产；以及对现场产品进行智能状态监测和使用寿命监测。

在电力电子中使用 AI 所带来的根本性变化在于这样一种可能性：AI 可能使工程过程完全自动化——换句话说，即 AI 将全面负责功率模块或变换器的设计、优化、制造和测试这一愿景。这将使 AI 把成本降低推进到一个新的层次，但工程师的工作将何去何从？我们的愿景——或者说希望——是一位拥有卓越工作效率的、由 AI 辅助的工程师。

AI 做什么? AI 是计算机科学的一个分支，致力于构建能够执行通常需要人类智能才能完成的任务的系统。这些任务包括学习、推理、解决问题、理解语言和识别模式。AI 通过智能算法处理海量数据来运作。系统并不只是遵循一套严格的预先编写的规则，而是识别数据中的模式，并随着时间推移从中"学习"，以做出决策、预测结果或生成新内容。

这份 ECPE 白皮书关注的是 AI 方法和工具在电力电子中的应用，而不是电力电子在 AI 数据中心中的作用——后者同样是一个有趣且高度相关的话题。在由子小组（SG）1 编写、阐述基础知识和术语的引言之后，本白皮书的结构沿着电力电子产品的整个生命周期追溯 AI 方法和工具的应用——从早期开发阶段，到制造，直至产品的运行阶段（SG2 至 SG4）。

AI 方法和工具在人的学习与高级培训中的应用这一跨领域问题，在由 SG5 编写的另一份文件中阐述。

我们感谢各位作者的支持以及对这份 ECPE 白皮书所作的宝贵贡献，本白皮书突出了 AI 在电力电子整个产品生命周期——从早期开发阶段一直到运行中的产品——中的作用和重要性。

Prof. Dr. Leo Lorenz，ECPE 主席 Dipl.-Phys. Thomas Harder，ECPE 总经理

1 引言

AI 在电力电子中的重要性正在稳步提升 [1, 2]，为变换器优化、加速设计周期和智能状态监测开辟了新的途径。对于电气工程师而言，这一主题可能显得抽象，部分原因在于 AI 起源于计算机科学，而非传统工程学科 [3]。因此，在初次进入这一领域时，一个务实的、面向应用的视角会很有帮助。

下面，我们将通过三个与电力电子工程师所熟悉的任务和工作流程直接相关的视角来探讨 AI：

1. 利用机器学习（ML）和深度神经网络（DNN）[4, 5] 进行模式识别，以构建高效的仿真模型并开展失效分析；
2. 支持设计、分析和文档编写的大语言模型（LLM）；
3. 强化学习（RL）[6]，它提供了超越传统工程知识和/或直觉、发现新型控制策略或变换器概念的可能性。

首先，我们需要澄清术语。AI 是一个宽泛的总称，涵盖模拟人类智能某些方面的各种计算技术。ML 是 AI 的一个子集，关注的是从数据中学习、而非被显式编程的系统。DNN 受人脑结构的启发，是由多层人工神经元组成的机器学习模型——包括一个输入层、一个或多个隐藏层以及一个输出层，其中隐藏层的神经元计算前一层神经元的加权和，并对该加权和施加一个非线性激活函数（该激活函数使 DNN 能够学习数据中的非线性关系）——这使它们能够从高维数据中提取复杂特征。LLM 代表了一类较新的 AI，它们在海量文本

上进行训练，用于辅助推理、解释以及与设计相关的沟通。RL 描述的是通过与环境交互并以奖励形式获得反馈来进行学习的系统（"试错式"学习）。RL 不需要标注数据，而是在运行过程中通过与环境交互来积累信息。

上述各方法之间的关系如图 1.1 所示。尽管这些定义看起来可能较为形式化，但它们会自然而然地将我们引向实际的工程角色。

> **图 1.1：** AI 领域试图创建模仿人类智能的系统。该图展示了 AI、ML、DNN、LLM 和 RL 这些术语之间的相互关系。

1.1 基于机器学习和深度神经网络的模式识别

对于熟悉传统建模的工程师来说，将机器学习视为曲线拟合的延伸会很有帮助。线性回归是每位工程师都用过的工具，它用一条直线拟合数据以近似描述某种行为，例如根据开关电流（在给定电压下）估算开关损耗，或确定导通损耗随温度变化的函数关系。ML 建立在这一思想之上，但将其规模大幅扩展。它不是拟合一条简单的曲线，而是在具有数千乃至数百万个输入变量的数据集中寻找关系。在这一语境下，线性回归——也就是简单的线性曲线拟合——就是一种 ML 算法，因此按一般定义它已经是 AI 的一种形式。

一个说明超高阶曲线拟合的简单例子是一幅 100×100 像素的图像，它对应 10'000 个输入参数（维度为 10'000）。预测一个物理量——例如根据磁场仿真图像推导出的电感值 [7]——就变成了一项维度极高的任务。没有哪位工程师能够为这样的映射写出显式规则，但像 DNN 这样的 ML 算法却能够自主学习它。通过堆叠许多（隐藏）层的人工神经元，每一层提取越来越有意义的特征，DNN 学会的是对图像进行泛化，而不是死记硬背。这与查找表等方法有本质区别，后者需要存储每一种可能的情况，并且无法外推到已知数据之外。

在上面的例子中，"DNN 训练即从数据中学习"这一数学过程，就是调用 ML 库中的 DNN 算法，并输入数千幅包含不同几何图形（例如电感或变压器的磁芯、气隙、绕组）的图像，以及与每幅图像所示几何结构相对应的、用有限元法（FEM）计算得到的电感值 [7]。这需要大量的计算资源，但可以使用现有的开源软件。训练完成后，只要新的几何图形与训练中使用的几何图形差异不太大，DNN 就能预测其电感值。

在电力电子中，这种能力极具价值。电力电子领域会产生复杂多样的数据，例如来自 FEM 工具的电磁场分布、来自计算流体动力学（CFD）仿真的温度和流场数据、实测开关波形、电磁干扰（EMI）频谱、声学噪声、PCB 和封装结构的视觉检测图像、大量的半导体表征数据以及其他器件数据。利用这些信息训练的 DNN 可以作为快速代理模型 [7]，以惊人的速度和精度近似基于物理的仿真。它们使工程师能够构建模型，从而以比传统仿真快几个数量级的速度探索元件选择、版图、散热策略和开关条件。

机器学习也被用于推进健康监测 [8]。通过评估半导体模块的图像、机械应力产生的声学模式，或在开关瞬态期间采集的电信号，ML 模型能够检测出退化的早期迹象，例如键合线脱落、焊料空洞或热疲劳。这一能力促成了预测性维护并提高了系统可靠性。

另一个新兴领域是器件建模 [9, 10]。制造商提供了大量的数据手册和测量曲线，但工程师仍需花费大量时间提取参数并构建仿真模型。基于经验性半导体数据训练的 DNN 能够比解析方程更准确地捕捉非线性和温度效应，同时保持较高的计算效率。

总之，ML 丰富了工程师的工具箱 [11]。它从仿真和测量数据中学习，支持更快、更精确的建模，并提供新的诊断能力，理想情况下是对已有物理认识的补充而非替代。

1.2 作为设计助手的大语言模型

DNN 帮助识别模式，而 LLM 则辅助知识处理和工程工作流程 [12, 13, 14]。LLM 在海量技术文本上训练，可支持文档编写、推理、编程和文献解读。从本质上讲，它们是极其庞大的 DNN——通常拥有数十亿个参数——旨在学习语言的统计结构。在训练过程中，DNN 基于统计反复预测句子中的下一个词，并根据猜测是否正确来调整其内部参数。通过这一过程，它掌握了语法、技术术语、逻辑关系和事实关联。当 DNN 达到一定规模时，它的回答看起来很智能，并且在上下文中合乎情理，尽管这些回答主要基于统计（"在前面两个词之后，哪个词以多大的概率出现？"）以及一定的随机性。LLM 的巨大规模使其能够在广阔的知识领域中存储细微的模式和联系，从而能够基于所学到的上下文（而不是固定编程的规则）生成连贯的文本、解释工程概念并提供有见地的设计辅助。

DNN 在数值或图像数据中识别模式，而 LLM 支持的是另一类工程工作，尤其是推理、文档编写和知识获取。LLM 在大量技术文献、代码和报告上训练，使其能够辅助完成涉及文本、解释和结构化问题求解的任务。专门在电力电子数据（例如 IEEE Xplore 数据库中的相关出版物）上训练 LLM，将为电力电子工程师打造一个非常强大的虚拟助手。

工程师可以以对话方式与此类模型交互，请求帮助理解应用笔记、起草设计文档，或生成 MATLAB、Python 或 SPICE 仿真脚本。他们还可以就非常具体的话题寻求指导，例如 SiC 器件的栅极驱动调试、开关速度与电磁干扰之间的权衡，或散热设计方面的考量。在电力电子中使用 LLM 的一种非常有效的方式，是根据电流和电压应力为电路选择元件，而这通常是一个非常耗时的过程（例如，目前 DigiKey 的在线数据库中有超过 7,000 种不同类型的绝缘栅双极晶体管（IGBT）及 IGBT 模块）。用户提供一个提示词（prompt），也就是引导模型作答的指令或问题。精心编写的提示词能提供更好的引导，并使 LLM 给出质量显著更高的回答。

LLM 并不取代工程判断，而是充当准智能助手，在概念设计和早期设计阶段提供快速的知识获取并支持探索 [15, 16]。在审阅大量信息或起草结构化分析时，它们尤其有用。

1.3 用于探索性变换器开发的强化学习

LLM 帮助工程师运用已知的东西。相比之下，RL 有潜力探索尚未知晓的东西 [17, 18]。RL 智能体不是从固定的数据集中学习，而是与一个仿真环境交互，尝试各种控制动作或结构参数，并因期望的行为而获得奖励——例如高效率、低元件应力、正弦电流控制/低谐波畸变（见图 1.2），或快速的瞬态响应。图中展示的是单相全桥交流（AC）/直流（DC）变换器（环境）的正弦输入电流控制，所用 DNN 由深度强化学习（DRL）算法根据奖励函数（即与正弦电流参考值的偏差和开关损耗的加权和）进行参数化。

> **图 1.2：** 单相全桥 AC/DC 变换器的正弦输入电流控制。

DRL 算法不需要用户提供的训练数据；相反，它对拓扑进行探索，根据奖励评估控制动作的成效，并最终确定 DNN 的权重和激活函数，以使奖励最大化（"边做边学"）。基于 DNN 的控制器甚至能够应对训练期间从未遇到过的情况，例如负载阶跃 [18]。按照 RL 领域的通用术语，对环境（变换器电路）施加的动作（门

极信号 $g_i(t)$，$i = 1, 2, 3, \ldots$）由智能体（DRL 算法以及具有三个隐藏层、每层 64 个神经元的 DNN）根据状态（电流参考值 i_N^*、输入电流 i_N 以及上一时间步的门极信号 $g_i' = g_i(t-1)$）来确定。

这一范式与人类工程师获得直觉的方式非常相似，例如尝试电路元件的不同布置、观察其行为，并迭代地改进决策。然而，与人类不同，RL 系统可以系统地探索巨大的设计空间，而不受既有拓扑或控制启发式规则的约束。因此，RL 可能会发现非常规的调制技术、软开关策略或混合变换器架构，而这些很难从传统的设计思维中产生。

尽管 RL 需要可计算的训练环境以及精心定义的奖励，但其概念上的吸引力是显而易见的。它代表了一条通往自动化发现的道路——有望带来全新的电力电子设计方法。

1.4 小结

AI 并不是传统电力电子工程的替代品，而是它的自然延伸。当从模式识别、语言辅助设计和基于 RL 的探索这些务实的视角来看待时，AI 就远没有那么抽象，而是与日常工程实践更加契合。

DNN 促进了快速建模和健康监测，而 LLM 提升了工程生产力和知识获取能力。RL 有可能开启新的变换器概念和控制策略。它们共同构成了一套工具，补充了基于物理的认识，并加速了电力电子领域的创新。

总而言之，这些 AI 技术扩展了传统的电力电子工具，支持更快的设计周期、更高的可靠性，并有可能催生新的变换器和控制概念。到目前为止，其根基仍然是扎实的电气工程，而 AI 则在此之上增添了一个强大的新能力层。

2 AI 在电力电子设计中的范围与作用

现代电力电子系统的复杂性日益增加——这由宽禁带（WBG）器件、严格的电磁兼容（EMC）要求、强烈的多物理场耦合以及不断加快的开发周期所驱动——已将传统设计流程推向极限。AI 方法为在整个电力电子生命周期中增强并部分自动化设计、优化、鉴定和验证提供了新的手段。本章对电力电子设计与工程中的 AI 方法和工具进行了结构化的、批判性的综述，涵盖概念探索、元件级协同设计、仿真加速、可靠性与寿命预测以及设计验证。

本章探讨 AI 如何应对成本、性能与鲁棒性之间的关键设计权衡，同时强调与数据可得性、泛化能力、偏差和可信度相关的挑战。随后讨论 AI 支持的拓扑探索，包括自动发现以及作为拓扑评估潜在使能技术的强化学习，还有高维设计空间所带来的局限。此外，本章还讨论多物理场、AI 增强的元件级协同设计，包括半导体、磁性元件和无源元件的代理模型；元件参数和版图的多目标优化（MOO）；以及作为快速性能评估、可靠性评估和寿命预测使能技术的 AI 加速仿真。

最后，展望部分强调了 LLM 和智能体（agentic）工作流程对未来设计流程日益增长的影响，它们能够实现自动化需求管理、人在回路工程以及可认证的 AI 工具链。本章最后呼吁产业界、学术界和资助机构协同行动，以支持 AI 在电力电子设计与工程中可信、可持续的应用。

现代电力电子系统的设计日益受到系统复杂性和开发压力同时攀升的挑战。WBG 半导体器件的广泛采用显著扩展了可用的设计空间，使更高的开关频率、更高的功率密度和更高的效率成为可能。与此同时，这些进

步加剧了电、热和机械领域之间的多物理场耦合效应，并使 EMC 约束更加严苛。传统设计方法——主要基于按领域顺序进行的优化和手工迭代——越来越难以应对由此产生的高维度和相互依赖性。

与此同时，市场和监管压力要求更短的开发周期、更高的产品可靠性以及更好的成本–性能权衡。因此，设计团队需要在更紧迫的上市时间约束下评估越来越多的硬件和控制策略，而且在设计阶段早期往往掌握的知识并不完整。这种局面暴露了传统设计流程的根本局限，特别是在早期探索和系统级优化方面。

AI 方法通过实现数据驱动的抽象、快速代理建模以及对大型、高度耦合设计空间的自动探索，提供了一种互补的范式。其目标不是取代物理建模或工程专业知识，而是用能够识别非直观解决方案、加速设计迭代并系统地平衡相互冲突目标的工具来增强现有流程。在这一背景下，AI 在电力电子设计中的作用不仅限于纯粹的性能优化，还包括在设计过程早期就纳入可靠性和寿命方面的考虑，以及在整个设计生命周期中实现自动化文档编写和可追溯性。

2.1 权衡与挑战

在电力电子设计中采用 AI，必须对照成本、开发时间与性能之间的经典权衡来进行评判。AI 可以加速参数扫描、减少手工迭代并支持对非直观解决方案的探索，但它也带来了数据生成、模型训练、工具集成、验证和维护方面的工作量 [19]。因此，AI 在设计空间复杂、传统仿真或测试代价高昂、且预期性能收益足以抵消额外开销的场合最为有用。对于简单且已被充分理解的设计任务，解析模型或传统优化可能仍然更加高效和透明。

一个主要的限制是高质量数据的可得性和管理。电力电子数据往往分散在仿真工具、测量结果、供应商信息和特定项目的设计文件中。运行条件、器件代际、热边界、调制策略和版图寄生参数的差异降低了数据的可复用性和可比性。如果没有结构化的元数据、版本控制和可追溯的数据管道，AI 模型学到的可能是测试装置的伪影，而不是具有物理意义的设计关系 [20]。

通用性和可信度仍然是关键挑战。为某一种拓扑、电压等级、半导体技术、散热方案或调制策略训练的模型，可能无法可靠地外推到另一个设计系列。训练数据也可能过度代表标称或成功的设计，而对罕见故障、公差、老化效应和最坏工况代表不足。因此，可信 AI 需要不确定性量化、可解释性、鲁棒性检查，以及对照独立的仿真或测量进行验证，在安全相关的应用中尤其如此。

最后，电力电子领域缺乏被广泛接受的公开基准数据集，用于拓扑选择、损耗预测、EMI 感知的版图优化、热协同设计和寿命估计等 AI 辅助设计任务。这使得公平比较和可复现性变得困难。需要标准化的参考变换器、运行工况、数据集和评估指标，不仅用于评估预测精度，还用于评估在真实工程流程中的外推能力、计算成本、物理一致性和集成工作量。随着基于 LLM 的设计工具和智能体设计工具进入电力电子工作流程，这一点变得更加重要 [21]。

2.1.1 设计应用中 AI 潜力的决策矩阵

将 AI 纳入电力电子设计，需要对 AI 能在何处带来可衡量的工程价值进行结构化评估。不应仅仅因为某项任务在技术上可以自动化就引入 AI。如果设计问题简单、在解析上已被充分理解或评估成本低廉，传统模型和优化方法可能仍然更加透明和高效。相反，当设计空间是高维的、非线性的、多目标的、评估代价高昂的，或者只能被解析模型部分刻画时，AI 就变得有吸引力。这与多准则决策分析是一致的，后者主张通过明确的准则、权重和权衡来评估备选方案，而不是依赖单一的定性判断 [19, 22]。

对于电力电子，决策应区分三个方面：AI 收益潜力、AI 可行性和部署风险。收益潜力描述 AI 是否可能改进工程流程；可行性描述能否现实地开发出可靠的模型；部署风险描述该模型能否在预期应用中被安全且可追溯地使用。表 2.1 总结了所提出的筛选矩阵。每项准则可评为低、中、高三档，并具有一定程度的定性灵活性。

表 2.1：电力电子设计中 AI 潜力的筛选矩阵（每项准则可评为低、中、高三档，并可使用 0 到 10 之间的整数，保留一定的定性灵活性）

维度	准则	低（0–3）	中（4–7）	高（8–10）	高分的含义
收益	搜索空间复杂度	少量弱耦合变量	若干耦合参数	高维、非线性、离散–连续混合空间	AI 可能改进探索
收益	模型不确定性	存在可靠的解析模型	存在已知局限的近似模型	强烈依赖经验或缺乏精确的解析模型	AI 可能捕捉缺失的关系
收益	多目标耦合	各目标基本相互独立	中等程度的权衡	效率、EMI、成本、热应力、体积或寿命之间存在强烈的帕累托冲突	AI/MOO 可能改进权衡搜索
收益	迭代成本	快速的解析计算	中等的仿真工作量	昂贵的有限元分析（FEA）、CFD、EMC 仿真、任务剖面运行或实验室测试	代理模型可降低评估成本
收益	性能敏感度	局部影响较小	对元件级有相关影响	对效率、EMI、功率密度、成本或寿命等系统 KPI 有强烈影响	优化价值高
可行性	数据可得性与质量	稀疏、不一致、标注不佳	运行空间覆盖不完整或验证不完整（例如仅有仿真数据）	结构化、有代表性、可追溯的仿真/测量数据	模型训练与验证是现实可行的
可行性	领域复杂度	单一物理领域	两个耦合领域	电、热、磁、EMI、机械和老化相互耦合	AI 可支持耦合抽象
可行性	模型维度	标量或一维特征	波形、映射图或二维场	三维场、图结构、版图或随时间变化的多领域数据	可能有理由采用先进的 AI 架构
可行性	计算资源	严重的算力/内存限制	工作站或边缘端约束	具备离线 CPU/GPU/高性能计算（HPC）资源	可以采用更大的模型或开展训练活动
风险	关键程度	非关键的设计支持	工程决策支持	安全关键或与鉴定相关的决策	限制黑箱自主
风险	法规负担	与正式合规无关	与内部流程相关	与国际电工委员会（IEC）、国际标准化组织（ISO）、UL 或汽车鉴定相关	可追溯性和验证与确认（V&V）主导部署

维度	准则	低（0–3）	中（4–7）	高（8–10）	高分的含义
风险	严格的时延要求	离线使用	近实时的工程支持	嵌入式或实时控制/保护	模型规模和确定性受到约束
风险	可解释性要求	低	中	高	优先采用物理信息模型或透明模型
风险	错误预测的代价	后果轻微	可纠正的工程错误	硬件损坏、安全风险或无效的鉴定结果	必须进行独立验证

不将所有准则压缩为一个分数，而是计算三个归一化分数：

$$B = \frac{\sum_i w_i b_i}{10 \sum_i w_i}, \qquad F = \frac{\sum_k u_k f_k}{10 \sum_k u_k}, \qquad R = \frac{\sum_j v_j r_j}{10 \sum_j v_j} \tag{2.1}$$

其中 B 为 AI 收益潜力，F 为 AI 可行性，R 为部署风险。b_i、f_k 和 r_j 为各准则的评分，而 w_i、u_k 和 v_j 为与应用相关的权重。权重应由领域专家选定；如果不清楚优先级，可以将等权重作为初步筛选的假设。该评分的目的并非提供一个普适的真理，而是使决策透明且可复现。所得分类可按表 2.2 进行解读。

表 2.2：归一化筛选分数的解读

条件	解读
$B \geq 0.6$、$F \geq 0.6$ 且 $R \leq 0.4$	强 AI 候选：在设计自动化、代理建模或优化中使用 AI 很可能是合理的
$B \geq 0.6$，且"强候选"和"研究候选"条件均不适用	有条件的 AI 候选：仅在具备物理约束、不确定性量化、可追溯性和人在回路验证的情况下使用
$B \geq 0.6$ 且（$F < 0.4$ 且 $R \leq 0.4$）或（$F \geq 0.6$ 且 $R > 0.6$）	研究候选：该用例前景可观，但数据、验证或工具尚不足以支撑部署，因此产业应用可能有限
$B < 0.6$	弱 AI 候选：解析模型、基于规则的方法或传统优化可能更为可取
高关键程度 + 高时延要求 + 低可解释性	无论收益分数如何，都不适合作为独立的黑箱 AI 功能

这种区分很重要，因为高风险应用并不自动意味着是糟糕的 AI 用例。例如，一个与安全相关的保护功能可能具有很高的收益潜力，但可接受的 AI 角色可能仅限于离线设计探索、异常筛查、测试用例生成或决策支持。在没有确定性后备方案和形式化验证的情况下，不应将其部署为不受约束的黑箱实时控制器。

作为合理性检验，EMI 感知的版图优化以及任意波形下的磁损耗代理建模通常在收益上得分很高，因为它们涉及非线性、多领域且评估代价高昂的设计空间。如果仿真或测量数据是结构化的并经过独立验证，它们也可能是可行的。相比之下，根据已知纹波电流方程进行简单的电容选型在收益上得分较低，因为解析模型透明、廉价且已足够。安全关键的实时保护任务可能在收益上得分很高，但在部署风险上也得分很高；因此，该矩阵会将其归类为有条件的或非独立的 AI 应用，而不是直接进行黑箱部署。

因此，这一决策矩阵应被理解为一种实用的筛选和优先级排序工具。它通过识别那些高设计复杂度、不完整模型、高昂迭代成本和强多物理场耦合与足够的数据质量及现实的验证路径同时存在的情形，来支持以价值为导向的 AI 采用。这种结构化方法与更广泛的观点一致，即电力电子中的 AI 应支持设计、控制、维护、优化、回归、分类和数据结构探索，同时始终以物理约束和工程验证为基础 [23, 24]。

2.1.2 设计应用中常用的 AI 架构和模型

鉴于电力电子设计中存在强非线性、多物理场耦合、有限的标注数据和严格的可靠性要求，模型的选择应由任务和部署环境驱动，而不是由某种特定架构的流行程度驱动。在实践中，AI 模型很少作为独立的黑箱使用。它们被嵌入到基于物理的仿真、优化、验证或人在回路的设计流程中。表 2.3 区分了学习范式、模型族和设计角色，而表 2.4 给出了参考性的数据和算力需求。

表 2.3：与电力电子设计相关的 AI 模型族

模型族/范式	代表性方法	在电力电子中的典型用途	优势	主要局限	参考文献
经典监督学习	线性/核回归、支持向量机、随机森林、梯度提升	快速的损耗、效率、温度、可行性及故障分类器/估计器；早期代理模型	适用于中等规模数据集；对 CPU 友好；相对可解释	外推能力有限；常需特征工程；不擅长高维场或版图	[19], [22]
深度监督代理模型	前馈神经网络、卷积神经网络（CNN）、多输出神经网络、残差网络	变换器和元件代理模型；快速预测损耗、热应力、EMC 指标、寿命指标	推理速度快；非线性逼近能力强；适合用于优化循环	需要标注的仿真/测量数据；可能过拟合；通常不具备原生的不确定性估计	[19, 22, 25]
时序与序列模型	循环神经网络（RNN）、长短期记忆网络（LSTM）、门控循环单元（GRU）、时间卷积网络、Transformer 编码器	任务剖面建模、退化与老化预测、基于波形的诊断、动态变换器建模	能捕捉时间依赖性和波形历史	训练可能需要大量数据；长时域稳定性和外推仍然困难	[19, 20]
无监督与表示学习	主成分分析（PCA）、均匀流形逼近与投影（UMAP）、聚类、自编码器、自监督编码器	设计空间可视化、工作点聚类、异常发现、优化前的特征压缩	在标签稀缺时有用；改善数据理解和预处理	不直接提供性能预测；潜变量可能缺乏物理意义	[19], [22]
概率与主动学习代理模型	高斯过程、贝叶斯神经网络、多项式混沌展开、贝叶斯优化、主动学习	不确定性感知设计、公差研究、昂贵的 FEA/CFD/EMC 优化、自适应采样	样本效率高；具备不确定性感知；适用于每次仿真或测试都很昂贵的情形	高斯过程随数据集规模扩展性差；不确定性质量取决于假设	[22], [25]
强化学习	DQN、近端策略优化（PPO）、软演员–评论家（SAC）、基于模型的 RL、约束 RL	调制/控制整定、拓扑–控制协同设计、序贯参数决策	学习序贯策略；能发现非直观的控制策略；与拓扑可行性评估相关	样本成本高；奖励设计困难；不能保证安全性和稳定性	[23]

模型族/范式	代表性方法	在电力电子中的典型用途	优势	主要局限	参考文献
物理信息与混合模型	物理信息神经网络（PINN）、物理信息 DeepONet、傅里叶神经算子、神经算子、ML 修正的降阶模型	快速场预测、逆向设计、电–热–磁耦合仿真、任务剖面研究	嵌入物理约束；可减少对标注测量数据的依赖；适用于参数化偏微分方程（PDE）类问题	训练困难；对缩放和损失加权敏感；工业鲁棒性仍然有限	[26, 27]
基于图的模型	图神经网络、图 Transformer、电路图编码器	电路拓扑表示、版图分析、寄生参数建模、拓扑发现	天然适合表示电路和版图；能处理可变规模的结构	需要带图标注的或由仿真生成的电路/版图数据集；可解释性和验证仍具挑战	[24]
生成式与基础模型	Transformer、扩散模型、多模态基础模型、大语言模型	需求分析、脚本/代码生成、仿真编排、设计辅助、候选拓扑/版图生成	表示学习能力强；适用于自动化、文档编写和工具编排	存在幻觉风险；训练或微调成本高；在安全关键的硬件决策方面尚不成熟	[28, 29]
可解释的新兴模型	柯尔莫哥洛夫–阿诺德网络（KAN）、符号回归、稀疏辨识	自适应控制、紧凑代理模型、可解释的函数逼近	可能比稠密神经网络更易解释；可得到紧凑模型	在电力电子中尚处于早期阶段；鲁棒性和基准测试仍然有限	[30]

表 2.4 中的数值是数量级层面的筛选参考值，而非普适性的要求。所需的数据集规模在很大程度上取决于维度、噪声水平、运行空间覆盖率，以及数据是来自测量、高保真仿真还是合成的试验设计活动。

表 2.4：用于模型选择的参考性数据与算力范围

模型族/范式	训练数据或采样工作量	训练算力	推理占用	在电力电子设计中的实际成熟度	合适的部署角色
经典监督学习	10^2–10^4 个标注样本	CPU；数分钟至数小时	kB–MB；µs–ms	用于诊断和低维代理模型时成熟度高	离线及嵌入式支持
深度监督代理模型	10^3–10^6 个标注的仿真/测量样本	GPU 有帮助；数小时至数天	MB–100 MB；µs–ms	对于仿真训练的代理模型为中到高	离线优化、快速设计筛选
时序与序列模型	10^3–10^6 个标注或自监督的序列/任务剖面	通常需要 GPU；数小时至数天	MB–100 MB；ms	对于监测/面向控制的任务为中等	监测、动态建模、离线设计
无监督/表示学习	10^3–10^6 个无标注样本	视模型而定，CPU/GPU	MB–100 MB；ms	对于数据分析和预处理为中等	数据探索、特征提取
概率与主动学习代理模型	初始 10^2–10^4 次昂贵评估	CPU/GPU；成本随样本数量急剧增长	MB 级；ms–s	对于昂贵仿真为中等	自适应采样、贝叶斯优化
强化学习	许多深度 RL 情形下需 10^5–10^8 个环境步；简单/基于模型的情形较少	常需 GPU/HPC；可能需数天	训练后 MB–100 MB；µs–ms	用于控制时为中等；用于拓扑设计时处于早期	离线训练、约束控制研究

模型族/范式	训练数据或采样工作量	训练算力	推理占用	在电力电子设计中的实际成熟度	合适的部署角色
物理信息/神经算子模型	10^4–10^7 个配点或仿真快照；不一定需要标注的测量数据	常需 GPU/HPC；数小时至数天/数周	MB–GB；ms–s	对于电力电子特定的多物理场为早期到中等	快速场求解器、逆向设计、代理 PDE 模型
基于图的模型	10^3–10^6 个仿真或实测的电路/版图/图	通常需要 GPU	MB–100 MB；ms	处于早期但对拓扑/版图前景可观	拓扑探索、版图/寄生参数筛查
生成式/基础模型/LLM 智能体	微调：10^3–10^5 个领域样例；预训练：远多于此	训练需大型 GPU 集群；使用时可通过 API 或本地 GPU	本地模型为 GB 级；基于 API 时在外部	用于硬件设计时处于早期，用于代码/文档时较高	人在回路的设计辅助
可解释的紧凑模型	10^2–10^4 个样本或稀疏的实验数据	CPU/GPU；数分钟至数小时	kB–MB；µs–ms	在电力电子中处于早期阶段	自适应控制、透明代理模型

该表表明，没有哪一类模型能在所有电力电子设计任务中占据主导地位。经典机器学习和梯度提升对于低维和表格型问题仍然很有吸引力。当需要反复评估非线性映射时，深度神经代理模型就变得有用。当每次仿真或实验都很昂贵时，概率模型和主动学习很有价值。强化学习最适用于序贯的设计和控制决策，特别是当拓扑评估需要一个可行的控制策略时。物理信息模型和基于图的模型在多物理场、版图和拓扑发现方面前景可观，但需要谨慎验证。LLM 和智能体工作流程目前在需求分析、文档编写、代码/脚本生成和仿真编排方面最为擅长；它们不应被当作安全关键硬件决策的自主权威。

2.2 AI 支持的拓扑与架构探索

2.2.1 自动拓扑发现

自动拓扑发现旨在生成并评估超越既有设计模板的新型变换器结构。最近的方法利用基于图的表示（例如电路图），并结合进化算法、图神经网络（GNN）和生成模型等搜索策略来提出候选拓扑。在实践中，探索空间极其庞大且高度组合化，需要进行约束感知的剪枝才能保持可处理性。硬约束（例如电压/电流限值、器件额定值）和软约束（例如效率目标、EMC 裕量、热极限、可制造性）通常被嵌入为可行性过滤器或纳入目标函数，以便尽早剔除不可行的设计，并将搜索集中在具有物理意义的区域。

自动发现的一个关键环节是对候选拓扑进行基准测试和排序。这需要在标准化的工作点和指标（例如效率图、损耗分解、热余量、元件数量、成本代理指标、EMC 指标）上进行一致的评估。通常使用代理模型和降阶仿真来实现高通量筛选，然后有选择地进行高保真验证。然而，基准测试对建模假设仍然敏感，如果约束或先验没有被仔细定义，结果可能会偏向已知的架构。

主要的挑战是对新生成拓扑的验证。与已知设计的参数优化不同，新颖结构缺乏既定的控制策略和经过验证的运行模式。如果没有合适的控制策略，性能指标就无法被可靠地评估，从而导致不完整或具有误导性的评价。这一局限促使人们将控制综合纳入发现循环——最主要的是通过强化学习或生成式 AI——它们能够为候选拓扑推断出可行的控制策略，从而实现有意义的闭环评估。

2.2.2 强化学习：自动拓扑探索的关键使能技术

RL 与电力电子设计相关，因为许多设计问题是序贯的、非线性的、有约束的，并且部分是离散的。与监督学习不同，RL 不需要为每个工作点提供标注的输入–输出对。相反，智能体与仿真模型、数字孪生或实验环境进行交互，观察状态 s_t，选择动作 a_t，并更新其策略 $\pi(a_t \mid s_t)$，以最大化期望累积奖励：

$$J(\pi) = \mathbb{E}_\pi \left[\sum_{t=0}^{T} \gamma^t r_t \right]. \tag{2.2}$$

其中，r_t 表示时间步 t 的标量奖励，T 为有限的回合时域，$\gamma \in [0,1]$ 为折扣因子，$\mathbb{E}_\pi[\cdot]$ 表示对由策略 π 和环境动态所生成轨迹的期望。在训练过程中更新策略以最大化 $J(\pi)$；在离线训练的工程应用中，经过验证的策略在随后的部署期间可以保持固定。

RL 在设计中的意义不仅限于传统的控制器整定。它可以在四个层面上支持设计自动化。第一，预训练的策略可以快速整定控制器参数、调制变量或工作点。第二，在梯度不可用或不可靠的高维搜索中，RL 可以取代或增强遗传算法等启发式优化器。第三，RL 可以通过将开关状态、连接选择、元件启用或符号化的图变换视为动作来支持拓扑探索。第四，也是对自动拓扑发现最重要的一点，RL 可以通过找出可行的调制或控制策略，来评估一个新生成的变换器结构是否真的能够运行，如图 2.1 所示。

最后这一角色是关键区别所在。拓扑生成器可能产生许多在结构上有效的电路，但仅有结构有效性并不能证明其具有工程价值。一个候选变换器必须能够调节所需的变量，遵守器件和热的限制，避免不安全的开关状态，并在预期的源和负载范围内运行。RL 将结构探索与闭环行为联系起来：对于每个候选拓扑，智能体搜索一个运行策略，并根据所产生的动态性能获得奖励或惩罚。从这个意义上说，在拓扑被推进到高保真仿真、详细优化或实验验证之前，RL 起到了可行性过滤器的作用。

> **图 2.1：** 基于 RL 的设计优化：参数化的系统状态通过学习得到的动作进行更新，在仿真环境中进行评估，并通过反映系统性能的奖励信号进行优化。

表 2.5：变换器设计中 RL 的角色、动作空间、价值与局限

RL 在设计中的角色	设计变量/动作空间	主要价值	主要局限
性能整定	控制器增益、调制变量、运行设定点	快速适配已知系统	必须验证稳定性和鲁棒性
优化支持	初始候选方案、搜索方向、探索策略	可以加速启发式多目标搜索	不能保证全局最优
控制综合	开关状态、占空比、调制模式	确定候选拓扑是否能够运行	仿真和样本成本高
拓扑生成	图操作、符号变换、元件插入/移除	能够在预定义模板之外进行探索	需要严格的物理约束和图有效性约束

近期的研究工作支持这一解读。AutoTG 将变换器设计表述为一个符号优化问题，并使用 RL 根据用户的规格和偏好生成候选功率变换器拓扑 [31]。早期关于根据规格自动设计变换器的工作展示了基于 RL 的拓扑空间探索 [32]。近期的综述进一步将 RL 在功率变换器中的应用分为拓扑推导、参数设计和控制实现 [23]，而聚焦于变换器控制的综述则总结了相应的控制应用和实现挑战 [33]。

尽管具有这些潜力，基于 RL 的拓扑探索仍然受到奖励定义、样本复杂度和验证工作量的制约。奖励必须综合效率、跟踪性能、热应力、EMC 行为、器件利用率、成本和鲁棒性等相互冲突的目标，同时不能诱导出物理上无效或仅在特定仿真中成立的解。因此，RL 应作为混合设计流程的一部分使用，配合图有效性检查、基于物理的约束、代理模型、不确定性估计以及人在回路的验证。

2.2.3 维度问题

电力电子中基于 AI 的设计方法的一个根本局限，来自于现实设计空间的极高维度。变换器架构、元件参数、控制变量和运行条件共同构成了一个高维的、离散–连续混合的优化问题。虽然 AI 方法通常能够有效地识别局部最优，但要保证接近全局最优仍然具有挑战性，尤其是在数据稀疏或计算预算有限的情况下。暴力探索是不可行的，而不受约束的学习则存在收敛到仅在设计空间狭窄区域内最优的解的风险。这一维度问题凸显了纳入基于物理的约束、分层设计分解以及有依据地减少自由度的必要性，以使 AI 驱动的探索变得可处理且与工程相关。利用元模型进行灵敏度分析，通过联合选择有影响力的变量和逼近模型来降低有效输入维度，可以作为一种替代方法 [34]。

2.2.4 控制对系统架构或元件设计的影响

电力电子设计的一个关键方面是控制策略与硬件性能之间的强耦合。一个拓扑或元件配置无法被孤立地进行有意义的优化，因为它的效率、损耗分布、热行为和 EMC 特性直接取决于所采用的控制。因此，忽略控制会导致有偏差或不完整的设计结论。

控制应被视为设计空间的一个内在维度，而不是下游的一个步骤。先进的控制策略可以重塑系统行为并弥补硬件的局限。例如，智能控制器可以改变导通损耗与开关损耗之间的平衡，使一个导通损耗高但开关特性良好的拓扑能够运行在其弱点被缓解、优势被发挥的工况中。因此，控制实际上定义了一个系统可达到的性能包络。

这种控制–硬件耦合的一个代表性例子可以在现代汽车牵引逆变器设计中找到，其中运行策略直接影响系统级的权衡。这种相互作用在汽车牵引逆变器的高调制比运行中表现得尤为明显，特别是六步波或过调制模式 [35, 36]。将运行范围扩展到线性区之外可以提高基波输出电压，从而实现更高的功率或更小的电流，其系统级影响约为 10%。与此同时，它也改变了各元件之间的损耗分布、谐波含量和热应力。

对控制的考虑并不是一个二元选择，而是一个连续的、高度参数化的空间，正如脉冲模式的例子所示 [37]。这将优化问题扩展为一个硬件–控制耦合空间，使传统方法力不从心。因此，基于 AI 的设计必须从本质上对控制和硬件进行协同优化。特别是对于拓扑探索，只有在合适的控制策略下才能评估性能。因此，将控制综合纳入设计循环，对于确保对候选架构进行有意义的闭环评估至关重要。

2.3 多物理场与 AI 增强的协同设计与优化（元件级）

2.3.1 半导体、磁性元件和无源元件的代理模型

在半导体器件层面，设计本身就涉及多个性能指标和器件参数之间的强耦合权衡，这使得高效的多目标探索变得越来越重要 [38]。磁性元件和无源元件也有类似的需求，需要精确且计算高效的模型，以将元件行为纳入更广泛的多物理场和系统级优化中 [38]。磁性元件——电感、变压器和 EMC 滤波器——是现代电力电子系统中决定效率、功率密度和热行为的关键因素。尤其是在具有高开关频率、快速边沿和多频激励的 WBG 变换器中，精确而快速的磁芯损耗模型对于与半导体、散热和机械结构进行元件级协同设计至关重要。这就

需要既保留物理洞察、又在计算上足够廉价以用于大规模优化循环的代理模型。经典的磁芯损耗模型，例如 Steinmetz 型公式及其广义变体，将比损耗近似为频率和峰值磁通密度的函数，并可扩展到非正弦波形。它们紧凑、可解释，且便于针对单一材料进行参数化。然而，一旦需要处理任意脉宽调制（PWM）模式、多频激励、直流偏置、温度依赖性以及跨材料泛化，它们就力不从心了（尽管学术界已经提出了一些修正公式）。基于磁滞和有限元的模型提高了保真度，但对于迭代式的系统级设计空间探索而言计算代价过高。

文献 [39] 中的 HARDCORE 方法展示了混合的、物理信息机器学习如何在任意 $B(t)$ 波形下为环形铁氧体磁芯弥合这一差距。该问题被分解为两个阶段。首先，一个一维残差膨胀卷积神经网络根据输入磁通密度 $B(t)$ 和工程化特征重建磁场 $H(t)$ 的完整时间序列。其次，通过对 B–H 回线面积进行物理积分得到功率损耗，随后再用一个小型残差修正网络补偿剩余的系统误差。一个核心的方法要素是大量的特征工程：除原始的 $B(t)$ 序列外，模型还输入导数、波形分类以及频率和温度等具有物理意义的标量描述量。这些特征在一个轻量级架构中与 CNN 提取的时间特征相融合，从而以极少的参数和适度的数据需求实现了很高的预测精度。

嵌入到多物理场协同设计流程中后，这类磁性代理模型能够在广阔的设计空间（材料、几何形状、气隙配置、驱动条件）中提供快速且有物理依据的损耗估计。与热模型和可靠性模型相结合，它们能够在自动化的、AI 驱动的优化和拓扑探索中高效地评估热点温度和寿命，使磁性元件成为一个一等的设计"旋钮"，而不是事后才考虑的约束。

2.3.2 用于电-热-机械耦合设计的 ML–物理混合求解器

除了上面讨论的元件级代理模型之外，功率模块的协同设计还需要评估紧密耦合的多领域行为。电损耗会产生空间上不均匀的发热；由此产生的温度梯度会引发机械应力，因为不同的材料层——半导体芯片、焊料、铜走线、陶瓷基板——以不同的速率膨胀。这种电–热–机械（E–T–M）耦合相互作用必须在设计阶段加以解决，而全保真的 FEA 或 CFD 仍是完成这项工作的标准工具。然而，一次参数化设计扫描就可能需要数千次求解器评估，当必须同时平衡多个目标时，暴力探索就变得不切实际。

经典的模型降阶（MOR）长期以来一直被用来缓解这一瓶颈。基于投影的方法将完整的有限元系统压缩到一个小的数学基上，在保留求解器数学结构和误差界的同时，将数万个方程缩减为寥寥几个。对于 SiC 功率模块，将参数化 MOR 应用于直接耦合的热–机械 FEA（同时求解温度和形变），已证明可将计算时间缩短约 80%，而应力误差低于百分之一，从而能够在材料属性和层几何结构上快速进行设计点扫描 [40]。这些方法成熟且可信，但仍然存在局限：它们需要专家来设置，并且在强非线性或高维参数空间中效率会下降。

机器学习正开始在多个层面进入这一流程。最成熟的路线是利用物理求解器生成训练数据，并拟合一个数据驱动的代理模型——通常是神经网络、高斯过程或多项式展开——在后续的优化循环中取代求解器。对于 IGBT 散热器设计，基于三维 CFD 训练的多项式混沌展开代理模型集成，已实现了带有内置不确定性量化的几何优化 [41]。对于变换器级的参数设计，最近的一个框架将神经网络可行性分类器、概率性的效率与温度预测器以及多目标优化器串联起来（全部基于仿真输出进行训练），以在热约束下权衡效率与温度 [42]。在这两种情况下，物理求解器仍然是真值的来源，并会被再次调用以验证最终的候选方案；ML 模型加速了搜索，但并不取代物理。这将基于仿真训练的代理模型与本章稍后讨论的物理信息神经网络区分开来，后者将控制方程本身编码到训练过程中。

然而，"ML–物理混合求解器"这一术语所隐含的更深层次的集成在很大程度上仍然缺失：即机器学习模型与物理求解器在同一个求解过程中共同运行的架构——例如 ML 修正的降阶模型、由神经算子增强的时间步进器，或用于加速迭代 FEA 求解器的学习型预条件子。这类方法在结构力学和增材制造工艺仿真等相邻领域正在迅速发展，但其在功率模块设计中的 E–T–M 耦合问题上的应用仍处于早期阶段。一个基于开源 MOOSE 平台的多层级多物理场框架已经展示了用于多芯片电子协同设计的、结合降阶建模的电–热–机械耦合仿真，并将 ML 增强确定为自然的下一步 [43]。

弥合这一差距的实际动力是显而易见的。对复杂散热结构——例如具有拓扑优化内部几何结构的增材制造散热器——进行基于进化算法或遗传算法的优化，通常需要数百次顺序的 CFD 评估，总计算时间以天乃至周计 [44]。将真正的 ML–物理混合求解器嵌入此类优化器的内部评估循环，可以大幅压缩这些优化活动，使迭代式的、面向具体应用的 E–T–M 协同设计在现实的项目周期内变得可行。这种加速是下一节所讨论的多目标优化和进化优化策略的关键使能因素。

2.3.3 元件、EMC 滤波器和版图的进化优化

上述优化活动说明了一个更普遍的规律：电力电子设计问题本质上是多目标的，并且相关的目标几乎总是相互冲突。散热器必须在热阻与压降、质量和温度均匀性之间取得平衡。功率模块版图必须在寄生电感与热性能和均流之间进行权衡。EMC 滤波器必须满足发射限值，同时使体积、损耗和成本最小化 [45]。没有哪一个标量品质函数能够刻画这些权衡，这就是为什么基于帕累托的优化器已成为标准框架，而遗传算法（GA）和非支配排序遗传算法（NSGA）-II 等进化算法是最广泛使用的引擎。

在实践中，这些算法与物理求解器直接耦合，使每个候选方案都以全保真度进行评估。这种方法适用于范围很广的元件。耦合 CFD 的 GA 以及结合解析热模型的 NSGA-II 已被应用于散热器和散热片的几何优化 [44, 46]。进化搜索与二维 FEA 相结合，实现了针对难以优化的寄生元件的平面变压器自动设计 [47]。综合性的 EMC 滤波器平台将元件数据库与高频寄生模型进行对照扫描，以同时从体积、损耗和衰减方面评估各种拓扑 [48]。在模块层面，NSGA-II 已被用于在多芯片版图中布置裸芯片和键合线，借助自动化的电磁和热仿真，联合最小化杂散电感、支路电感失配和结温离散度 [49]。PowerSynth 2 等设计自动化工具通过基于约束图的版图生成和降阶模型扩展了这一范式，能够快速综合从二维到三维的模块版图 [50]。

有几个缺口限制了更广泛的采用。评估成本仍然是主要瓶颈：数千次求解器调用、每次耗时数分钟到数小时，限制了在项目周期内可以探索的设计变量和目标。贝叶斯优化——一种在相邻领域已经成熟的样本高效替代方法——在电力电子元件领域基本上仍未被探索。同样缺失的是在电、热和体积耦合约束下对无源元件进行系统的多目标选型。下一节讨论的更快的代理模型和物理信息模型可以缓解评估成本瓶颈，使进化优化和贝叶斯优化在现实的变换器复杂度下都变得可行。

2.4 AI 加速的仿真、可靠性预测、设计确认与验证

2.4.1 代理模型与物理信息模型

电力电子设计越来越需要大量高保真的电磁和热仿真，用于设计空间探索、MOO、公差和蒙特卡洛研究，以及几何或拓扑优化。经典的有限元和多物理场求解器能提供可信的结果，但当需要成千上万乃至数百万次评估时，它们就会成为瓶颈。同样，尽管 SPICE 级电路仿真在运行次数有限时通常是高效的，但在大规模面向 EMC 的参数扫描或优化循环中也可能变得耗时。与此同时，工程师越来越需要在模型中纳入实测的非

线性材料和器件行为，而这在纯粹基于方程的求解器中很繁琐，但对于机器学习代理模型来说却是自然而然的 [51]。因此，快速的、能利用数据的代理模型和物理信息模型成为仿真、整定和虚拟鉴定的关键使能技术，尤其是在标量设计参数让位于几何乃至拓扑自由度的情况下。

PINN [26] 及相关方法（例如物理信息 DeepONet 和神经算子 [52]）通过神经网络直接逼近偏微分方程的解，而不是反复求解离散化的系统。在初始的一次性训练阶段，对网络参数进行优化，以最小化一个复合损失函数，该损失函数既强制满足控制方程残差，也约束与边界条件或初始条件的偏差 [26]。自动微分提供了高效的导数计算，物理约束可以作为硬约束嵌入架构之中 [53]。训练完成后，评估就简化为一次前向传播，避免了迭代求解器，在已报道的例子中，对于完整的二维或三维场，推理时间可以达到 1–100 ms 的范围 [53, 54, 55, 56]。其主要优势是多个物理领域的直接耦合、适用于优化循环的超快推理以及对测量数据的原生纳入 [26, 53]。尚存的挑战包括针对工业问题的稳健训练、适当的缩放和采样、架构选择、优化策略，以及对尖锐界面和刚性物理问题的处理 [53]。

近期的应用既展示了物理信息代理模型在与电力电子相关的多物理场问题中的潜力，也展示了其当前的局限：

- **用于电感和损耗的静磁变压器代理模型：** 对于轴对称变压器几何结构，卷积 PINN 在一个 18 维几何参数空间（包括不同的线圈和铁氧体形状）上逼近磁矢量势 [54]。报道的推理时间为每个几何结构 8–30 ms，而有限元参考计算约为 0.9 s，相当于约 30–100 倍的加速，同时电感和耦合系数的偏差保持在 1% 以内 [54]。与 HARDCORE 等数据驱动的损耗模型相结合，每个样本的磁芯损耗可在 50 ms 内预测完成 [39]。这些结果表明，与电力电子相关的场量，例如电感、耦合和磁芯损耗，可以在优化所需的时间尺度上完成评估。
- **用于任务剖面仿真的电化学电池模型：** 一个针对单粒子锂离子电池模型的物理信息 DeepONet 代理模型，以纯物理信息、无数据的方式进行训练，以捕捉在任意电流曲线和八个标量电化学参数下的电压响应。训练使用了 10,000 条随机生成的电流曲线、在 10 维时空–参数域中的 50,000 个配点、1,000,000 个训练轮次，在一块 NVIDIA H200 GPU 上耗时约 80 小时。训练后的模型在恒流、脉冲和驾驶循环工况下的平均电压误差低于 1 mV，CPU 推理时间约为 3.5 ms，比数值参考求解器快约 100 倍 [55]。
- **基于 PINN 代理模型的多领域集成与优化：** 上述例子可以推广到多领域电力电子工作流程中，在这些流程中，电、电磁和热模型必须在任务剖面和设计变异下组合使用。物理信息神经算子允许在几何形状、材料和运行条件上训练参数化的解算子 [53]，并且可以嵌入到更高层次的任务中，例如逆向设计和拓扑优化 [56]、试验设计与参数估计 [55]，以及在 18 维几何空间上的变压器优化 [54]。现有结果显示了良好的分布内精度，以及有用但并非无限的外推能力。大的拓扑变化或差异很大的物理问题可能会降低模型质量。因此，基于 PINN 的代理模型已经是 MOO 内循环和基于任务剖面的可靠性分析的有力候选者，但在它们能够在安全关键的决策循环中取代有限元模型之前，仍需要改进的训练策略、对尖锐界面和非光滑现象的稳健处理，以及系统的不确定性量化。

物理信息代理模型正从研究原型向工业流程中可部署的组件演进。DeepXDE、NVIDIA Modulus 和 TorchPhysics 等现有框架已经提供了支持 GPU 和先进训练策略的物理信息神经网络构建模块。关于面向半导体和电力电子制造的数据校准神经网络、以及在边缘设备上部署用于自动化或控制的持续研究，指向了嵌入电子设计自动化（EDA）和技术计算机辅助设计（TCAD）等虚拟设计环境中的、集成且可认证的代理

模块。对于电力电子仿真和可靠性预测，这一演进有望带来针对 EMI、磁性元件和热行为的、经过验证的标准化代理模型库，从而实现实时虚拟原型设计、自动化设计探索和更稳健的寿命评估。

2.4.2 虚拟孪生和/或数字影子

虚拟孪生（也称为数字孪生）扩展了经典仿真模型，它将设计数据、运行条件、测量结果和可靠性模型连接成电力电子系统的一个可更新的表示。在本节语境下，其主要作用是将快速代理模型和物理信息模型与可靠性预测、寿命评估和设计验证联系起来。这一点尤为重要，因为电力电子系统的寿命很少由单一元件或单一应力因素决定。半导体、键合线、焊接或烧结接头、基板、电容器、磁性元件和散热界面都承受着电、热、机械和环境的耦合载荷 [57, 58]。

在面向可靠性的虚拟孪生中，变换器的运行和任务剖面被转换为损耗、电流、电压、温度和应力循环。然后，热阻抗网络、场仿真或热代理模型提供元件级的温度曲线。这些温度曲线与退化模型或寿命模型相耦合，以估计损伤累积、剩余使用寿命或失效概率。对于功率模块，主要的失效机理通常与结温波动、平均温度、功率循环以及互连和封装中的热机械疲劳有关。对于无源元件，寿命通常由热点温度、纹波电流、电压应力、湿度和材料老化决定。

这使得虚拟孪生在设计过程的多个阶段都很有用。在概念和版图选择阶段，它可以在相同的任务剖面下比较候选拓扑、散热方案、封装技术和控制策略。在验证阶段，它可以检查预期的运行应力是否保持在设计限值之内。在应用阶段，它可以用测量数据进行更新，以检测预测行为与观测行为之间的偏差。AI 的贡献主要在于加速昂贵的模型评估、根据测量数据更新模型参数、检测异常以及估计不确定性。然而，虚拟孪生不应被当作一个单一的黑箱寿命预测器。在工程使用中，它必须保持从需求和设计参数到仿真应力、验证数据、寿命模型以及最终可靠性决策的可追溯性。

2.4.3 对所交付结果的验证/确认

只有当结果可信、可复现且可追溯时，AI 加速的仿真、代理模型和虚拟孪生才能支持工业设计。验证（verification）和确认（validation）回答的是不同的问题。验证关注的是模型实现、软件流程、数据管道和数值过程是否正确。确认关注的是所交付的结果对于预期的工程决策是否足够准确。对于基于 AI 的工具，这种区分至关重要，因为其输出不仅取决于物理方程和求解器设置，还取决于训练数据、模型架构、超参数、不确定性处理以及外推行为。

一个实用的验证与确认流程应从明确界定预期用途开始。用于早期设计空间筛选的代理模型，与用于寿命预测、合规支持或安全相关决策的模型相比，所需的证据等级并不相同。因此，确认包络应规定电压、电流、温度、开关频率、拓扑、元件技术、散热条件、任务剖面和版图假设的允许范围。超出该包络的预测应被明确标记为外推，而不应与经过确认的域内结果以相同的置信度报告。

自动化的验证与确认可以通过将一致性检查直接嵌入设计流程来减少人工工作量。这些检查可能包括单位和边界条件检查、与解析极限的比较、守恒律残差、单调性或无源性约束、独立求解器交叉检查、跨软件版本的回归测试，以及与测量数据的比较。对于 AI 模型，还需要额外的检查，包括不确定性量化、置信区间校准、灵敏度分析、主导输入因素的可解释性、分布外检测，以及训练和确认数据集的文档记录。当前的 AI 质量和风险管理标准越来越强调这种基于生命周期的评估，包括质量特性、风险识别、监测以及对 AI 特有不确定性的处理 [59, 60]。

合规性也必须被明确地加以处理。根据应用的不同，电力电子产品可能需要满足 IEC、ISO、UL、汽车、电网规范或客户特定的要求。因此，AI 生成的结果应与需求、测试用例、模型假设和证据工件相关联。对于安全相关功能，IEC 61508 强调针对电气、电子和可编程电子安全相关系统的结构化生命周期流程；基于 AI 的工具必须被纳入这些流程中，而不是被用作无法追溯的捷径 [61]。这并不意味着每一个 AI 代理模型本身都必须经过认证，但它的角色必须被明确分类，例如设计辅助、筛选、虚拟测试、鉴定支持，或控制与保护功能。

虚拟鉴定和 AI 生成的应力场景是这一流程的有前景的扩展。AI 不只是复现已知的测试用例，还可以帮助生成极端工况、罕见的任务剖面、最坏情况的热循环、公差组合、EMI 敏感的工作点以及与老化相关的应力模式。这些场景可以提高设计的鲁棒性，降低确认仅覆盖标称运行的风险。然而，除非已经证明了模型预测与实测行为之间的相关性，否则虚拟鉴定无法取代物理测试。因此，可信的路线是混合式的：AI 加速场景生成、仿真和文档编写，而最终鉴定仍以独立的测量、物理约束、不确定性界限和可审计的工程判断为依据。

2.5 展望与研究需求

2.5.1 总结——集成设计–仿真–鉴定的数字孪生

前面各节表明，正在逐渐从孤立的 AI 工具向集成的设计–仿真–鉴定环境转变。在这样的流程中，拓扑探索、元件选型、多物理场仿真、可靠性预测和验证不再被视为相互分离的顺序步骤。相反，它们通过一个数字孪生框架连接起来，在该框架中，设计参数、仿真模型、代理模型、任务剖面、测量数据和鉴定证据在整个开发周期中都保持可追溯。

对于电力电子来说，这种集成尤为重要，因为设计决策在各领域之间强烈耦合。一个拓扑或调制策略会影响半导体损耗、热负荷、磁性元件设计、EMC 行为、电容器应力，并最终影响寿命。因此，集成孪生可以提供一个公共的评估层：AI 辅助生成的拓扑或参数候选方案首先由快速代理模型和物理信息模型进行筛选，然后在任务剖面下进行评估，最后与可靠性和验证准则相关联。这使得能够更早地识别薄弱的设计区域，并降低优化在改善某一指标的同时违反热、EMI、寿命或可制造性约束的风险。

长期目标并不是一个完全自主的黑箱设计流程，而是一个可追溯、可认证的工程流程。数字孪生应结合基于物理的模型、数据驱动的代理模型、不确定性量化和实测确认数据。其输出应支持设计决策、为虚拟鉴定生成证据并指导物理测试，而不是取代工程判断。在这一角色中，AI 成为加速和协调层：它减少仿真工作量、提出设计备选方案、识别应力场景、支持文档编写，并帮助保持需求、模型、测试和鉴定工件之间的一致性。

因此，未来的电力电子设计环境很可能会演变为闭环的数字化工程平台。这些平台将结合自动化探索、快速多物理场评估、可靠性感知的优化以及面向标准的验证。它们的工业价值将不仅仅取决于单个 AI 模型的精度，而更多地取决于可追溯性、鲁棒性、不确定性处理以及与现有工程和认证流程的集成。

2.5.2 大语言模型对设计流程的影响

LLM 和基于 Transformer 的基础模型的应用正日益重塑工程流程。这些模型建立在《Attention Is All You Need》[62] 中提出的 Transformer 架构之上，其自注意力机制实现了可扩展的上下文推理，并构成了现代生成式预训练 Transformer（GPT）类系统的基础 [13]。大规模预训练和迁移学习已成为主导范

式，而近期的多模态模型则将这些能力扩展到与工程相关的跨领域输入，包括文本、图形和仿真数据 [63, 64]。

在电力电子中，LLM 的采用在以软件为中心和以硬件为中心的工作流程之间表现出明显的不对称性。LLM 在面向软件的任务中已经非常有效，例如需求获取、嵌入式固件生成、调试、测试综合和文档编写，这得益于大规模代码语料和成熟的 DevOps 工具 [21, 65]。相比之下，以硬件为中心的活动，例如拓扑选择、元件选型和仿真驱动的优化，仍然不够成熟，目前的演示主要局限于研究环境（例如 PE-GPT 及相关框架）[28, 66]。这一差距反映了硬件设计从根本上更高的复杂性，它需要整合物理约束、结构化的工程知识，并与仿真工具紧密耦合 [21]。

一个关键的新兴方向是使用自主的、基于智能体的 AI 系统来编排设计流程。基于 LLM 的代码生成能力（例如类 Codex 系统），这些智能体可以规划设计任务、生成仿真脚本、在 LTspice、SIMetrix、PLECS 或 MATLAB/Simulink 等工具中执行这些脚本、分析输出，并迭代地改进设计参数。近期的方法将推理与行动（例如 ReAct 式框架）同反思式优化（例如 Reflexion）相结合，实现了跨多个工具和领域的闭环设计探索 [67, 68]。个人 AI 助手和工程副驾驶（例如 OpenClaw 类系统）的早期实现展示了此类智能体如何将多步骤流程自动化，包括模型搭建、参数扫描、灵敏度分析和文档生成。尽管仍处于萌芽阶段，这些智能体方法代表了从被动辅助向主动设计编排的重大转变。

尽管取得了这些进展，仍有若干局限制约着其在以硬件为中心的工作流程中的采用。即使是物理信息 LLM 智能体，也需要高质量的领域特定数据、正式的验证程序和人工监督，以确保正确性和可复现性 [69]、[70]。PE-GPT 等方法集成了检索增强生成（RAG）、基于物理的约束和仿真反馈回路，以减少幻觉并强制输出在物理上保持一致 [21, 28]。更广泛的综述强调了在数据可得性、泛化以及与现有工程工具链集成方面持续存在的挑战，因此需要系统的验证、极端工况测试和专家确认 [66, 71]。

因此，LLM 目前在作为混合流程中的辅助系统部署时最为有效。在这种情况下，LLM 加速构思、文档编写和代码级开发，而核心硬件设计仍然以基于物理的建模、仿真和经验确认为基础，由工程师负责验证和签核 [21, 66]。领域适配的模型（例如 PE-GPT）展示了如何将变换器特定的约束、调制策略和设计规则嵌入到模型推理中，从而能够与工程任务进行更有意义的交互 [28, 72]。当与数字孪生和代理模型相结合时，LLM 可以支持与电、热和电磁行为相一致的系统级推理 [72]。

新兴能力进一步延伸到可追溯性和可认证的设计流程。基于 LLM 的系统可以将需求映射到设计工件、生成测试用例、识别合规差距，并支持符合工程标准的文档编写 [21]、[65]。与此同时，多智能体架构能够在拓扑探索、参数整定和灵敏度分析等设计任务之间进行分布式优化，为协调一致的设计空间探索提供结构化框架 [70, 67]。然而，对于工业采用而言，鲁棒性仍然至关重要：工作流程必须纳入不确定性量化、可解释性，并与既定的 IEC/ISO 和汽车鉴定流程保持一致 [72]。人在回路的确认仍然必不可少，尤其是在可制造性、可靠性和安全关键评估方面。

展望未来，多模态 LLM、智能体编排、仿真环境和结构化知识框架的融合有望重新定义电力电子的设计流程。未来的方向包括自动化调制设计、智能化物料清单优化、EMI 感知的版图生成以及受物理约束的拓扑发现 [69, 15]。随着数据集、验证管道和领域适配的成熟，LLM 驱动的系统——尤其是那些采用直接与工程工具交互的自主智能体的系统——很可能成为设计环境的基础组件，从而实现更快的迭代、更好的可追溯性和更全局优化的解决方案 [21, 72]。

2.5.3 行动呼吁：技能缺口以及科研与产业需求

在电力电子、数据驱动建模和以软件为中心的工程三者的交汇处，一个持续存在的技能缺口正在显现。除了电路和控制方面的经典专业知识外，有效采用 AI 还需要机器学习、数据工程和工具链集成方面的能力。因此，有针对性的技能提升、跨学科团队以及面向工程实际的 AI 实践是部署的先决条件。这一缺口也加剧了现有的对基于 AI 方法的怀疑和不信任。然而，这既不能成为拒绝的理由，也不能成为盲目信任的理由；相反，采用应通过渐进式集成来推进，每一步都在既定的工程流程中经过严格的验证和确认。

从产业角度看，当务之急是从手工的、以硬件为中心的原型过渡到稳健的、可认证的虚拟流程。这需要标准化的数据管道、经过确认的数据集，以及与现有 EDA/计算机辅助工程（CAE）环境的紧密集成。治理机制——可追溯性、不确定性量化、可解释性以及对 IEC/ISO/汽车标准的合规——必须从设计之初就嵌入其中。企业应投资于面向工程的内部 MLOps（数据和版本控制、模型确认、可审计性），以及用于验证和签核的人在回路流程。与此同时，持续的技能提升计划和将 AI 逐步集成到现有流程中也是必不可少的，并且在每一步都要高度重视验证、鲁棒性和可追溯性，以系统地建立对 AI 辅助工程的信任。

从科研角度看，重点应转向可复现的、有基准的、系统级的解决方案。关键缺口包括缺乏公开的高质量数据集、跨拓扑泛化能力有限，以及物理约束在学习模型中集成不足。优先事项包括物理–ML 混合方法、标准化基准、开放的参考实现，以及将学习与仿真和实验验证相结合的可扩展验证规程。研究机构应发挥倍增器的作用，以必要的勇气去探索未知方向，而不受眼前经济合理性的束缚。高度重视开放、透明和可复现的模型与管道，对于实现向产业的快速转移和适配、减少重复工作以及建立对 AI 驱动工程的集体信任至关重要。

资助和政策应重新调整方向，聚焦于基础设施和成果转化：开放数据集、共享仿真平台和参考工具链；连接 AI、电力电子和软件工程的长期计划；以及对产学合作的激励措施。重点应优先放在 AI 的长期、可持续采用上，而不是那些很少能转化为产业实践的短期"速效成果"。应对 AI（尤其是生成式 AI）未来挑战的前瞻性计划，应致力于减少模糊性、提高鲁棒性并降低集成门槛。支持应明确针对对产业（包括较小的实体）切实可行的验证框架、认证路径和治理模式——对于这些较小的实体，过度监管加上专业知识有限可能会阻碍采用。清晰的指南、共享的最佳实践和可获取的验证基础设施，对于实现 AI 辅助设计的广泛、可信部署至关重要。

需要教育、产业和政策各方面协同行动，以弥合技能缺口、建立可靠的工程框架，并在电力电子中实现可信、可扩展的 AI 驱动设计。

3 AI 在电力电子制造中的应用

对电力电子日益增长的需求由能源转型和交通电气化所驱动，而家电和消费类设备应用则构成了另一个主要的部署领域 [73, 74]。这对制造商提出了挑战：要实现更小的封装、更高的集成密度和更好的热管理，同时还要提高良率并降低成本 [75, 76, 77]。生产链涵盖从半导体制造和量测到模块、基板、封装集成以及可靠性测试等紧密耦合的各个阶段 [78, 79, 75]。由于底层数据是多维的、非线性的且相互依赖，AI 方法正越来越多地被用于支持工艺理解和优化 [80, 81, 78]。已报道的收益包括更快的良率爬坡、更短的量测延迟、更高的工艺质量以及更少的停机时间 [81, 82, 79, 83]。

3.1 电力电子制造中 AI 用例与方法的系统化梳理

为了梳理 AI 在电力电子制造中于何处以及如何创造价值，本章采用了 Chen 等人提出的二维分类框架 [84]。其中一个轴刻画认知维度，即 AI 系统所提供的分析洞察的深度。另一个轴描述结构维度，即该洞察被应用于制造系统的哪个部分。

3.1.1 认知维度：从可见性到自主性

认知轴遵循"四知"（four-knows）分类法，该分类法按照分析能力的成熟度对 AI 系统进行分类。

在最基础的层级，**知其然（know-what，可见性）** 建立对当前工艺状态的认知：设备是否在漂移，晶圆是否仍在规格范围内，或者某个工艺参数是否已超出其控制限。在公差狭窄、可靠性要求严格的电力电子制造中，这种实时可见性本身就已具有相当大的实用价值 [78]。

知其所以然（know-why，透明性） 超越了检测，追问是什么导致了所观察到的偏差。根因模型帮助工程师将缺陷追溯到其源头，而不是通过反复试错来应对症状。这在多步骤工艺链中尤其重要，因为良率损失可能是在最终被检测到之处的上游若干工序中引入的 [84]。

知其何时（know-when，预测） 增加了时间维度的视角。通过预测未来的系统状态——无论是产品质量趋势、设备退化轨迹还是工艺漂移——制造商可以从被动响应转向基于状态的策略。其运营收益显而易见：更少的计划外停机、时机更合适的维护以及更稳定的产出 [79, 85]。

最高级的层级，**知其如何做（know-how，处方）**，实现了闭环。在这一阶段，AI 系统会推荐或自主执行纠正措施，从实时的配方调整到优化的维护计划。尽管这有望带来最大的运营影响，但在电力电子中的部署仍然受到认证要求以及安全关键应用对可解释性需求的限制 [84]。

3.1.2 结构维度：应用范围

第二个轴刻画的是这些认知能力在制造系统中的部署位置。在**产品层级**，关注点是芯片和模块质量。AI 通过将电参数、物理完整性和热行为等器件特性与下游的现场性能联系起来，支持良率提升和可靠性保证。**工艺层级**针对单个制造步骤，将配方参数与步骤级结果关联起来。在微小的参数偏移可能对器件可靠性产生不成比例影响的场合，这种粒度是必不可少的。在**设备层级**，关注点转向设备本身的状态，通过监测腔室健康状况、耗材磨损和校准漂移来防止计划外停机，并保持一致的工艺能力。最后，**系统层级**涵盖全厂范围的问题，例如跨步骤优化、端到端可追溯性和测试时间缩减，这些都依赖于在制造执行系统（MES）中整合数据。

将这两个维度叠加，便得到一个矩阵，其中每个单元格代表一类不同的 AI 应用，各自具有不同的数据要求、建模挑战和运营价值。表 3.1 给出了电力电子制造的这一映射。由于专门针对功率半导体制造的已发表 AI 应用仍然有限，该表还借鉴了逻辑和存储器制造等相邻半导体领域中经过验证的工作，这些领域在工艺设备、检测方式和数据结构方面与之基本相同。

表 3.1：电力电子制造中具有代表性的 AI/ML 应用

层级	范围	知其然（可见性）	知其所以然（透明性）	知其何时（预测）	知其如何做（处方）
产品	*前道测试*				

层级	范围	知其然（可见性）	知其所以然（透明性）	知其何时（预测）	知其如何做（处方）
	晶圆分选	晶圆缺陷分类 [86, 87, 88]	空间模式分析 [89, 90]	虚拟电性测试 [79, 91]	基于覆盖率的测试缩减 [92]
	后道测试				
	下线（EoL）测试	参数异常检测 †	失效模式聚类 †	可靠性预测 †	面向良率优化的分档 [93]
	老化（Burn-In）测试	原位退化监测 †	失效机理分类 †	早期失效预测 [94]	老化缩减 [95, 96, 97, 98]
工艺	*前道工艺*				
	外延	基于原位信号的生长状态 [99]	生长参数关联 [100]	外延生长速率预测 [101]	批次间（run-to-run）配方优化 [102, 103]
	离子注入	束流形状控制 [104]	剂量均匀性根因 †	离子源剩余使用寿命（RUL）预测 †	剂量控制 [105]
	退火	原位方阻监测 †	激活均匀性根因 †	加热器 RUL 预测 †	方阻优化 [106]
	刻蚀	基于光学发射光谱（OES）的终点检测 [107]	腔室故障分类 [108]	刻蚀设备 RUL 预测 [109, 110, 111]	刻蚀配方优化 [112]
	光刻	晶圆图缺陷检测 [87]	套刻误差根因 [113, 114]	掩模退化预测 †	剂量/焦距优化 [105]
	后道组装				
	芯片贴装	X 射线/扫描声学显微镜（SAM）空洞检测 [115, 116]	空洞形成根因 †	空洞–热阻（Rth）预测 [117]	拾放优化 [118, 119]
	键合	键合脱落监测 [120]	可解释的质量分类 [121]	拉力/剪切强度预测 [122, 123, 124]	多目标键合参数优化 [125]
	灌封	空洞检测 [115]	模流缺陷关联 [126]	封装翘曲预测 [127]	翘曲参数优化 [128]
设备	设备	腔室状态监测；设备漂移检测 [85, 129]	基于深度学习的设备故障诊断 [130]	停机/RUL 预测 [85, 131, 83]	维护排程 [84]
系统	全厂	跨设备故障检测与分类（FDC）可迁移性评估 [132]	跨步骤根因分析 [80]	良率预测 [133]	生产排程 [134, 135]

† 在撰写本文时尚未找到已发表文献支持、但看似合理的用例。

3.2 从洞察到实施：选择合适的模型

一旦确定了用例，接下来的实际问题就是部署哪种模型架构。在生产现场，这一选择很少仅由精度决定。数据可得性、时延约束以及对可解释输出的需求都具有相当大的分量，特别是当模型预测为工艺控制或质量保

证决策提供依据时 [84, 78, 121, 136]。表 3.2 将常见的模型类别与其典型的数据模态以及在"四知"框架 [84] 中所处的认知阶段联系起来，可作为将给定用例匹配到合适架构的参考。

表 3.2：电力电子制造中具有代表性的 AI 模型类别及示例应用（作者根据 [84, 78, 79, 137, 103] 整理）

模型类别	方法	认知阶段	数据模态*	示例应用
卷积类	CNN、ViT、U-Net	知其然	图像/时间序列	晶圆检测；空洞检测；键合检测
自编码器	AE、VAE	知其然/知其所以然	图像/时间序列	腔室异常检测；漂移识别
基于树的方法	XGBoost、随机森林	知其所以然/知其何时	表格数据	虚拟量测；质量预测
概率类	贝叶斯网络、高斯过程	知其所以然	表格数据	参数探索；不确定性量化
循环/注意力类	LSTM、Transformer	知其何时	时间序列/图像	RUL 预测；温度曲线预测
物理信息类	PINN、混合 ML	知其所以然/知其何时	时间序列/表格数据	热阻估计；数字孪生
基于策略的方法	RL、贝叶斯优化	知其如何做	表格数据/时间序列	配方整定；批次间控制
聚类	k 均值、自组织映射（SOM）	知其所以然	表格数据/图像	缺陷聚类；设备分群

* 大多数模型类别都能处理其他数据模态；表中所列条目反映的是典型用法。

在全部四个结构层级上，生产部署已经展示了这些模型类别的实用价值。卷积架构在晶圆图缺陷分类中目前已常规地达到 96–98% 的准确率 [138, 139]；在标注数据稀缺的场合，具备少样本适配能力的视觉基础模型已经弥补了大部分剩余差距 [140]。

> **图 3.1 内容示意**（电力电子制造链各工艺步骤及对应的代表性 AI/ML 方法）：
>
> - **晶圆制造（上游工艺优化）：** 晶锭 → 切割与研磨（崩边检测；厚度与总厚度偏差 TTV 预测）→ 化学机械抛光 CMP（终点预测）→ 清洗（晶圆表面检测的计算机视觉 CV；晶圆分级）→ 外延（缺陷预测；贝叶斯学习；RL；批次间优化；虚拟量测；生长参数探索）。
> - **前道工艺（下游缺陷预测与反馈）：** 光刻（掩模健康监测；光刻胶缺陷检测的 CV；基于 GAN 的逆向光刻 ILT 模型；自适应曝光控制）→ 离子注入（离子源 RUL 预测；注入损伤预测）→ 刻蚀（等离子体状态监测；形貌预测，例如微沟槽）→ PVD/CVD → 金属化（配方整定；代理模型；腔室健康监测）；缺陷检测与分类（CNN、ViT；基于视觉语言模型 VLM 的晶圆级推理）。
> - **后道工艺：** 划片（裂纹检测的 CV；芯片分级与智能分档）→ 芯片贴装（空洞检测的 CV；烧结质量预测；CNN、VAE、U-Net）→ 引线键合（键合质量检测；拉力/剪切预测；自组织映射 SOM；键合线检测的异常检测）→ 灌封（热机械数字孪生）→ 器件测试与老化（自适应老化；生存分析）。
> - **基板制造：** 粉末 → 原料制备（配方优化，贝叶斯方法；代理模型）→ 成型 → 脱脂（裂纹/起泡风险预测；溶剂萃取时间建模）→ 烧结（PINN；翘曲/收缩预测；缺陷检测的 CV，如凹坑、气泡）→ 金属化（检测与缺陷分类的 CV；YOLO 类模型；钎焊合金成分优化）→ 化学表面处理（镀液健康状况估计；镀层缺陷预测）→ 局部放电表征（故障检测；RUL 预测）→ 基板。

> **图 3.1：** 电力电子制造链概览，以及映射到每个工艺步骤的代表性 AI/ML 方法和应用。图片来源：frog – stock.adobe.com (#47721432)；Muhammad – stock.adobe.com (#2070511296)；iStock.com/dahuang1231 (#2248314480)。

XGBoost 等基于树的方法在虚拟量测中占据主导地位，它们以逐片晶圆的质量估计取代了不频繁的抽检，从而实现了 100% 的晶圆覆盖率和更紧密的批次间控制回路 [141, 142, 143, 144]。在设备层级，半导体预测与健康管理越来越依赖循环模型、迁移学习模型和基于注意力的模型进行剩余使用寿命预测，尤其是针对离子铣刻蚀设备 [145, 109, 110, 111]。更广泛地说，据报道，工业预测性维护部署可将计划外停机减少多达 50%，将维护成本降低约 40%；这在半导体制造中尤为重要，因为计划外停机造成的损失可达每小时数百万美元 [146, 83]。在谱系的处方端，对于其非线性动态无法被传统线性模型很好刻画的工艺，强化学习正在成为经典的基于 EWMA 的批次间控制器的一种可行替代方案 [137]。图 3.1 将结构视角和认知视角结合起来，把具有代表性的 AI 方法和应用映射到物理制造链上，从基板制造、前道晶圆工艺、后道模块组装一直到最终的器件测试。

3.3 典型 AI 应用及成功实施的最佳实践

作为上述系统性综述的补充，本节通过两个案例研究来说明 AI 在电力电子中的实际影响。第一个案例来自弗劳恩霍夫 IKTS，采用基于 Transformer 的架构，根据高速率的局部放电信号预测基板的剩余使用寿命。第二个案例来自西门子在埃尔朗根的功率模块生产线，部署了用于自动化键合线检测的无监督异常检测。它们共同展示了 AI 方法如何从研究转化为可衡量的生产收益。

3.3.1 基于局部放电数据的 AI 驱动剩余使用寿命预测

利用图像分类来解读来自计算机断层扫描（CT）或 SAM 等各种电力电子表征方法的数据，已是业界先进水平且已广泛可用。因此，这里将介绍一种不同的方法，作为电力电子中更为专门化的 AI 方法的一个示例。

随着电力电子模块的制造推进，系统的复杂性呈指数级增长。这就需要在工艺中尽可能早地进行失效预测，以免在后续环节中再投入可能白白损失的价值。由于直接覆铜（DCB）基板容易出现由热循环引起的缺陷，从而导致在现场发生击穿，因此对基板进行表征可以减少后续成本。CT 和 SAM 提供了一种（耗时的）解决方案，但无法表征对模块完整性至关重要的电气特性。作为替代方案，局部放电（PD）测量正在得到推广。

> **图 3.2：** 相位分辨局部放电图谱，按 PD 源着色（左），以及特征脉冲波形（右）。

局部放电是发生在绝缘系统几何受限部位、但不像击穿那样贯穿整个绝缘的放电。它们往往发生在空洞、裂纹、导电颗粒或材料界面等缺陷处。当由交流电源激发时，每次局部放电都可以用其强度（称为视在电荷 q_{app}）以及相对于试验电压的相位来表征。利用这些值，可以生成相位分辨局部放电（PRPD）图谱，形成与 PD 源相关的图样。这些图谱通常用于识别 PD 发生的潜在来源，但来自不同来源的 PD 在时间和相位上容易发生重叠。为了在这些情况下实现分类，可以利用每个脉冲的波形，因为它与其发生的物理特性相关（图 3.2）。

此处介绍的方法的目标是找到 DCB 基板的缺陷或 RUL 与 PD 特征之间的相关性，并训练一个人工神经网络（ANN）来检测退化或缺陷。为了建立数据库，制作了数百个双面金属化的样品，并按照汽车鉴定指南

（AQG）324 分批进行人工老化，温度范围为 −40 °C 至 125 °C，保持时间 15 分钟。为了对样品进行分类，弗劳恩霍夫 IKTS 搭建了一个自动化测试台，能够以高达 150 万事件/秒的速率进行 PD 检测和脉冲波形分类。它能够使用用户定义的电压/频率斜坡（最高 17 kV，20 Hz … 2 kHz）进行符合 IEC 60270 的测试。

> **图 3.3：** 一个未经人工老化样品的时域图（上）和相位分辨局部放电图谱（下），展示不同的细节层次。PD 事件的颜色编码通过模式分类实时完成。

与传统的 PD 测量系统不同，IKTS 开发的解决方案对每次 PD 事件所采集的脉冲波形进行采样和实时分类。所产生的数据在多个维度上相互依赖（图 3.3），数据速率接近 800 MB/s。

所采集的数据含有噪声，在维度和数量上都很复杂，彼此重叠，并且沿时间轴具有不同的信息深度，这使其与数字化的人类语音有些相似。利用这种相似性，在"面向可持续电力电子的多模态 AI 分析"项目[2]中，与 Impact Labs GmbH[1] 合作开发了一个同时用于 RUL 和故障检测的人工神经网络。该模型采用基于 Transformer 的掩码自编码器架构，能够对完整的脉冲序列（多个连续的 PD 事件）进行资源高效的离群点检测。它在来自多个测量源的、部分被掩码的无标注原始数据上进行预训练，使其能够学习 PD 行为与不同放电源之间的基本相互依赖关系。随后，使用来自人工老化或基板缺陷的标签对同一模型进行微调，从而减少了完成回归或分类任务所需的人工标注量。系统采用语音识别模型中已成熟的方法进行剪枝和量化，从而能够在消费级硬件上实时运行，而无需专门的 AI 集群或硬件。仅评估一次测量中的 600（！）个脉冲波形，它就实现了超过 90% 的 RUL 预测精度（基于热冲击循环次数计算），误差为 ±5%（图 3.4）。

> **图 3.4：** 人工老化的 SCB 基板的预测 RUL 与实际 RUL 的比较。RUL 被估计为与冲击循环次数成线性比例。

缺陷检测通过对模型进行微调、使其识别特定用例的噪声基底和"黄金板"（golden board）特征来检测离群点。这表明了该方法的高度适应性，无需重新训练整个模型，使得该方法能够适用于来自各种来源的原始测量数据。

> [1] 如需进一步咨询，请联系 Dr. Oliver Guhr：oliver.guhr@develappers.de [2] 由萨克森开发银行和欧洲区域发展基金资助，资助编号 100723614

3.3.2 批量生产中用于键合线检测的无监督异常检测

粗线键合是 IGBT 模块组装中的一个关键步骤，其质量保证传统上依赖于 100% 的人工目视检查。这一劳动密集型过程造成了生产吞吐量的瓶颈，并且由于操作员疲劳和主观评估标准而引入了不一致性。典型的缺陷——焊球、纤维、键合线错位和污染——如果未被发现，可能会损害模块的可靠性，但识别它们需要在每个班次的数千个单元上保持持续的注意力。

为了解决这一问题，在功率模块后道生产线上部署了一套自动光学检测（AOI）系统。与需要穷尽式编程缺陷特征的传统基于规则的机器视觉系统不同，该实现利用了无监督异常检测方法。该系统无需针对特定缺陷的训练数据，而是直接从生产样本中学习"正常"键合结果的表示。模块根据与这一学习到的基线的偏差被自动分为"正常"和"异常"两类，从而能够立即向键合工艺提供反馈。

该部署使人工检测工作量减少了 30% 以上，操作员的角色从穷尽式筛查转变为抽检确认和异常处理。至关重要的是，该系统会生成异常分数热力图，直观地突出显示检测到的偏差的空间位置，使操作员能够在复检时快速识别并评估被标记缺陷的具体性质。与无辅助的目视检查相比，这种定位能力显著加快了根因分析，并支持更一致的决策。

> **图 3.5：** 带有纤维（左）和焊球（右）的二极管的异常分数热力图。由西门子股份公司的 Nataliya Müller 和 Jonas Pirner 提供。

从认知角度看，该系统在产品层级建立了对工艺符合性的实时可见性，对应于"四知"框架中的"知其然"阶段 [84]。它无需针对特定缺陷进行重新训练即可泛化的能力，解决了半导体制造中一个长期存在的挑战：在模型开发期间未曾预料到的新失效模式的出现。通过专注于对"正常性"建模而不是枚举缺陷，AOI 系统对工艺漂移和未预料到的异常类型保持鲁棒 [147]。

这一应用的成功突显了 AI 赋能质量保证的一个更广泛的趋势：从需要大量标注数据集的监督分类，转向只需极少人工标注即可运行的自监督和异常检测范式。未来的扩展可能会通过将检测到的异常与键合力、超声功率或基板温度等上游工艺参数相关联，纳入"知其所以然"的能力，从而实现预测性质量控制 [148, 121]。

3.4 "会思考的工厂"：生成式 AI 与自主 AI 智能体的新兴应用

生成式 AI 和智能体 AI 代表了人工智能演进的一个新阶段，其特征是系统能够创造内容并自主执行动作、追求目标，而不仅仅是分类或预测。突出的例子包括 Stable Diffusion 等图像生成系统，以及 GPT 和其他能够撰写、总结、推理并生成复杂文档或软件代码的 LLM 等文本生成模型。最近，这些能力已被扩展到智能体 AI 系统中，这些系统将生成模型与规划、记忆和工具使用机制相结合。智能体系统不是针对一个提示词产生单一输出，而是可以将复杂目标分解为多个步骤，与软件工具或数据库交互，并根据反馈迭代地改进其行动。应用于功率半导体制造和设备维护时，生成式 AI 和智能体 AI 超越了传统的分析，走向自适应的、知识驱动的生产支持以及日益自主的决策框架 [149, 150, 151, 152]。

生成式 AI 正开始解决工艺开发和运营中的瓶颈：一方面用学习得到的生成模型取代计算代价高昂的仿真，例如使用图像合成技术来加速逆向光刻技术（ILT）流程 [153, 154, 155, 156]；另一方面生成高质量的合成数据，以克服数据稀缺并改进检测和缺陷分类系统的训练 [157, 158, 159, 160]。在这些能力的基础上，智能体 AI 系统可以在 MES、设备控制软件和数据平台之间编排多步骤工作流程，例如持续监测设备健康状况、关联各工艺步骤之间的异常、触发预测性维护（PdM）措施，以及协调配方调整或技术人员干预等响应 [161, 151, 152, 162]。这些方法共同推动了向主动的、自我优化的运营方式的转变，在这种方式下，AI 支持更快的工艺开发周期、缓解数据限制并辅助工程师，将传统自动化扩展为自适应的、自主的"会思考的工厂"（thinking fab）。

3.4.1 从分析型 AI 到智能体 AI 的转变

AI 系统的实际实施最终归结为运营决策（例如合格/不合格、放行/不放行），这些决策要么由人在 AI 推荐的支持下作出，要么由系统自身自主执行。由于决策过程中所使用的不同类别 AI 之间的过渡是渐进的（因为从本质上讲，大多数 AI 模型都是在估计概率），我们引入"决策空间"这一概念，作为区分分析型 AI、生成式 AI 和智能体 AI 的度量。

传统 ML 和分析型 AI 通常用于缺陷分类、异常检测或 RUL 预测等任务，其决策空间通常狭窄且受到良好约束。决策是离散的，通常是二元或类别型的（例如合格/不合格、缺陷类型 A/B/C、预计在 X 小时内失效）。

相比之下，生成式 AI 在一个大得多的决策空间中运作。它不是从预定义的类别中进行选择，而是产生高维输出，例如图像、信号或文本。例如，在 ILT 应用中，生成模型在像素级别定义掩模图形；在合成数据生成中，它们产生逼真的晶圆缺陷图像。语言模型逐个词元（token）地生成代码、配方或文档。在这里，决策空间扩展为连续的、结构化的输出生成。

智能体 AI 系统引入了一种性质上不同的决策形式。通过将生成模型与规划、记忆和工具使用相结合，它们在一个开放式的决策空间中运作，原则上该空间仅受可用工具、系统约束和所施加的护栏的限制。

OpenClaw 是这种开放式推理系统的潜力与风险的一个鲜明例证。它是一个实验性的开源智能体 AI，能够与各种工具交互、执行 shell 命令，并以提升的系统权限运行 [163]。在一些已报道的案例中，OpenClaw 在实时运行的系统上自主解决了其自身代码库中的问题，展示了自我改进和处理不可预见的边缘情况的能力 [164, 165]。然而，也有大量报告称 OpenClaw 把自己的代码破坏到无法恢复的地步，这凸显了在高风险工业环境中部署智能体 AI 时，稳健的护栏、验证机制和人在回路（HITL）控制的至关重要性。

表 3.3：AI 系统的自主程度与风险分类

AI 类别	自主程度	决策空间	风险特征
分析型	低	二元、离散	低（假阳性、假阴性）
生成式	中	创造性、信息性	中等（幻觉）
智能体	高	开放式、功能性	高（系统性不稳定）

3.4.2 按自主程度与影响对用例进行分类

为了系统地组织 AI 应用，我们将具有代表性的用例映射到由"利害/影响"和"能动性/自主性"所定义的二维空间中，如图 3.6 所示。利害/影响轴反映的是工厂内某一决策的运营和财务后果，而能动性/自主性轴刻画的是 AI 系统能够在多大程度上超越预定义逻辑行事，即其决策空间的广度。这一框架补充了现有的自动化层级（例如 MES、先进过程控制（APC）和设备控制），明确地将 AI 能力与决策权限和风险联系起来。

在低能动性一端，AI 系统在受约束的决策空间内运行，产生确定性或类别型的输出。这些系统通常嵌入在既定的工厂流程中，并与 APC、FDC 和 MES 紧密耦合。具有代表性的高影响用例包括缺陷检测与分类、带 RUL 估计的 PdM 以及虚拟量测（VM）。尽管决策逻辑很窄（例如合格/不合格、阈值越限、类别标签），但其运营影响是巨大的：触发设备暂停、返工回路或维护措施会直接影响良率、生产周期和整体设备效率（OEE）。因此，这些分析型 AI 系统处于高利害、低能动性的象限，在这里鲁棒性、可解释性和确认至关重要。

相反，由生成式 AI 和智能体 AI 架构所支撑的高能动性系统在一个显著扩展的决策空间中运作。这些系统目前通过低到中等利害的应用进入半导体制造领域，构成了"认知顾问"层。典型用例包括用于工程支持的领域特定 LLM 助手 [166, 167]、用于文档和知识搜索的智能体 RAG [168, 169, 161]、试验设计（DoE）支持智能体，以及符合设备特定语法的代码和配方生成 [170]。这些系统整合了异构的工厂数据、非结构化文档、MES 历史记录、FDC 信号和传感器时间序列，但主要仍是建议性的，其决策由工程师确认，而不是直

接在设备上执行 [171, 172]。这种定位既能实现快速部署和可衡量的生产力提升，又能限制运营风险。此外，生成式 AI 还能实现合成数据生成（例如晶圆缺陷图像、测试数据）[157, 158, 159, 160] 以及计算光刻流程的加速（例如基于生成对抗网络（GAN）的 ILT 近似）[153, 154, 155, 156]。

> **图 3.6：** 按影响与自主程度对用例进行分类。绿色圆点：分析型 AI；黄色圆点：生成式 AI；蓝色圆点：智能体 AI。

高能动性、高利害的象限代表了通往"会思考的工厂"的长期轨迹。在这里，智能体系统从顾问角色演变为与 APC 和设备控制系统集成的闭环自主控制层。新兴概念包括自主配方优化、自适应控制策略以及跨工艺模块和设备组的多智能体协调 [151, 173, 171]。

在这些区域之间存在一个"信任建立区"，在这里，生成式和智能体 AI 系统开始影响运营决策，但尚未完全自主执行。例子包括工具增强的智能体数据分析、上下文感知的异常调查，以及在 APC 框架下配方整定支持的早期形式 [169, 150]。在这一区域，通过使用护栏、沙箱执行环境和 HITL 确认，逐步提高自主程度。这种分阶段的部署策略符合半导体行业对鉴定、变更控制和工艺稳定性的要求，使 AI 驱动的决策权限能够逐步扩大。

作为一个实际例子，图 3.7 展示了在 InstruNEXT GmbH 开发的软件平台中集成的智能体告警数据分析。该 AI 智能体使用本地 LLM 运行，可以使用统计、相关性、异常和趋势检测等多种工具，并将结果与通过智能体 RAG 从用户手册和元件数据手册等文档中检索到的上下文信息相结合，从而为操作员和工程师提供可执行的建议，而不仅仅是告警代码 [174]。

> **图 3.7：** 结合工具使用和智能体 RAG 的智能体数据分析。由 InstruNEXT GmbH 提供。

最终，这可能会延伸到能够与半导体设备直接交互的、无监督或极少监督的物理智能体。尽管潜在收益（自我优化的工艺、更低的波动性和更高的良率）十分可观，但在这一象限中的部署需要严格的保障措施，包括形式化验证、运行时监测和故障安全机制，以满足大批量制造的可靠性标准。

总之，AI 在半导体制造中的采用沿着能动性–影响谱系逐步扩展：分析型 AI 在既定 MES/APC 框架内的高利害、低能动性应用中占主导地位，而生成式和智能体 AI 则先被引入风险较低的顾问角色，然后再向更高的自主性推进。在信任建立机制和系统集成的支持下，决策空间的这种逐步扩大，确定了通往"会思考的工厂"的路径。

4 AI 在电力电子运行中的应用

本章讨论在电力电子系统产品运行期间使用 AI 方法和工具。与用于设计自动化或离线分析的 AI 不同，运行中的 AI 必须满足时延、确定性、鲁棒性、安全性和可维护性方面的严格约束。首先，我们在 4.1 节中探讨在线运行期间的典型任务以及 AI 方法如何支持这些任务。除了高层次的方法概述和相关文献引用外，我们还提供了精选的应用示例。然后，在 4.2 节中我们讨论工业部署方面的挑战，最后在 4.3 节中简要展望电力电子系统运行中可能出现的、由 AI 驱动的未来趋势。

4.1 产品运行期间的典型任务

4.1.1 控制

AI 方法在电力电子控制中主要用于：(i) 在非线性和约束条件下改善动态性能；(ii) 减少跨产品变体的标定工作量；(iii) 提高对参数漂移的鲁棒性。在产品运行中，这些收益必须在严格的实时约束下实现。因此，任何 AI 组件都必须是轻量级的、推理时间确定的，并且其输出是有界的 [175]。表 4.1 总结了主要的方法类别、它们在控制架构中的典型作用，以及它们目前与电力电子产品运行的相关程度。

表 4.1：面向电力电子产品运行的 AI 辅助控制方法概览

方法类别	在控制中的典型作用	代表性电力电子用例	主要优势	部署成熟度
模型增强控制 [176]	在保留经典控制结构的同时学习特定的残余效应	死区补偿、压降补偿、磁饱和补偿、扰动估计	在保留控制结构的同时提高精度	高
学习加速的预测/约束处理 [177]	为约束控制提供快速代理模型或离线学习的策略	降阶预测、近似模型预测控制、考虑热或效率的降额	降低在线计算量	中–高
AI 辅助整定与调度 [178]	在不同运行区域间调整控制器参数或运行模式	增益调度、自适应参数整定、开关频率调度	降低标定工作量	高
基于 RL 的监督控制 [179]	在基于规则的监督器确认的前提下选择更高层级的动作	设定点调度、模式切换、效率最优运行	长时域优化与自适应	中
端到端学习控制 [180, 181]	直接将测量值映射为控制动作	主要为面向研究的演示	显式建模工作量最小	低

模型增强控制： 一个实用的切入点、也是工业上可行的方法，是保留经典控制结构（电流/电压环、锁相环（PLL）、调制器、保护），仅在建模误差占主导的地方引入学习模块。在这种设置下，学习被用作有针对性的补偿器，而不是完全替代。典型例子有：(a) 数据驱动的扰动观测器（学习集总扰动/不确定性）；(b) 从运行数据中学习得到的考虑损耗/热的降额图；(c) 通过学习得到的非线性函数补偿死区、压降和磁饱和。这些方法保留了人们熟悉的安全包络，因为外环仍然基于物理，而学习模块受到显式约束（例如有限增益、有限带宽、单调性）[182]、[183]。

学习加速的控制与约束处理： 这在电力电子中很有吸引力，因为关键限值（电流限值、直流母线纹波、热极限、开关状态）可以被显式处理。然而，主要障碍是在紧迫的采样时限下完成计算。因此，有两种常见的 AI 模式：(i) 为被控对象或选定状态学习一个降阶预测器（代理模型）以加速预测；(ii) 离线学习控制策略，用快速推理取代在线优化。在这两种情况下，仍应显式地施加约束（投影、限幅、可行集检查），而不是隐式地依赖学习得到的模型 [184]、[185]。

用于整定和调度的 RL： 当 RL 用于监督层决策而不是内部电流环时最为现实，因为监督层以较慢的速率运行，能够容忍额外的检查。例子包括设定点调度、效率最优的开关频率选择以及跨运行区域的自适应增益调度。一种安全的部署模式是：由 RL 提出一个动作，由基于规则的监督器根据约束和稳定裕度对其进行确认，并在存在不确定性或异常情况时由后备逻辑切换回基线控制器。

稳定性、安全性与验证方面： 由于学习组件是数据驱动的，确认必须明确覆盖边缘情况，例如运行极限、快速瞬态、传感器失效和饱和事件 [186]、[187]。图 4.1 展示了一个代表性的应用示例，其中 AI 作为逆变器控制中的监督层，处理测量信号以进行故障检测和诊断。在这一角色中，当在并网系统中检测到异常情况时，AI 模块支持故障穿越以及向孤岛运行过渡等功能，而内部控制环仍然基于物理且具有确定性。这个例子反映了一种对产品运行尤为相关的部署模式，因为它在不将硬实时执行权限移交给学习组件的情况下，提高了态势感知和运行适应性。对于与控制相关的 AI 模块，推荐的工程措施有：

- 有界输出和有界变化率（以防止向控制环注入不连续性）；
- 输入有效性检查（范围、合理性、信号质量标志）；
- 不确定性感知的运行（当输入处于分布外时增大安全裕量）；
- 结构化的回退到经典控制（根据应用选择故障可运行或故障安全）。

总体而言，在控制中最具可部署性的 AI 方法是一种混合方法：基于物理的控制提供稳定性结构，而学习在物理模型不完整之处改进建模和自适应。

> **图 4.1 内容示意：** 光伏阵列 → 光伏逆变器（开关 S1–S6，LCL 滤波器 L_i、L_g、C_f）→ 电网；MPPT 算法与逆变器控制器产生 PWM；测量量（V_{pv}、I_{pv}、V_{dc}、V_{abc}、I_{abc}）进入监测引擎，经时域/频域特征提取后判断"正常"或"故障"（F1、F2、F3）；逆变器运行模式包括：① 正常控制；② 故障穿越（低电压穿越 LVRT 控制）/容错控制；③ 故障检测（FD）后转入孤岛运行；控制变量经 dq/abc 变换后送往逆变器。
>
> **图 4.1：** 并网系统中 AI 辅助的逆变器监督控制的代表性示例。AI 层处理测量信号以实现故障检测、故障穿越支持以及向孤岛运行的过渡，而内部控制环仍然基于物理且具有确定性。

4.1.2 模型辨识（含数字孪生）

物理信息机器学习方法： AI 不断融入电力电子，为先进控制、状态监测和预测性维护铺平了道路。然而，经典的数据驱动机器学习模型在实际电力电子应用中常常面临重大障碍。纯深度学习的黑箱性质本质上缺乏物理可解释性和因果性，难以确保安全性和可靠性。此外，这些纯数据驱动的模型需要大量高质量数据才能学习复杂的非线性行为，而在电力电子中，这样的数据很少能覆盖各种不同的运行边界和变化的任务剖面。为了克服这些局限，物理信息机器学习（PIML）已成为一种有前景的范式 [188]。

通过将基尔霍夫定律和常微分方程（ODE）等基本物理原理无缝嵌入学习过程，PIML 弥合了基于物理的解析模型与数据驱动方法之间的差距。所嵌入的物理有效地对学习空间进行了正则化，减少了对穷尽式数据集的依赖，并大幅提高了数据效率。最重要的是，PIML 增强了模型的鲁棒性，即使面对未见过的运行条件也能确保物理上一致的预测，从而解决了电力电子中数字孪生以及预测与健康管理（PHM）所面临的关键可靠性约束。凸显 PIML 潜力的一个代表性应用是其在参数估计中的实现 [189]，这是构建功率变换器精确数字孪生的核心要求。由于噪声、测量误差以及需要侵入式的硬件干预，在变化的运行条件下准确提取原位元件参数（例如电感、电容和等效串联电阻）传统上颇具挑战。一个基于 PIML 的新颖框架已经被开发出来，并在 DC-DC Buck 变换器上得到了成功验证，如图 4.2a 所示。在这种方法中，深度神经网络与变换器的物理动态模型相耦合。这种物理信息方法表现出了显著的鲁棒性。该案例说明了 PIML 如何为电力电子系统中数据需求少且高度可靠的数字孪生开启新的可能性。

用于非线性参数的查找表或函数： 在讨论电力电子应用时，与开关损耗、热效应以及系统效率相对应的许多系统行为在本质上都具有显著的非线性，无法用某些函数方程来表示。因此，为了在 AI 应用中分析和评估此类非线性模型，通常的做法是使用查找表（LUT）和非线性函数。LUT 基于通过实验观测或仿真研究得到的预先计算数据，提供输入–输出相关性的映射。即使在计算能力有限的情况下，它通常也有助于实现快速的实时评估。在速度和可靠性至关重要的嵌入式控制器和基于 AI 的优化中，LUT 尤其有益。

> **图 4.2：** 与模型辨识相关的示意图。(a) 电力电子系统参数估计中的物理信息机器学习 [189]；(b) 通过查找表和生成式 AI 对电力电子器件进行热映射 [190]。

然而，数据限制可能是 LUT 的制约因素之一，因此电力电子现象也会用非线性函数来表达，从而可以表示为连续的特性。用多项式表示随温度变化的电阻、用指数函数表征二极管特性等，都是表示电力电子动态的非线性函数的典型例子。与查找表相比，非线性函数占用的内存更少，并且能够生成连续性更好的工作点，这使其适用于控制和系统级仿真。

此外，智能技术和机器学习技术往往通过映射非线性数据来进行学习，而高斯过程、神经网络、支持向量回归等智能模型在拟合非线性模式方面表现更好，可作为 LUT 和解析方法的替代方案。而且在实践中，常见的是一种混合方法：LUT 作为训练智能模型的输入，同时也考虑基于物理的函数。这种组合往往能在精度和计算效率之间取得平衡，使 AI 驱动的电力电子更加可靠且面向未来。

ML 方法与热模型的结合（热神经网络（TNN））： 电力电子器件（尤其是宽禁带器件）的热建模一直采用 RC 网络来表示。宽禁带功率模块表现出非线性的温度依赖性以及瞬态行为，可以用传统的 Foster 模型 [191] 或 Cauer 模型 [192] 来表示。然而，这类模型有时难以精确捕捉其动态。因此，人们引入了基于机器学习的模型来提高传统方法的预测能力。许多研究人员在动态功率损耗变化 [193] 和不均匀发热 [194] 方面探索了智能技术。也有一些持续性的工作利用生成对抗网络开发随温度变化的 RC 框架 [190]，如图 4.2b 所示，目的是精确模拟随温度变化的热参数的动态。总之，将机器学习技术与热网络模型相结合，为预测电力电子系统的器件温度提供了一个适应性更强、更准确的框架。

面向电力电子系统的 AI 赋能数字孪生： 数字孪生框架正越来越多地被研究用于电力电子系统的先进监测、优化和可靠性评估。在这一背景下，数字孪生代表物理变换器的一个动态虚拟对应物，它整合了实时测量、基于物理的电热模型和数据驱动的学习算法，以在变化的运行条件下复现系统行为。经典实现依赖电路模型、半导体损耗模型和热 RC 网络来刻画电气变量、开关损耗和结温动态之间的相互作用。然而，在实际系统中，准确辨识模型参数以及刻画运行条件、器件退化和热效应之间复杂的非线性耦合仍然具有挑战性。

AI 的最新进展使得能够在数字孪生架构中集成基于机器学习的代理模型，以显著降低的计算复杂度逼近多维损耗曲面、效率图和电热动态。此类方法已被研究用于半导体结温的实时估计、变换器效率预测以及功率模块的状态监测 [195, 196]。

此外，将基于物理的模型与数据驱动学习相结合的混合建模策略（包括物理信息神经网络），允许在训练过程中施加能量平衡和热动态等物理约束，从而改善模型的泛化能力和鲁棒性 [197]。因此，这些 AI 赋能的数字孪生为下一代电力电子系统的预测性维护、可靠性感知运行和自适应优化提供了一个有前景的框架。

4.1.3 状态估计

任何电力电子系统都可以表示为一个非线性离散时间状态空间模型：

$$x_{k+1} = f(x_k, u_k) + w_k, \qquad y_k = h(x_k, u_k) + v_k, \tag{4.1}$$

其中 $x_k \in \mathbb{R}^n$ 为内部状态，$u_k \in \mathbb{R}^m$ 为已知输入，$y_k \in \mathbb{R}^p$ 为测量输出；w_k 和 v_k 分别刻画模型不确定性和测量噪声。在实践中，传感器只提供 y_k（通常 $p < n$），而 $h(\cdot)$ 可能是非线性的，并且会受到开关纹波和 EMI 的干扰。因此，状态估计是根据输入–输出历史来重建 x_k。电力电子中的典型任务总结在表 4.2 中。

形式上，滤波计算在线估计 $\hat{x}_{k|k} = \mathcal{E}(y_{0:k}, u_{0:k-1})$，即根据截至时刻 k 的测量值和所施加的输入得到当前状态。根据应用的不同，也可以考虑预测（$\hat{x}_{k+\ell|k}$）或平滑（$\hat{x}_{k|N}$，其中 $N > k$）。经典观测器通过基于模型 $f(\cdot)$ 的时间更新以及由新息 $y_k - h(\hat{x}_{k|k-1}, u_k, k)$ 驱动的测量校正来实现 $\mathcal{E}(\cdot)$。ML 辅助的估计器保留这一结构，但学习 f、h 和/或更新律的一部分，以减少建模误差和非平稳的不确定性。

在开环估计中，状态的重建不使用新息反馈，例如 $\hat{x}_k = g(y_{0:k}, u_{0:k})$，其中 $g(\cdot)$ 为一个（辨识得到的）模型。开环估计器计算成本低、部署简单，但它们对模型失配、漂移和非平稳扰动（例如开关纹波、EMI 和老化）仍然敏感。相比之下，闭环估计器通过反馈新息来驱动收敛，例如采用以下可能时变的观测器结构：

$$\hat{x}_{k+1|k} = f(\hat{x}_{k|k}, u_k, k), \qquad \hat{x}_{k+1|k+1} = \hat{x}_{k+1|k} + L_{k+1}\big(y_{k+1} - h(\hat{x}_{k+1|k}, u_{k+1}, k+1)\big), \tag{4.2}$$

其中经典的 Luenberger 型设计和（扩展/无迹）卡尔曼滤波器是突出的实例 [198, 199, 200]。对于电力电子运行，这一区分自然延伸到状态与模型的联合估计：未知或缓慢变化的参数 θ（例如 L、C、等效串联电阻（ESR），或损耗与热参数）通过扩充 x（即 $x_k^a = [x_k^\top, \theta_k^\top]^\top$）与状态一起进行联合估计，或者使用对偶/自适应方案 [201, 202, 203]。这种参数跟踪可以作为预测性维护（参见 4.1.5 小节）和故障检测（参见 4.1.4 小节）的健康指标。由于估计质量最终取决于 $f(\cdot)$、$h(\cdot)$ 及其参数的保真度，数据驱动的模型辨识和数字孪生在 4.1.2 小节中单独讨论。

表 4.2：电力电子系统（含电驱动）中典型的状态估计用例及使用非 ML 方法的代表性文献

用例类别（含典型状态）	典型在线用途	示例
无传感器电驱动（θ_e、ω、磁链/反电动势（EMF）相关状态）	省去机械传感器，或在传感器故障时提供备份	[204, 205, 206]
变换器电气状态（电感电流、电容电压）	减少传感器数量（虚拟传感）并补偿负载影响	[207, 208, 200, 209]
电网接口状态（电网电压幅值/相角/频率）	在畸变/不平衡电网中实现同步与控制	[210, 211, 212, 213]
热状态（例如结温或电机温度）	无需侵入式传感器即可实现热降额和寿命感知运行	[214, 215]

当有精确模型可用时，经典观测器能提供结构性、可解释性和收敛性保证，但实际的电力电子系统会表现出依赖于工作点的寄生参数、依赖于模式的行为、传感器缺陷以及老化引起的漂移，这些在整个寿命期内仍然难以建模。因此，数据驱动的方法和混合 ML 方法减少了对高精度专家模型和手工整定的依赖，提高了对失配和非平稳不确定性的鲁棒性，并能基于有限的测量实现虚拟传感；表 4.3 总结了代表性的例子。在安全关键的应用中，工程师通常将 ML 部署为基于物理的估计器的助手，例如用于学习增益、噪声统计量或残余动态，而不是端到端地取代估计器 [216, 217]。

图 4.3 展示了一个近期的基于 ML 的状态估计示例。在电力电子变换器的磁芯中，瞬态 B–H 轨迹构成了一个具有隐藏内部状态的非线性动态系统：尽管 $H(t)$ 和 $B(t)$ 是可测量的，但底层的磁畴构型、钉扎效应和

转动过程是不可测量的 [247, 248, 249]。因此，相同的瞬时 B 可能根据激励历史对应不同的 H 值，所以精确的模型需要内部记忆变量。

微磁学和磁畴理论等微观白箱方法可以解释这种瞬态铁磁行为，但将其迁移到宏观的磁芯样品轨迹上仍然是一个计算密集的多尺度问题，难以扩展到器件级仿真 [249, 250]。因此，循环神经网络或混合神经磁滞代理模型提供了一种有吸引力的替代方案，因为它们直接从测量的磁滞回线中学习潜在的记忆动态，同时仍支持快速推理，可在磁性元件和变换器设计流程中反复使用 [244, 243, 242]。

表 4.3：电力电子系统中 ML 辅助和基于 ML 的状态估计用例类别及代表性文献

用例类别/被估计量	ML 在估计器回路中的典型作用	参考文献
无传感器驱动：转子角度/转速	纯黑箱或 ML 辅助估计，例如由 ANN 整定观测器参数	[218, 205, 219, 206, 220, 221, 222]
无传感器驱动：转子磁链	对感应电机中不可测量的转子磁链进行黑箱或 ML 辅助估计	[223, 224]
电流和电压的虚拟传感	将物理信息先验与 ML 模型相结合的开环状态估计	[225, 189, 226, 227]
瞬态过程中的电流/电压去噪	对受 EMI 干扰的瞬态信号进行递归 ANN 去噪，通常比经典滤波器延迟更小	[228, 229, 230]
并网变换器：电压/谐波监测	根据本地变换器测量推断不可测量的电压/谐波指标（例如与总谐波畸变（THD）相关的量）	[231, 232, 233, 234]
变换器和驱动中的温度估计	在集总参数热网络中嵌入 ANN 子模型，以刻画寄生效应、非线性参数和损耗效应	[235, 236, 237, 238]
感性元件中的磁状态估计（瞬态 B–H 曲线模型）	用于磁性元件瞬态 B–H 轨迹的开环动态 ML 模型	[239, 240, 241, 242, 243, 244]
ML 辅助滤波（通用但适用于电力电子）：增益/噪声学习、潜空间滤波	保留卡尔曼滤波器/观测器框架，但学习 L_k、Q/R、残余动态或潜在编码器	[216, 217, 245, 246]

图 4.3： 针对磁性元件内瞬态 B–H 轨迹的基于 ML 的开环状态估计（来源：[240]）。(a) 基于 LSTM 的估计器方法：编码器（LSTM 单元，输入 $B_{mem}(t)$、$H_{mem}(t)$ 等记忆序列，输出隐状态 h_t 和单元状态 c_t）→ 前馈神经网络（FNN）阶段 → 投影器，由当前状态和 $B(t_{k+1})$ 预测下一状态 $H(t_{k+1})$；(b) 时域中的示例测试结果（频率 200 kHz，100 个周期，与实测数据对比）。

4.1.4 故障检测

故障检测描述的是对离散异常事件的识别。这使其区别于预测性维护（4.1.5 小节），后者关注的是渐进的退化现象。尽管时间尺度不同，两者都依赖于相似的信号和特征处理流程。因此，实际的系统架构通常实现共享的信号预处理，其中高优先级的故障检测以短时延运行，而退化跟踪则在后台任务中执行。

在电力电子系统中，故障检测旨在早期发现异常状况，定位最可能的故障源（例如器件、传感器、栅极驱动、无源元件、互连、负载或电网），并触发适当的响应，例如告警、降额、重构或停机 [251]。尽管这一目

标在概念上看似简单，但产品运行施加了严格的约束。与实验室诊断不同，传感能力有限，计算资源有界，并且必须在不影响保护速度的前提下尽量减少误跳闸。

为了有效地选择检测策略，必须对故障类型有系统的认识，如图 4.4 所示。功率变换器面临着各种各样的电气、热、环境和与控制相关的故障，这在文献中已有大量报道 [252, 253]。与变换器运行相关的主要故障类别总结在表 4.4 中。

> **图 4.4 内容示意：**（并网系统：直流源/电池 → DC/DC → 直流母线电容 C_{dc} → DC/AC → 滤波器 → 变压器 → 电网/负载，PWM 与控制接口）
>
> - **功率器件/模块的退化、失效模式与故障：** 键合线疲劳/脱落；焊料疲劳/开裂；芯片贴装分层；基板开裂；金属化腐蚀；器件开路/短路故障。
> - **功率变换器的退化、失效模式与故障：** 热/电过应力；栅极驱动器退化/失效；直流母线电容老化/失效；开关开路故障；开关短路故障；控制/传感器故障。
> - **滤波器的退化、失效模式与故障：** 热过应力；介质老化/开裂；电解液蒸发/泄漏；焊点退化；电容减小/ESR 增大；无源元件开路/短路故障。
>
> **图 4.4：** 并网系统的故障分布（受 [252] 启发）。

表 4.4：功率电子变换器的故障分类 [254, 255, 256, 257]

故障类别	说明	根本因素	主要后果
半导体器件故障	功率开关失效	短路、键合线脱落、过热、栅极失效	直通、变换器停机、器件损毁
电容器故障	直流母线或滤波电容失效	ESR 增大、电容损失、绝缘失效	直流母线纹波、过电压、寿命缩短
磁性元件故障	电感和变压器中的问题	绕组短路、绝缘击穿、磁芯饱和	过电流、畸变、过度发热
栅极驱动与控制故障	开关指令中的故障	脉冲丢失、控制器失效	不受控的开关、直通、保护跳闸
母线故障	互连布线中的异常	过电压、接地问题、绝缘击穿	系统停机、半导体应力
输入连接故障	来自电网或电源的故障	过/欠电压、缺相、浪涌	元件应力、变换器工作异常
输出连接故障	负载侧的故障	短路、过载、接地故障	过电流、变换器停机
条件性故障	环境和运行应力	极端温度、振动、湿度	长期退化、间歇性失效
系统级故障	组合或级联故障	保护失效、EMI、通信中断	多元件损坏、失稳

这些故障类别直接影响检测方法的选择。一般来说，突发的电气故障（例如短路、栅极脉冲丢失）需要嵌入在保护层中的快速检测机制，而参数型或环境型故障通常需要基于趋势或基于模型的监测策略。在以下各小节中，我们讨论各种方法及相关挑战。

基于模型和基于信号的方法

这些方法依赖于残差或诊断特征，它们在健康运行时保持很小，而在出现故障时发生偏离 [258]。在实践中，可以观察到三种反复出现的模式：

- **利用观测器生成残差**（例如 Luenberger 型或卡尔曼型观测器），或在实测电流/电压与期望值之间建立等价关系（parity relations）。
- **从电信号中提取特征**，包括序分量、谐波指标、选定频带内的频谱能量、小波系数、开关瞬态特征（例如 di/dt、dv/dt 代理量）以及直流母线纹波特性。
- **在冗余或物理相关的信号之间进行一致性检查**（例如相电流与直流母线电流的平衡、指令开关状态与实际开关状态的对比）。

这些方法的主要优点是可解释性好、数据需求低，并且更容易在既定的工业开发和安全保证流程中进行验证与确认。然而，它们的性能取决于模型精度和运行条件，这可能限制其在参数漂移或负载剖面剧烈变化情况下的鲁棒性。

基于 AI 的故障检测

当故障特征很细微、由多种因素造成，或被噪声和运行变化所掩盖时，基于 AI 的方法尤其有益 [259, 260]。在工业实现中，以下三类最为相关：

- **监督分类**，在有标注的故障数据可用时使用（例如来自加速老化试验、硬件在环（HiL）装置或现场返修分析）。对于嵌入式目标，通常优先选择浅层神经网络、基于树的模型和支持向量机（SVM）等轻量级分类器。
- **无监督或单类异常检测**，用于罕见的或以前未见过的故障。自编码器、单类 SVM、密度估计模型或特征空间中的聚类等方法使用健康数据进行训练，并检测与所学正常行为的偏差。
- **用于早期故障的时序模型**。基于序列的模型，例如 RNN（如 LSTM、GRU）和时间卷积网络，在滑动窗口上运行，以识别趋势和变化点，而不是孤立的偏差。

无论选择哪种算法，跨工作点的特征鲁棒性和实时可计算性仍然是主要的设计约束。

混合概念、实际挑战与工业相关性

鉴于解析方法和数据驱动方法具有互补的优势，混合架构经常被采用。一种常见的结构是将快速且可解释的基于物理的残差与基于 AI 的决策层相结合，后者可调整阈值、补偿对工作点的依赖性或融合多个弱指标。相关思想在文献中已有体现，例如一些变换器故障诊断方案将基于信号或变换的特征提取与多层感知机或随机森林等轻量级分类器相结合，用于实时的逆变器故障检测与定位 [261, 262]。嵌入单调性、能量一致性或热因果性等物理信息约束，可以进一步提高鲁棒性和泛化能力。

从工业角度看，部署挑战包括类别不平衡（故障很罕见）、实验室数据与现场数据之间的领域偏移、传感器限制（带宽、量化、漂移）以及适当响应策略的定义。因此，产品运行中的评估指标应侧重于在具有代表性的工作循环下的检测时间和误跳闸率，而不是仅仅依赖离线精度。

4.1.5 预测性维护

电力电子的 PdM 利用运行期间采集的状态数据来估计关键元件的健康状态和 RUL。与故障检测不同，PdM 针对的是缓慢的退化动态，其中参数漂移随着由负载、热循环、湿度、振动和开关应力所定义的任务

剖面而演变 [263, 264, 265]。

电力电子中的主要老化机理： 损耗型（wear-out）机理主要由热机械应力和电过应力驱动。这些机理包括互连退化（键合线脱落、焊料疲劳）、封装和热界面材料（TIM）老化（热阻增大）、栅氧化层退化，以及无源元件老化（例如直流母线电容 ESR 增大和电容损失）。由于退化强烈依赖于任务剖面，PdM 必须基于循环的应力累积来运行，而不是基于静态的寿命假设。

健康指标与退化可观测量： 在实际系统中，退化是通过随时间演变的可测量代理量间接推断的。这些代理量包括电气特征（例如通态电压漂移、开关瞬态变化）、热响应（例如在恒定损耗下结温升高）以及运行统计量（例如降额频率、应力循环直方图）。关键的挑战是将退化引起的变化与正常的工作点依赖性解耦。

可测量指标、隐藏的退化状态与决策层之间的这种关系如图 4.5 所示，突出了可靠 PdM 所需的多层推断过程。

> **图 4.5 内容示意：** 面向基于 AI 故障检测的数据生成：对功率变换器、其元件及系统不平衡进行故障/失效模式分析（影响）；功率电子变换器（$V_{in} \rightarrow V_{out}$）；直接测量与虚拟传感器测量的融合；在宽运行条件下构建数据集并处理有用数据；AI/ML 工具选择 → 监测模型开发 → 监测引擎。
>
> **图 4.5：** 电力电子系统的预测性维护架构。

预测性维护方法： PdM 方法大致可分为基于物理的方法和数据驱动的方法，两者都依赖于应力、退化和可观测特征之间一致的映射关系 [19]。

(1) 基于物理的寿命建模： 基于物理的 PdM 利用电热模型和经验寿命定律，从应力循环中计算累积损伤。这种方法提供了可解释性以及与失效机理的直接联系，但需要准确估计结温和应力循环等内部状态 [263, 269]。

表 4.5：电力电子中退化机理与可观测指标之间的映射 [266, 267, 268]

元件/失效模式	主要应力驱动因素	可观测指标	测量领域
键合线疲劳	热循环（ΔT_j）	通态电压 $V_{CE(on)}$ / $R_{DS(on)}$ 增大	电气
焊料/芯片贴装退化	功率循环、热机械应力	热阻抗 Z_{th} 增大	电热
直流母线电容老化	纹波电流、温度	ESR 增大、电容下降、直流母线纹波	电气
磁性元件绝缘退化	热应力 + 电应力	磁芯损耗、谐波畸变	电磁

(2) 基于 AI 的健康状态与 RUL 估计： 数据驱动的方法学习从指标到健康状态或 RUL 的映射。这些方法包括回归模型、时间序列模型以及能够在变化的运行条件下捕捉退化趋势的概率估计器 [265]。应当明确考虑 RUL 的不确定性，可以将统计和随机模型 [270] 与 AI 方法结合使用以进行概率预测。由于失效数据有限，通常需要采用迁移学习和半监督学习等混合训练策略 [19]。

数字孪生与混合 PdM 概念： 混合方法将基于物理的模型与 AI 相结合，以平衡可解释性和适应性。在这种结构中，物理模型估计应力和内部状态，而 AI 补偿建模误差或估计不可测量的参数。这在减少对大型标注数据集依赖的同时，提高了跨变换器变体的泛化能力。

表 4.6：电力电子系统 PdM 建模范式的比较

方法	模型结构	关键局限	工业适用性
基于物理	电热模型 + 寿命模型	需要准确的应力/状态估计	高（可解释、可认证）
数据驱动（AI）	特征 → RUL 映射	数据稀缺、外推能力有限	中（需要确认）
混合（数字孪生）	物理 + ML 修正	集成复杂度增加	高（兼顾精度与鲁棒性）

如表 4.5 和表 4.6 所总结的，有效的 PdM 需要在退化物理、可观测特征和模型结构之间保持一致的对应关系。

工业相关性与开放挑战： 在工业部署中，PdM 必须对传感器漂移、数据缺失和不断变化的运行条件保持鲁棒。一个关键的实际挑战不是模型精度，而是不确定性下的阈值标定和决策鲁棒性。因此，PdM 系统需要持续的确认、自适应阈值设定，以及与监督控制的集成，以确保在产品整个寿命期内安全可靠地运行。

4.2 工业部署挑战

4.2.1 网络安全与数据隐私

产品运行中的 AI 赋能功能引入了额外的数据流（日志记录、联网、更新），并产生了训练好的模型、特征处理流程和状态数据等高价值资产，从而扩大了网络攻击面。因此，网络安全必须与性能和可靠性要求协同设计，而不是作为附加项来对待 [271]。对于电力电子系统，主要的安全目标仍然是可用性、完整性和机密性，但由于实时约束和有限的嵌入式资源，实现这些目标变得更加复杂。

AI 的集成引入了紧密耦合的信息物理漏洞。对传感器信号（例如电流、电压、温度）的篡改可能会通过观测器和基于学习的估计器传播，导致错误的控制或保护动作。同样，如果认证和加密不足，通信接口（现场总线、以太网、无线、云）会使系统暴露于重放攻击和注入攻击之下 [272]。除数据通道之外，模型参数和训练数据集等 AI 特有资产也带来了新的风险，包括模型篡改和数据投毒，它们可能会系统性地降低检测精度或使决策边界产生偏差。

为了应对这些挑战，必须在 AI 组件的整个生命周期内实施安全措施。在实践中，AI 工件（模型、特征定义、标定数据）应与安全关键固件同等对待，确保其完整性、真实性和可追溯性 [273]。这包括安全启动机制、签名的模型部署、经过认证的通信通道，以及对输入和输出的运行时确认。特别是，对 AI 输出进行界限和合理性检查，对于防止错误决策传播到控制环中至关重要。此外，更新机制必须包含回滚保护和严格的版本控制，以避免意外的降级攻击。

表 4.7：电力电子系统中由 AI 引入的漏洞传播路径

注入点	受影响的内部变量	在 AI/控制回路中的传播机制	缓解策略
模拟传感器通道（模数转换器（ADC）输入）	状态估计值（i_d、i_q、T_j）	偏置/噪声改变观测器残差 → 状态重建错误 → 控制律性能下降	信号合理性检查、冗余、观测器一致性监测
数字通信总线（CAN/以太网）	监督层参考值、设定点	重放/注入修改参考轨迹 → 与被控对象动态失配 → 失稳或违反约束	经过认证的通信、序列计数器、异常检测

注入点	受影响的内部变量	在 AI/控制回路中的传播机制	缓解策略
ML 推理层（权重/激活）	学习得到的映射（例如损耗/热模型）	权重扰动或对抗性输入 → 非线性映射失真 → 错误的补偿或预测	模型签名、运行时界限、对抗鲁棒性测试
训练/更新管道	模型参数和决策边界	被投毒的数据集 → 特征分布偏差 → 检测精度长期下降	数据集确认、漂移检测、受控的再训练程序
特征提取阶段	派生特征（谐波、有效值、梯度）	特征失真 → AI 模型中的误分类或异常被掩盖	鲁棒的特征设计、归一化检查、特征空间冗余

表 4.7 总结了这些威胁向量及其在传感、推理和执行各层之间的传播路径，图 4.6 对此进行了概念性说明。如图所示，在数据层引入的扰动可能会通过 AI 模型逐级传递，并最终影响物理系统的行为，这凸显了跨层保护机制的必要性。

> **图 4.6 内容示意：**
>
> - **信息层（Cyber Layer）：** 1. 通信流量；2. 通信延迟、数据包丢失、链路故障；3. 网络安全。
> - **信息物理层（Cyber-Physical Layer）：** 1. 保护配合失调；2. 信息层不可用；3. 监测单元失效；5. 基于延迟的失稳。
> - **物理层（Physical Layer）：** 1. 元件级可靠性；2. 过载；3. 多时间尺度稳定性评估；4. 间歇性可再生能源；5. 系统级事故。
> - 传感/监测与控制在信息层与物理层（发电机 G、电动机 M、各类变换器）之间交互。
>
> **图 4.6：** AI 赋能电力电子系统中信息物理攻击传播的概念示意图，展示了传感、AI 推理和控制各层之间的相互作用 [274]。

除安全之外，由于越来越多地将运行数据用于分析和预测性维护，还必须考虑数据隐私。此类数据可能会泄露有关使用模式或系统运行的敏感信息。因此，应在数据管道中嵌入隐私保护的设计原则，包括本地特征提取（边缘处理）、最少的数据传输以及受控的数据保留。当需要进行机群级学习时，联邦学习等方法可以减少原始数据的交换；但它们仍然需要稳健的认证以及针对恶意更新的防护。

总体而言，网络安全和数据隐私直接影响系统的可靠性和安全性。在 AI 赋能的电力电子产品中，被攻破的数据或模型不仅可能导致错误的监测结果，还可能导致不安全的控制动作，因此安全且注重隐私的设计是部署的一项基本要求。

4.2.2 功能安全/生产部署

将 ML 模型集成到嵌入式和安全关键环境中，可能会对 ISO 26262 等传统认证和安全标准构成重大挑战。大多数标准主要是为确定性的、基于规则的软件设计的，这与 ML 模型的数据驱动本质有根本区别。

ML 模型必须满足的功能安全要求，在很大程度上取决于模型的部署环境和模型的任务。例如，一个辅助性的虚拟温度传感器与安全毫无关系。在其失效或出现异常行为的最坏情况下，主系统也很少受到影响。另一方面，一个集成在电动汽车逆变器电流控制器中的模型则是高度安全关键的，因为它可能影响车辆的加速。

从监管角度看，欧盟（EU）《人工智能法案》等新兴框架将大多数汽车 AI 应用——尤其是那些影响执行或安全相关决策的应用——归类为高风险系统。这意味着在透明度、可追溯性、数据集治理和部署后监测方面

存在额外要求，这些要求超出了传统的功能安全标准，必须被纳入开发生命周期之中。

为了应对 ML 模型的非确定性，可解释性和不确定性量化成为安全保证的关键使能因素。在实践中，嵌入式电力电子应用通常采用紧凑的模型（例如浅层神经网络或基于回归的方法），这些模型允许部分可解释性和有界行为。这有助于验证，而不确定性度量（例如置信界或残差监测）则能在运行时检测出不可靠的预测。

在当前的工业实践中，安全关键的部署通常避免使用在线自学习模型，因为持续变化的模型参数违反了认证假设。取而代之的是，人们更倾向于使用固定的（离线训练的）模型并进行受控更新，以确保在整个产品生命周期中行为的可追溯性和可重复性。

近期的工业方法强调 AI 系统的统一安全生命周期，将 ISO 26262、ISO 21448（预期功能安全（SOTIF））以及 ISO/PAS 8800 等新兴标准结合起来。这些框架将安全概念扩展到包括鲁棒性、韧性和运行监测，以应对源于数据不足和分布偏移（而非硬件故障）的失效模式。

在这些机制的基础上，安全保证要求将 ML 组件嵌入到具有显式监测和后备策略的分层安全架构中。在此类系统中，ML 的输出受到持续监督，一旦偏离预期行为，就会触发确定性的安全机制。

表 4.8：电力电子系统中 ML 组件的失效传播与安全机制

失效来源	受影响的变量	系统级影响	缓解机制
训练数据偏差	估计状态（例如 T_j、磁链）	系统性误差 → 错误的降额或保护	数据集确认、安全裕量
分布外（OOD）输入/分布偏移	ML 模型输出	无界预测 → 失稳或违反约束	OOD 检测、运行时监测
量化/实现误差	模型推理输出	偏离训练时的行为 → 控制精度下降	工具链确认、误差界定
传感器异常	输入特征	特征空间失真 → 误分类或估计误差	输入合理性检查、冗余

图 4.7 展示了 ML 组件、安全监测器和后备机制之间的相互作用。该架构突出显示了安全约束如何在多个层级上得到执行，确保由 ML 引起的偏差不会不受控制地传播到物理系统中。

总体而言，基于 ML 的系统的功能安全正在从纯粹的确定性验证，转向有界模型行为、运行时监测和系统级安全执行的组合。这与新兴的安全理念相一致，即在 AI 赋能的嵌入式系统中将鲁棒性和韧性视为首要的设计目标。

> **图 4.7：** 面向 ML 赋能电力电子系统的分层安全架构，展示了 ML 推理、运行时监测和后备控制机制之间的相互作用。

4.2.3 嵌入式硬件要求

对于部署到嵌入式硬件上的 ML 模型来说，优化至关重要，因为成本压力使计算资源受到严格限制。一个典型的目标环境是运行实时操作系统的微控制器，该系统以固定的周期性间隔调度任务。因此，模型推理可用的时延预算直接取决于由哪个任务来承载该模型：嵌入在功率逆变器快速控制环中的神经网络，比在同一设备上较慢的监督任务中运行的神经网络，面临着严格得多的时间和内存限制。

最主要的优化是模型压缩，可以在训练期间进行，也可以作为后处理步骤。其目的是在对模型精度影响可接受的前提下，减少内存占用和推理时间 [275]。表 4.9 总结了常用的技术：

表 4.9：面向边缘部署的模型压缩技术

方法	说明	参考文献
架构搜索	在神经架构搜索（NAS）期间，更具体地说是采用一种多目标策略，在模型性能与硬件约束（例如参数数量或乘累加（MAC）运算次数）之间进行权衡，得到一个帕累托前沿，并从中选择架构。	[276]
剪枝	移除对输出贡献可忽略的权重或神经元。结构化剪枝（整个滤波器或层）可在标准硬件上直接带来加速；非结构化剪枝则需要稀疏张量支持才能实现收益。	[277]
量化	ML 框架默认采用 32 位浮点（float32）运算。将精度降低到 16 位浮点（float16）、8 位整数（int8）甚至 4 位整数，可按比例缩小内存和存储占用，并加速定点硬件上的运算。常见的有两种变体：训练后量化（PTQ）对已训练好的模型进行转换，而量化感知训练（QAT）则在训练过程中模拟量化噪声。	[278]
知识蒸馏	训练一个紧凑的学生网络去复现一个更大、更精确的教师模型的输出分布，而不仅仅是从硬标签中学习。教师的软预测携带更丰富的梯度信息，使学生能够达到在其参数预算下原本无法达到的精度水平。	[279]
激活函数	嵌入式环境通常不提供与桌面工作站相同的指令集。特别是 tanh 或 sigmoid 等常见激活函数可能只能以近似形式提供。在训练期间就需要考虑目标平台。	[280]

部署在硬件中的 AI 模型必须能够抵御内存错误、电源中断以及振动、温度变化和电磁干扰等恶劣环境。这些条件既影响硬件选择（需具备内置纠错、定时器等），也影响模型设计，可能需要额外的确认或冗余以确保可靠运行。

近年来，微控制器（MCU）行业的主要公司开始在其芯片中提供加速器内核。各公司使用各自的品牌名称，如神经处理单元（NPU）（德州仪器）、Neural-ART（意法半导体）或 NNLite（英飞凌），但它们都具有一个针对神经网络（NN）推理中占主导地位的矩阵–向量运算进行优化的 MAC 阵列 [281]。这些加速器只支持定点运算（INT8/INT4）。因此，量化既是一种压缩技术，也是硬件加速部署的硬性前提。作为硬件创新的补充，MCU 制造商还通过专门的工具链来支持开发。例如，意法半导体的 X-Cube-AI 可将开放神经网络交换（ONNX）、TensorFlow Lite 和 Keras 模型转换为面向 STM32 目标的优化 C 代码 [282]。

4.2.4 数据要求与系统激励

基于 ML 的模型、观测器和控制器正迅速进入电力电子系统，但与模型架构或训练算法相比，数据质量仍然较少受到关注 [235, 283, 284]。这一差距至关重要，因为电力电子的动态跨越了时间尺度上的若干个数量级，从开关瞬态到缓慢的热行为；因此，传感器带宽、同步采样、抗混叠、分辨率和噪声水平都必须与所关注的现象相匹配，因为学习无法恢复在测量链中丢失的信息 [285, 286]。相应地，好的数据必须具有信息量、代表性、良好的分布以及物理上的合理性：它们必须覆盖允许的运行域、相关的瞬态过程、边界区域、扰动和器件差异，同时尽量减少训练与部署之间的失配，因为黑箱 ML 方法在外推和分布偏移下性能会迅速下降 [4, 287]。

> **图 4.8：** 通过系统激励获取信息丰富的数据，是任何 ML 方法的显而易见的前提（受 [283] 启发）。

这使得试验设计和系统激励成为一个一等问题——参见图 4.8。除了经典的持续激励和最优试验设计概念之外，非线性且受安全约束的电力电子系统还需要面向覆盖率或由不确定性引导的激励策略，在电流、电压、温度、EMI、成本和试验时间的硬性限制下，有意识地探测信息丰富的区域 [288, 289, 290, 291, 292, 293]。

系统激励选择一个输入策略，驱动系统通过安全但信息丰富的运行区域，以生成能够使后续模型质量最大化的数据。在一个简化的长时域设定中，忽略显式的历史状态，可写为：

$$\pi^\star \in \arg\max_{\pi} \ \mathcal{L}(\mathcal{X},\mathcal{U}) \quad \text{s.t.} \quad x_{k+1} = f\big(x_k, \pi(x_k)\big),\ x_k \in \mathbb{X},\ \pi(x_k) \in \mathbb{U},\ k = 0,\dots,T-1, \tag{4.3}$$

其中状态轨迹 $\mathcal{X} = (x_0,\dots,x_T)$，输入轨迹 $\mathcal{U} = (u_0,\dots,u_{T-1})$（由策略 π 表示），且 $T \in \mathbb{N} \gg 1$。上式 (4.3) 将系统激励表述为一个最优控制问题：$\mathcal{L}$ 量化一次轨迹推演（rollout）的信息量，而 $\mathbb{X}$ 和 $\mathbb{U}$ 保证运行安全。对于白箱和灰箱模型，信息量通常由费希尔信息矩阵导出 [284, 289]；对于黑箱模型，它通常通过塑造目标状态和输入分布的空间填充度量来定义 [290, 293, 292]。求解 (4.3) 仍然是一个"先有鸡还是先有蛋"的问题，因为最优激励需要一个预测模型，而这个模型恰恰需要先通过激励来辨识。因此，在实践中采用迭代的方式：采集一批数据，更新模型，重新设计激励，如此循环往复。由于安全关键的边缘情况难以测量、内部状态只能被部分观测，以及公差、老化和平台差异扩大了相关的运行域，数据需求会进一步增加。迁移学习可以减少跨产品代际的工作量，但它无法弥补源数据从根本上缺乏信息或不匹配的问题 [294]。在需要真值的场合，尤其是故障或异常检测，数据标注和打标签成为额外的瓶颈，因为它们需要领域专业知识，而且罕见事件往往代表性稀少。

4.3 未来研究展望

在未来十年中，面向电力电子的 AI 学术研究将超越传统的确定性建模。这一演进将由三个紧密耦合的大趋势驱动，旨在弥合算法能力与工业系统严苛可靠性要求之间的差距：

- **可信的、不确定性感知的 AI：** 该领域正在从确定性的黑箱预测转向经过校准的、面向决策的不确定性量化。在关键运行中，AI 系统不仅会预测 RUL 或监测状态指标，还会提供严格的置信区间。在分布偏移（例如新的运行工况或元件老化）下，这些不确定性界限可以驱动自适应安全裕量、不确定性感知的降额以及稳健的后备策略。由此，AI 的输出从点估计演变为可在运行中采取行动、保护系统完整性的信息 [295, 296, 297, 298]。

- **面向可泛化表示与可迁移性的基础模型：** 跨时间序列、空间图结构和多物理场领域的预训练表示，正在成为应对电力电子中标注失效数据稀缺问题的关键杠杆。通过跨拓扑的迁移学习，在标准变换器架构（例如基本 DC-DC 拓扑）上训练的基础模型，可以通过少样本微调适配到更复杂的系统。这一转变可以打破不同运行工况之间的数据孤岛，并在标注失效数据仍然稀缺的情况下，提高数字孪生、诊断、预测和数据高效适配的可扩展性 [299, 300, 24, 301, 302, 303]。
- **用于监督层编排和人在回路流程的智能体 AI：** 尽管硬实时控制（例如纳秒级的栅极开关）仍将由形式化验证、超低时延约束和基于物理的安全护栏所主导，但监督层的 AI 将变得越来越自主。具备语言能力、能够使用工具的智能体将编排复杂的工程和任务管理流程 [304, 305, 306, 307, 29]。例如，在海上风电变流器的机群级预测性维护中，一个智能体框架可以检测出早期的直流母线电容退化，通过天气 API 识别低风速的维护窗口，查询企业资源计划系统中的备件可用性，并生成派工计划供技术人员审查和批准。

综上所述，这些趋势表明，运行中的电力电子 AI 正在从针对特定任务的 AI，向可信的、可迁移的、部分自主的混合智能过渡，预计最强的学术影响将出现在基于物理的建模、概率决策支持和有监督的人类洞察三者的交汇处。

4.4 结论

在所有考虑的用例中，AI 在电力电子中的主要工业机遇并不在于取代已有的工程模型，而在于在建模工作量、参数漂移或多维非线性限制了传统方法的地方对其进行增强。因此，最有前景的路径是混合 AI：有界的、可监测的、与物理一致的方法，它们可以嵌入到现有的产品架构中，同时满足在实时能力、安全性、网络安全和全生命周期鲁棒性方面的要求。

参考文献

（参考文献保留原文）

[1] T. Ding, D. Xiang, T. Sun, Y. Qi, Z. Zhao, and Y. Qi, “Artificial intelligence applications in power electronics,” in Proceedings of the 7th International Conference on Energy Systems and Electrical Power (ICESEP), Wuhan, China, 2025, pp. 342–346.

[2] P. Martinez, “Artificial intelligence in power electronics: Challenges and trends,” Presentation at the PE International 2025, Brussels, Belgium, Apr. 2025.

[3] S. Russell and P. Norvig, Artificial Intelligence: A Modern Approach, Global Edition. Pearson, 2021.

[4] C. M. Bishop, Pattern Recognition and Machine Learning. New York, NY, USA: Springer, 2006.

[5] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. The MIT Press, 2016.

[6] R. S. Sutton and A. G. Barto, Reinforcement Learning: An Introduction, 2nd ed. Bradford Books, 2018.

[7] T. Guillod, P. Papamanolis, and J. W. Kolar, “Artificial neural network (ANN) based fast and accurate inductor modeling and design,” IEEE Open Journal of Power Electronics, vol. 1, pp. 284–299, Jul. 2020.

[8] J. Li, Y. Xu, K. Nie, B. Cao, S. Zuo, and J. Zhu, “PEDNet: A lightweight detection network of power equipment in infrared image based on YOLOv4-Tiny,” IEEE Transactions on Instrumentation and Measurement, vol. 72, pp. 1–12, 2023.

[9] Z. Zhu, C. Gong, H. Qin, R. Huo, Y. Xuan, and Y. Bian, “Artificial intelligence applications in LLC resonant converters from design to maintenance: An overview,” in Proceedings of the 8th International Conference on Energy, Electrical and Power Engineering (CEEPE), Wuxi, China, 2025, pp. 150–155.

[10] S. Reese, B. Sauter, and D. Maksimovic´, “Data-driven component-level design of switching power converters using predictive modeling,” IEEE Transactions on Power Electronics, vol. 40, no. 8, pp. 11 126–11 142, Aug. 2025.

[11] B. Bohara and H. S. Krishnamoorthy, “Computer vision-based framework for power converter identification and analysis,” in Proceedings of the IEEE International Conference on Power Electronics, Drives and Energy Systems (PEDES), Jaipur, India, 2022.

[12] S. Wolfram, “What is ChatGPT doing . . . and why does it work?” Stephen Wolfram Writings, writings.stephenwolfram.com/2023/02/what-is-chatgpt-doing-and-why-does-it-work, 2023.

[13] Brown, T. B., Mann, Benjamin, Ryder, Nick, Subbiah, Melanie, Kaplan, Jared, Dhariwal, Prafulla, Neelakantan, Arvind, Shyam, Pranav, Sastry, Girish, Askell, Amanda, Sandholm, Charles, Herbert-Vanderbilt, Ariel, Krueger, Gretchen, Henighan, Tom, Child, Rewon, Ramesh, Aditya, Ziegler, D. M., Wu, Jeffrey, Winter, Clemens, Hesse, Christopher, Chen, Mark, Sigler, Benjamin, Litwin, Mateusz, Gray, Scott, Chess, Benjamin, Clark, Jack, Berner, Christopher, McCandlish, Sam, Radford, Alec, Sutskever, Ilya, Amodei, and Dario, “Language models are few-shot learners,” arXiv preprint arXiv:2005.14165, 2020. [Online]. Available: https://arxiv.org/abs/2005.14165

[14] R. Bommasani et al., “On the opportunities and risks of foundation models,” Stanford Institute for Human-Centered AI, Tech. Rep., 2021.

[15] V. Raval, M. Zeid, P. Enjeti, and G. Pitel, “Circuit AI for bill of materials, switching loss optimization, capacitor RMS estimation, and more,” IEEE Power Electronics Magazine, vol. 12, no. 1, pp. 64–74, Mar. 2025. [Online]. Available: https://ieeexplore.ieee.org/document/10906712

[16] P. Enjeti, “Examples of generative AI and machine learning applications in power electronics,” Tutorial, 42nd Annual IEEE International Communication Energy Conference (INTELEC), Houston, Texas, USA, Oct. 2025.

[17] P. Mederitsch, J. W. Kolar, and U. Drofenik, “Exploring reinforcement learning algorithms for current control of single-phase AC/DC full-bridge converters,” in Proceedings of the 14th International Conference on Renewable Energy Research and Applications (ICRERA), Vienna, Austria, Oct. 2025.

[18] ———, “AI-based approach for exploring power electronics employing reinforcement learning,” in Proceedings of the 51st Annual Conference of the IEEE Industrial Electronics Society (IECON), Madrid, Spain, Oct. 2025.

[19] S. Zhao, F. Blaabjerg, and H. Wang, “An overview of artificial intelligence applications for power electronics,” IEEE Transactions on Power Electronics, vol. 36, no. 4, pp. 4633–4658, 2021.

[20] S. Subedi, Y. Gui, and Y. Xu, “Applications of data-driven dynamic modeling of power converters in power systems: An overview,” IEEE Transactions on Industry Applications, 2025.

[21] K. A. Ibrahim, P. C.-K. Luk, Z. Luo, S. Y. Ng, and L. Harrison, “Revolutionizing power electronics design through large language models: Applications and future directions,” Computers and Electrical Engineering, 2025.

[22] Y. Zhang, Y. Xu, and F. Blaabjerg, “Surrogate models for power electronic systems applying machine learning techniques,” Control of Power Electronic Converters and Systems: Volume 4, 2024.

[23] J. Ye, W. Xuan, Q. Guo, Y. Liu, B. Wang, X. Zhang, and H. H. C. Iu, “An overview of reinforcement learning for power electronic converters: Topology derivation, parameter design, and control implementation,” Renewable and Sustainable Energy Reviews, 2025.

[24] S. Fan, H. Lu, S. Zhang, N. Cao, X. Zhang, and J. Li, “Graph-transformer-based surrogate model for accelerated converter circuit topology design,” in Proc. 61st ACM/IEEE Design Automation Conference (DAC), 2024.

[25] Hackl, H., Riener, C. M., Hussain, and M, “Surrogate-based optimization of coupled inductor and common mode choke for e-vehicle fast charging application,” Elektrotechnik und Informationstechnik, vol. 143, pp. 20–32, 2026. [Online]. Available: https://doi.org/10.1007/s00502-025-01400-7

[26] M. Raissi, P. Perdikaris, and G. E. Karniadakis, “Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations,” Journal of Computational Physics, 2018.

[27] Z. Li, “Fourier neural operator for parametric partial differential equations,” in International Conference on Learning Representations, 2021.

[28] F. Lin, X. Li, W. Lei, J. J. Rodriguez-Andina, J. M. Guerrero, C. Wen, X. Zhang, and H. M, “Pe-gpt: A new paradigm for power electronics design,” IEEE Transactions on Industrial Electronics, 2024.

[29] J. Liu, F. Lin, X. Li, S. Zhao, and K. H. Lim, “Physics-informed autonomous llm agents for explainable power electronics modulation design,” in Proceedings of the AAAI Conference on Artificial Intelligence, vol. 40, no. 47, 2026, pp. 40 063–40 072.

[30] M. Novak, Y. Li, S. Zhao, H. Wang, and F. Blaabjerg, “Adaptive control design for power electronics converters using kolmogorov-arnold networks,” in Proc. IEEE Energy Conversion Congress and Exposition (ECCE), 2025.

[31] F. L. da Silva, R. Glatt, W. Su, V.-H. Bui, F. Chang, M. Wang, Y. L. Murphey, C. Huang, L. Xue, and R. Zeng, “Autotg: Reinforcement learning-based symbolic optimization for ai-assisted power converter design,” IEEE Journal of Emerging and Selected Topics in Industrial Electronics, 2023.

[32] S. Fan, N. Cao, S. Zhang, J. Li, X. Guo, and X. Zhang, “From specification to topology: Automatic power converter design via reinforcement learning,” in Proc. 2021 IEEE/ACM International Conference On Computer Aided Design (ICCAD), 2021.

[33] P. Chen, J. Zhao, K. Liu, J. Zhou, K. Dong, and Y. Li, “A review on the applications of reinforcement learning control for power electronic converters,” IEEE Transactions on Industry Applications, 2024.

[34] T. Most and J. Will, “Efficient sensitivity analysis for virtual prototyping,” in European Congress on Computational Methods in Applied Sciences and Engineering (ECCOMAS 2012), Vienna, Austria, Sep. 2012, presented September 10–14, 2012. [Online]. Available: https://library.dynardo.de/fileadmin/Material_Dynardo/bibliothek/Optimierung_Sensitivitaet/MOST_2012_ECCOMAS_EfficientSensitivityAnalysisForVirtualPrototyping.pdf

[35] M. Zimmermann, N. Conzelmann, and M. Adam, “Challenges and results of six-step operation in automotive traction drives,” Cariad SE, München, 2025.

[36] H. E. Khatib, D. Gaona, D. Gerling, and M. Saur, “Deadbeat flux vector control with continuous transition from linear to overmodulation including six-step operation considering the voltage and current limits by applying one single control law,” in 2021 23rd European Conference on Power Electronics and Applications (EPE’21 ECCE Europe), 2021.

[37] M. Hepp, M. Saur, W. Wondrak, and M. M. Bakran, “Optimized pulse patterns for salient permanent magnet synchronous machines considering nonlinear magnetic effects,” in PCIM Europe 2023, 2023.

[38] A. K. Brandl, S. Race, I. Kovacevic-Badstuebner, B. Kakarla, M. Nagel, and U. Grossner, “An advanced multi-aspect performance analysis of planar-gate 1.2 kV SiC power MOSFETs,” in Proceedings of the International Exhibition and Conference for Power Electronics, Intelligent Motion, Renewable Energy and Energy Management (PCIM Europe), Nuremberg, Germany, 2024, pp. 1608–1615.

[39] W. Kirchgässner, N. Förster, T. Piepenbrock, O. Schweins, and O. Wallscheid, “Hardcore: H-field and power loss estimation for arbitrary waveforms with residual, dilated convolutional neural networks in ferrite cores,” IEEE Transactions on Power Electronics, vol. 40, no. 2, pp. 3326–3335, 2025.

[40] S. Hassan, P. Rajaguru, S. Stoyanov, C. Bailey, and T. Tilford, “Coupled thermal-mechanical analysis of power electronic modules with finite element method and parametric model order reduction,” Power Electron. Devices Compon., 2024.

[41] D. Loukrezis and H. D. Gersem, “Power module heat sink design optimization with ensembles of data-driven polynomial chaos surrogate models,” e-Prime — Adv. Electr. Eng., Electron. Energy, 2022.

[42] A. Mahajan, S. Chaturvedi, S. Das, W. Su, and V.-H. Bui, “Optimal parameter design for power electronic converters using a probabilistic learning-based stochastic surrogate model,” Next Energy, 2025.

[43] X. Zhou, Y. Liu, M. Ali, and M. H, “A multilevel-multiphysics modeling and simulation approach for multichip electronics,” Appl. Therm. Eng., 2025.

[44] J. K. Briese, H. Schefer, L. Radomsky, R. Keilmann, and R. Mallwitz, “Enhancing power-dense and reliability-oriented heat sink structures through additive manufacturing for power electronics in aviation applications,” in Proc. IEEE ITherm, 2025.

[45] N. Tashakor, B. Esser, B. Arndt, P. Olbrich, J. Friebe, and A. Avakian, “AI-based design and optimization for automotive high-voltage filters focusing on novel cost-effective filter structures,” in International Symposium on Electromagnetic Compatibility – EMC Europe, 2025, pp. 250–255.

[46] Z. Ou, Y. Yin, F. Gao, and L. Zhu, “A novel multi-objective optimization framework for the thermal management system of high-power density switching power supply,” Appl. Therm. Eng, 2025.

[47] R. Rasmann, V. Golev, U. Schümann, and J. Schnack, “Automated design and optimization of planar transformers for high-frequency applications,” roc. IEEE Des. Methodol. Conf. (DMC), 2023.

[48] L. Ravuri and S. Lukic, “A comprehensive approach towards multi-objective emi filter design optimization in high-frequency sic-based motor drives,” in Proc. IEEE Appl. Power Electron. Conf. Expo. (APEC), 2022.

[49] R. Rasmann, Y. Shen, X. Dong, U. Schümann, and R. Mallwitz, “Optimization of semiconductor bare die positions within multi-chip power modules,” in Proc. PCIM Europe, 2025.

[50] M. Sanjabiasasi, H. A. Mantooth, and Y. Peng, “Powersynth 2: Automated power electronics physical design synthesis with custom and heterogeneous components,” IEEE Open J. Power Electron., 2025.

[51] B. Esser, B. Arndt, A. Avakian, N. Tashakor, and J. Friebe, “AI-based surrogate model for EMI filter optimization for electric vehicle applications,” in International Exhibition and Conference for Power Electronics, Intelligent Motion, Renewable Energy and Energy Management (PCIM), 2025, pp. 1876–1885.

[52] S. Goswami, A. Bora, Y. Yu, and G. E. Karniadakis, “Physics-informed deep neural operator networks,” in Machine Learning in Modeling and Simulation, 2023.

[53] J. D. Toscano, V. Oommen, A. J. Varghese, Z. Zou, N. A. Daryakenari, C. Wu, and G. E. Karniadakis, “From pinns to pikans: Recent advances in physics-informed machine learning,” Machine Learning: Computational Science and Engineering, 2025.

[54] P. Brendel, V. Medvedev, and A. Rosskopf, “Convolutional physics-informed neural networks for fast prediction of core losses in axisymmetric transformers,” IEEE Transactions on Magnetics, 2024.

[55] P. Brendel, C. Straub, A. Rosskopf, V. Lorentz, and F. Dietrich, “Physics-informed operator learning for parameter estimation in lithium-ion-battery models enhanced by global experimental design and local identifiability analysis,” SSRN preprint 6156315, 2026.

[56] V. Medvedev, A. Rosskopf, and A. Erdmann, “Generative inverse design of metamaterials enhanced by physics-informed neural network,” in in Proc. Nineteenth International Congress on Artificial Materials for Novel Wave Phenomena (Metamaterials), 2025.

[57] H. Wang, M. Liserre, and F. Blaabjerg, “Toward reliable power electronics: Challenges, design tools, and opportunities,” IEEE Industrial Electronics Magazine, 2013.

[58] F. Blaabjerg, H. Wang, I. Vernica, B. Liu, and P. Davari, “Reliability of power electronic systems for ev/hev applications,” in Proceedings of the IEEE, 2020.

[59] ISO/IEC 25059:2023, “Software engineering — systems and software quality requirements and evaluation (square) — quality model for ai systems,” p. 15, Jun. 2023. [Online]. Available: https://www.iso.org/standard/80655.html

[60] ISO/IEC 23894:2023, “Information technology — artificial intelligence — guidance on risk management,” p. 26, Feb. 2023. [Online]. Available: https://www.iso.org/standard/77304.html

[61] IEC 61508-1:2010, “Functional safety of electrical/electronic/programmable electronic safety-related systems — part 1: General requirements,” p. 127, Apr. 2010. [Online]. Available: https://webstore.iec.ch/en/publication/5515

[62] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” arXiv preprint arXiv:1706.03762, 2017. [Online]. Available: https://arxiv.org/abs/1706.03762

[63] Chowdhery, Aakanksha, Narang, Sharan, Devlin, Jacob, Bosma, Maarten, Mishra, Gaurav, Roberts, Adam, Barham, Paul, Chung, H. Won, Sutton, Charles, Sebastian, Sebastian et al., “Palm: Scaling language modeling with pathways,” arXiv preprint arXiv:2204.02311, 2022. [Online]. Available: https://arxiv.org/abs/2204.02311

[64] G. Team, “Gemini: A family of highly capable multimodal models,” arXiv preprint arXiv:2312.11805, 2023. [Online]. Available: https://arxiv.org/abs/2312.11805

[65] H. Huang and J. Zhao, “Domain--adaptive llms for chip design,” Hot Chips 2024 tutorial, 2024. [Online]. Available: https://hc2024.hotchips.org/assets/program/tutorials/5-HC24.ucsd.HanxianHuang.v02.pdf

[66] K. Sun, B. Su, B. Liu, J. Ying, H. Chen, and R. Ou, “Review of research progress on artificial intelligence-driven power electronics design and control methods,” Journal of Electrical Engineering, vol. 20, no. 5, pp. 1–10, 2025. [Online]. Available: https://www.jgcm.ac.cn/dqgcxb/en/article/doi/10.11985/2025.05.001

[67] Yao, Shunyu, Zhao, Jeffrey, Yu, Dian, Du, Nan, Shafran, Izhak, Narasimhan, Karthik, Yuan, and Ruoyuan, “React: Synergizing reasoning and acting in language models,” arXiv preprint arXiv:2210.03629, 2022. [Online]. Available: https://arxiv.org/abs/2210.03629

[68] Shinn, Noah, Labash, Beck, Gopinath, and Ashwin, “Reflexion: Language agents with verbal reinforcement learning,” arXiv preprint arXiv:2303.11366, 2023. [Online]. Available: https://arxiv.org/abs/2303.11366

[69] J. Liu, F. Lin, X. Li, K. H. Lim, and S. Zhao, “Physics-informed autonomous LLM agents for explainable power electronics modulation design,” arXiv preprint arXiv:2411.14214, 2024. [Online]. Available: https://arxiv.org/abs/2411.14214

[70] J. Liu, C. Cui, P. Lin, P. Hui, A. M. Y. M. Ghias, and C. Zhang, “A large language model based multi-agent framework for goal oriented controller design in power electronics,” in 2025 8th International Conference on Energy, 2025. [Online]. Available: https://ieeexplore.ieee.org/document/11034293

[71] F. Amjad, T. Korõtko, and A. Rosin, “Review of LLMs applications in electrical power and energy systems,” IEEE Access, vol. 13, pp. 150 951–150 969, 2025. [Online]. Available: https://ieeexplore.ieee.org/abstract/document/11129042

[72] M. Chen, “Power for AI and AI for power: The infinite entanglement between artificial intelligence and power electronics systems,” IEEE Power Electronics Magazine, 2024. [Online]. Available: https://ieeexplore.ieee.org/document/10906734

[73] F. Blaabjerg, Y. Yang, K. A. Kim, and J. Rodriguez, “Power electronics technology for large-scale renewable energy generation,” Proceedings of the IEEE, vol. 111, no. 4, pp. 335–355, 2023.

[74] J. L. Afonso, L. A. L. Cardoso, D. Pedrosa, T. J. C. Sousa, L. Machado, M. Tanta, and V. Monteiro, “A review on power electronics technologies for electric mobility,” Energies, vol. 13, no. 23, 2020. [Online]. Available: https://www.mdpi.com/1996-1073/13/23/6343

[75] F. Hou, W. Wang, L. Cao, J. Li, M. Su, T. Lin, G. Zhang, and B. Ferreira, “Review of packaging schemes for power module,” IEEE Journal of Emerging and Selected Topics in Power Electronics, vol. 8, no. 1, pp. 223–238, 2020.

[76] H. Lee, V. Smet, and R. Tummala, “A review of sic power module packaging technologies: Challenges, advances, and emerging issues,” IEEE Journal of Emerging and Selected Topics in Power Electronics, vol. 8, no. 1, pp. 239–255, 2020.

[77] H. Wang, J. Ma, Y. Yang, M. Gong, and Q. Wang, “A review of system-in-package technologies: Application and reliability of advanced packaging,” Micromachines, vol. 14, no. 6, 2023. [Online]. Available: https://www.mdpi.com/2072-666X/14/6/1149

[78] A. C. Huang, S. H. Meng, and T. J. Huang, “A survey on machine and deep learning in semiconductor industry: methods, opportunities, and challenges,” Cluster Computing, vol. 26, pp. 3437–3472, 2023.

[79] V. Maitra, Y. Su, and J. Shi, “Virtual metrology in semiconductor manufacturing: Current status and future prospects,” Expert Systems with Applications, vol. 249, p. 123559, 2024.

[80] C.-F. Chien, C.-W. Liu, and S.-C. Chuang, “Analysing semiconductor manufacturing big data for root cause detection of excursion for yield enhancement,” International Journal of Production Research, vol. 55, no. 17, pp. 5095–5107, 2017.

[81] J. Senoner, T. Netland, and S. Feuerriegel, “Using explainable artificial intelligence to improve process quality: Evidence from semiconductor manufacturing,” Manage. Sci., vol. 68, no. 8, p. 5704–5723, Aug. 2022. [Online]. Available: https://doi.org/10.1287/mnsc.2021.4190

[82] H.-W. Xu, Q.-H. Zhang, Y.-N. Sun, Q.-L. Chen, W. Qin, Y.-L. Lv, and J. Zhang, “A fast ramp-up framework for wafer yield improvement in semiconductor manufacturing systems,” Journal of Manufacturing Systems, vol. 76, pp. 222–233, 2024. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0278612524001407

[83] S. Phongmoo, C. Suedumrong, C. Kuensaen, R. Sinthavalai, and K. Leksakul, “Predictive maintenance in semiconductor manufacturing: Comparative analysis of machine learning models for downtime reduction,” Computers & Industrial Engineering, vol. 205, p. 111211, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0360835225003572

[84] T. Chen, V. Sampath, M. C. May, S. Shan, O. J. Jorg, J. J. A. Martín, F. Stamer, G. Fantoni, G. Tosello, and M. Calaon, “Machine Learning in Manufacturing towards Industry 4.0: From ‘For

Now’ to ‘Four-Know’,” Applied Sciences, vol. 13, no. 3, p. 1903, 2023.

[85] T. Zonta and others, “Predictive maintenance in the Industry 4.0: A systematic literature review,” Computers & Industrial Engineering, vol. 150, p. 106889, 2020.

[86] J. C. Gallagher and others, “Using machine learning with optical profilometry for GaN wafer screening,” Scientific Reports, vol. 13, p. 3352, 2023.

[87] J. Yu, Z. Shen, and S. Wang, “Wafer map defect recognition based on deep transfer learning-based densely connected convolutional network and deep forest,” Engineering Applications of Artificial Intelligence, vol. 105, p. 104387, 2021.

[88] S. Misra, D. Kim, J. Kim, W. Shin, and C. Kim, “A voting-based ensemble feature network for semiconductor wafer defect classification,” Scientific Reports, vol. 12, no. 1, p. 16254, 2022.

[89] J. Koo and S. Hwang, “A Unified Defect Pattern Analysis of Wafer Maps Using Density-Based Clustering,” IEEE Access, vol. 9, pp. 78 873–78 882, 2021.

[90] C.-Y. Hsu, “Clustering Ensemble for Identifying Defective Wafer Bin Map in Semiconductor Manufacturing,” Mathematical Problems in Engineering, vol. 2015, p. 707358, 2015.

[91] K. Suthar, D. Shah, J. Wang, and Q. P. He, “Next-generation virtual metrology for semiconductor manufacturing: A feature-based framework,” Computers & Chemical Engineering, vol. 127, pp. 140–149, 2019. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0098135419300833

[92] T. Song, Z. Huang, and A. Yan, “Machine learning classification algorithm for VLSI test cost reduction,” Integration, vol. 87, pp. 40–48, 2022. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0167926022000724

[93] T. Honda, T. Haarhuis, J. D. David, H. Hannink, G. Prewitt, and V. Rajan, “ML-assisted IC Test Binning with Real-Time Prediction at the Edge,” in 2023 7th IEEE Electron Devices Technology & Manufacturing Conference (EDTM), 2023, pp. 1–4.

[94] E. Suhir, “Predictive modeling sheds useful light on burn-in testing (BIT): Brief review and recent extension,” Microelectronics Reliability, vol. 126, p. 114240, 2021.

[95] I. Ahmed, F. Hosseinpour, P. Baraldi, E. Zio, and H. Lewitschnig, “An Artificial Intelligence-Based Framework for Burn-in Reduction in the Semiconductor Manufacturing Industry,” in Recent Advances in Microelectronics Reliability: Contributions from the European ECSEL JU project iRel40, W. D. van Driel, K. Pressel, and M. Soyturk, Eds. Cham: Springer International Publishing, 2024, pp. 117–133. [Online]. Available: https://doi.org/10.1007/978-3-031-59361-1_5

[96] I. Ahmed, P. Baraldi, E. Zio, and H. Lewitschnig, “A data-driven modelling framework for predicting the quality of semiconductor devices to support burn-in decisions,” Computers &

Industrial Engineering, vol. 204, p. 111115, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S036083522500261X

[97] E. Suhir, “To Burn-In, or Not to Burn-In: That’s the Question,” Aerospace, vol. 6, no. 3, p. 29, 2019.

[98] H. V. Pham, S. N. Demidenko, and G. M. Merola, “Eliminating re-burn-in in semiconductor manufacturing through statistical analysis of production test data,” in 2017 IEEE International Instrumentation and Measurement Technology Conference (I2MTC), 2017, pp. 1–6.

[99] C. Shen, W. Zhan, M. Li, Z. Sun, J. Tang, Z. Wu, C. Xu, B. Xu, C. Zhao, and Z. Wang, “Development of in situ characterization techniques in molecular beam epitaxy,” Journal of Semiconductors, vol. 45, no. 3, p. 031301, 2024.

[100] C. Shen, K. Yang, W. Zhan, B. Xu, Z. Li, S. Pan, S. Chen, Z. Wang, and C. Zhao, “Advances in intelligent epitaxy of semiconductor materials,” Progress in Quantum Electronics, vol. 103, p. 100587, 2025. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0079672725000357

[101] T.-S. Chou, S. Bin Anooz, R. Grüneberg, N. Dropka, W. Miller, T. T. Tran, Vi, J. Rehm, M. Albrecht, and A. Popp, “Machine learning supported analysis of MOVPE grown β-Ga_2O_3 thin films on sapphire,” Journal of Crystal Growth, vol. 592, p. 126737, Aug. 2022.

[102] Z. Ma and T. Pan, “Distributional reinforcement learning for run-to-run control in semiconductor manufacturing processes,” Neural Computing and Applications, vol. 35, no. 26, pp. 19 337–19 350, 2023.

[103] W.-T. Yang, J. Blue, A. Roussy, J. Pinaton, and M. S. Reis, “A physics-informed Run-to-Run control framework for semiconductor manufacturing,” Expert Systems with Applications, vol. 155, p. 113424, 2020.

[104] S. Takemura, S. Sakai, and E. Murayama, “Beam shape control system by machine learning on the NISSIN BeyEX medium current ion implanter,” MRS Advances, vol. 7, no. 36, pp. 1463–1467, 2022.

[105] J. Moyne, E. del Castillo, and A. M. Hurwitz, Run-to-Run Control in Semiconductor Manufacturing. CRC Press, 2001.

[106] C.-Y. Chang, Y.-W. Feng, T. S. Rawat, S.-W. Chen, and A. S. Lin, “Optimization of laser annealing parameters based on Bayesian reinforcement learning,” Journal of Intelligent Manufacturing, vol. 36, no. 4, pp. 2479–2492, 2025.

[107] C. S. Kim, H. J. Lee, H. R. Roh, T. Park, Y. Lee, J. Han, S. Kwon, C. Lee, J. Sun, K. Yoon, and J. M. Lee, “Improvement of Plasma Etching Endpoint Detection With Data-Driven Wavelength Selection and Gaussian Mixture Model,” IEEE Transactions on Semiconductor Manufacturing, vol. 36, no. 3, pp. 389–397, 2023.

[108] R. Yang and R. Chen, “Real-Time Fault Classification for Plasma Processes,” Sensors, vol. 11, no. 7, pp. 7037–7054, 2011. [Online]. Available: https://www.mdpi.com/1424-8220/11/7/7037

[109] C. Liu, L. Zhang, J. Li, J. Zheng, and C. Wu, “Two-Stage Transfer Learning for Fault Prognosis of Ion Mill Etching Process,” IEEE Transactions on Semiconductor Manufacturing, vol. 34, no. 2, pp. 185–193, 2021.

[110] C.-Y. Hsu, Y.-W. Lu, and J.-H. Yan, “Temporal convolution-based long-short term memory network with attention mechanism for remaining useful life prediction,” IEEE Transactions on Semiconductor Manufacturing, vol. 35, no. 2, pp. 220–228, 2022.

[111] Z. Yuan and R. Wang, “Multi-scale and multi-branch transformer network for remaining useful life prediction in ion mill etching process,” IEEE Transactions on Semiconductor Manufacturing, vol. 37, no. 1, pp. 67–75, 2024.

[112] S. Gu, D. Ying, M. Jin, Y. J. Lu, J. Wang, J. Lavaei, and C. Spanos, “Few-shot test-time optimization without retraining for semiconductor recipe generation and beyond,” 2025. [Online]. Available: https://arxiv.org/abs/2505.16060

[113] J. Yu and S. J. Qin, “Variance component analysis based fault diagnosis of multi-layer overlay lithography processes,” IIE Transactions, vol. 41, no. 9, pp. 764–775, 2009, publisher: Taylor & Francis _eprint: https://doi.org/10.1080/07408170902789076. [Online]. Available: https://doi.org/10.1080/07408170902789076

[114] L. v. Dijk, K. M. Adal, M. Chastan, A. Lam, and R. v. Haren, “Excursion detection and root-cause analysis using virtual overlay metrology,” in Metrology, Inspection, and Process Control for Semiconductor Manufacturing XXXV, O. Adan and J. C. Robinson, Eds., vol. 11611. SPIE, 2021, p. 1161132, backup Publisher: International Society for Optics and Photonics. [Online]. Available: https://doi.org/10.1117/12.2581561

[115] S. Zhou and others, “A Novel End-to-End Deep Learning Framework for Chip Packaging Defect Detection,” Sensors, vol. 24, no. 17, p. 5837, 2024.

[116] D. Kong, X. Hu, Z. Gong, and D. Zhang, “Segmentation of void defects in X-ray images of chip solder joints based on PCB-DeepLabV3 algorithm,” Scientific Reports, vol. 14, no. 1, p. 11925, 2024. [Online]. Available: https://doi.org/10.1038/s41598-024-61643-w

[117] O. Alavi, W. De Ceuninck, and M. Daenen, “Impact of Solder Voids on IGBT Thermal Behavior: A Multi-Methodological Approach,” Electronics, vol. 13, no. 11, 2024. [Online]. Available: https://www.mdpi.com/2079-9292/13/11/2188

[118] Y.-J. Park, G. Ahn, and S. Hur, “Optimization of pick-and-place in die attach process using a genetic algorithm,” Applied Soft Computing, vol. 68, pp. 856–865, 2018.

[119] G. Ahn, M. Park, Y.-J. Park, and S. Hur, “Interactive Q-Learning Approach for Pick-and-Place Optimization of the Die Attach Process in the Semiconductor Industry,” Mathematical

Problems in Engineering, vol. 2019, p. 4602052, 2019.

[120] T. Mamee, Z. Lou, K. Hata, M. Takamiya, T. Sakurai, S.-I. Nishizawa, and W. Saito, “Estimating of IGBT Bond Wire Lift-Off Trend Using Convolutional Neural Network (CNN),” IEEE Access, vol. 12, pp. 96 936–96 945, 2024.

[121] C. Rosman, K. Schelthoff, and A. Akcay, “Interpretable chip-quality classification with signal and feature selection in wire bonding,” Flexible Services and Manufacturing Journal, 2025. [Online]. Available: https://doi.org/10.1007/s10696-025-09621-w

[122] F. Wang and others, “Heavy Aluminum Wire Wedge Bonding Strength Prediction Using a Transducer Driven Current Signal and an Artificial Neural Network,” IEEE Transactions on Semiconductor Manufacturing, vol. 27, no. 2, pp. 230–238, 2014.

[123] C.-S. Wang and J.-E. Chiu, “Shear Force Classification Before Wire Bonding Based on Probe Mark 2-D Images Using Machine Learning Methods,” IEEE Transactions on Semiconductor Manufacturing, vol. 35, no. 2, pp. 210–219, 2022.

[124] C. Buchner, C. T. Seidler, M. F. Huber, H. Eigenbrod, H.-G. von Ribbeck, and F. Schlicht, “Machine learning-based shear force quality prediction of ultrasonic wire bonds: utilizing process data and machine data without additional sensors,” The International Journal of Advanced Manufacturing Technology, vol. 133, no. 11, pp. 5657–5672, 2024. [Online]. Available: https://doi.org/10.1007/s00170-024-14055-z

[125] C. Buchner, B. Riedle, J. Krauß, C. T. Seidler, M. F. Huber, H. Eigenbrod, H.-G. von Ribbeck, and F. Schlicht, “Machine learning-driven multi-objective parameter optimization for sustainable, efficient, and high-quality ultrasonic wire bonding,” Journal of Intelligent Manufacturing, 2025. [Online]. Available: https://doi.org/10.1007/s10845-025-02615-3

[126] B. R. Chang, H.-F. Tsai, and C.-C. Chen, “Analysis of Molding Defection in IC Packaging and Testing Process,” Electronics, vol. 13, no. 22, p. 4356, 2024.

[127] M.-K. Ho, Y.-H. Chen, M.-Y. Tsai, H.-C. Hu, and W.-C. Lo, “Development of GUI-Driven AI Deep Learning Platform for Predicting Warpage Behavior of Fan-Out Wafer-Level Packaging,” Micromachines, vol. 16, no. 3, p. 342, 2025.

[128] H.-K. Wang, Y.-C. Lin, T.-Y. Chen, C.-C. Wang, and C.-P. Hung, “Optimizing warpage in semiconductor packaging using GA-NN and conditional GAN with explainable AI,” Computers & Industrial Engineering, p. 110992, 2025.

[129] G. A. Susto, A. Beghi, and C. De Luca, “A Predictive Maintenance System for Epitaxy Processes Based on Filtering and Prediction Techniques,” IEEE Transactions on Semiconductor Manufacturing, vol. 25, no. 4, pp. 638–649, 2012.

[130] S.-X. Kao and C.-F. Chien, “Deep Learning Based Positioning Error Fault Diagnosis of Wire Bonding Equipment and an Empirical Study for IC Packaging,” IEEE Transactions on

Semiconductor Manufacturing, vol. 36, pp. 619–628, 2023.

[131] M. Fernandes, J. M. Corchado, and G. Marreiros, “Machine learning techniques applied to mechanical fault diagnosis and fault prognosis in the context of real industrial manufacturing use-cases: a systematic literature review,” Applied Intelligence, vol. 52, pp. 14 246–14 280, 2022.

[132] F. Zhu, X. Jia, W. Li, M. Xie, L. Li, and J. Lee, “Cross-Chamber Data Transferability Evaluation for Fault Detection and Classification in Semiconductor Manufacturing,” IEEE Transactions on Semiconductor Manufacturing, vol. 36, no. 1, pp. 68–77, 2023.

[133] S. J. Bae, J. Y. Hwang, and W. Kuo, “Yield prediction via spatial modeling of clustered defect counts across a wafer map,” IIE Transactions, vol. 39, no. 12, pp. 1073–1083, 2007.

[134] I.-B. Park, J. Huh, J. Kim, and J. Park, “Deep reinforcement learning based scheduling within production plan in semiconductor fabrication,” Expert Systems with Applications, vol. 191, p. 116253, 2022.

[135] P. Tassel, B. Kovács, M. Gebser, K. Schekotihin, P. Stöckermann, and G. Seidel, “Semiconductor Fab Scheduling with Self-Supervised and Reinforcement Learning,” in Proceedings of the 2023 Winter Simulation Conference (WSC). IEEE, 2023, pp. 1924–1935.

[136] J. Schmitt, J. Bönig, T. Borggräfe, G. Beitinger, and J. Deuse, “Predictive model-based quality inspection using machine learning and edge cloud computing,” Advanced Engineering Informatics, vol. 45, p. 101101, 2020. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1474034620300707

[137] Y. Li, J. Du, and W. Jiang, “Reinforcement learning for process control with application in semiconductor manufacturing,” IISE Transactions, vol. 56, no. 6, pp. 585–599, 2024.

[138] T. Nakazawa and D. V. Kulkarni, “Wafer Map Defect Pattern Classification and Image Retrieval Using Convolutional Neural Network,” IEEE Transactions on Semiconductor Manufacturing, vol. 31, no. 2, pp. 309–314, 2018.

[139] M. Saqlain, Q. Abbas, and J. Y. Lee, “A Deep Convolutional Neural Network for Wafer Defect Identification on an Imbalanced Dataset in Semiconductor Manufacturing Processes,” IEEE Transactions on Semiconductor Manufacturing, vol. 33, no. 3, pp. 436–444, 2020.

[140] T. Lin, H. Chen, P. C. Lai, Y. Wang, and A. Chiu, “Optimizing semiconductor defect classification with generative AI and vision foundation models,” Dec. 2025, published: NVIDIA Technical Blog. [Online]. Available: https://developer.nvidia.com/blog/optimizing-semiconductor-defect-classification-with-generative-ai-and-vision-foundation-models/

[141] C.-F. Chien, W.-T. Hung, C.-W. Pan, and T. H. V. Nguyen, “Decision-based virtual metrology for advanced process control to empower smart production and an empirical study for semiconductor manufacturing,” Computers & Industrial Engineering, vol. 169, p. 108245, 2022.

[142] P. Kang, H.-j. Lee, S. Cho, D. Kim, J. Park, C.-K. Park, and S. Doh, “A virtual metrology system for semiconductor manufacturing,” Expert Systems with Applications, vol. 36, no. 10, pp. 12 554–12 561, 2009.

[143] P. Kang, D. Kim, H.-j. Lee, S. Doh, and S. Cho, “Virtual metrology for run-to-run control in semiconductor manufacturing,” Expert Systems with Applications, vol. 38, no. 3, pp. 2508–2522, 2011.

[144] P.-Y. Chen, S. Y. Wu, J. H. Lin, F. Ko, H. Lo, J. Wang, C. H. Yu, and M.-s. Liang, “Virtual metrology: A solution for wafer to wafer advanced process control,” in ISSM 2005, IEEE International Symposium on Semiconductor Manufacturing, 2005, pp. 155–157.

[145] T. Vishnu, P. Gupta, P. Malhotra, L. Vig, and G. Shroff, “Recurrent neural networks for online remaining useful life estimation in ion mill etching system,” in Annual Conference of the PHM Society, vol. 10, 2018.

[146] Siemens AG, “The True Cost of Downtime 2024,” Senseye Predictive Maintenance, Siemens, Tech. Rep., 2024. [Online]. Available: https://assets.new.siemens.com/siemens/assets/api/uuid:1b43afb5-2d07-47f7-9eb7-893fe7d0bc59/TCOD-2024_original.pdf

[147] S. Al-Baddai, M. Juhrisch, J. Papadoudis, A. Renner, B. Lippmann, C. Luca, F. Haas, and W. Schober, Automated Anomaly Detection Through Assembly and Packaging Process. River Publishers, 2022, pp. 161–176.

[148] K. J. Braakman, D. M. Knotter, A. Akcay, and I. Adan, “Leveraging machine signals for device-level quality detection and automatic root cause analysis in semiconductor wire bonding,” in 2024 Winter Simulation Conference (WSC), 2024, pp. 1886–1897.

[149] M. A. Farahani, M. I. Khan, and T. Wuest, “Hybrid agentic AI and multi-agent systems in smart manufacturing,” arXiv preprint, 2025, arXiv:2511.18258; preprint submitted to NAMRC 2026.

[150] J. Lee and H. Su, “Agentic AI for smart manufacturing,” Manufacturing Letters, vol. 46, pp. 92–96, 2025.

[151] Y. Ren, Y. Liu, T. Ji, and X. Xu, “AI agents and agentic AI – navigating a plethora of concepts for future manufacturing,” Journal of Manufacturing Systems, vol. 83, 2025.

[152] A. Fernández-Miguel, M. P. Fernández Del Hoyo, F. E. García-Muiña, and D. Settembre-Blundo, “Agentic AI in smart manufacturing: Enabling human-centric predictive maintenance ecosystems,” Applied Sciences, vol. 15, no. 21, p. 11414, 2025.

[153] Y. Yang, K. Liu, Y. Gao, C. Wang, and L. Cao, “Advancements and challenges in inverse lithography technology: a review of artificial intelligence-based approaches,” Light: Science & Applications, vol. 14, p. 250, 2025.

[154] H. Yang and H. Ren, “Pushing the limits of inverse lithography with generative reinforcement learning,” 2026. [Online]. Available: https://arxiv.org/abs/2602.19027

[155] J. Ji et al., “Laser direct writing rapid inversion lithography method based on generative adversarial network,” Materials Science in Semiconductor Processing, vol. 28, p. 110525, 2026.

[156] NVIDIA Corporation, “TSMC and Synopsys bring breakthrough NVIDIA computational lithography platform to production,” GTC Press Release, Mar. 2024. [Online]. Available: https://nvidianews.nvidia.com/news/tsmc-synopsys-nvidia-culitho

[157] Z. Hu, T. Schlosser, M. Friedrich, A. L. Vieira e Silva, F. Beuth, and D. Kowerko, “Utilizing generative adversarial networks for image data augmentation and classification of semiconductor wafer dicing induced defects,” in Proceedings of the 2024 IEEE 29th International Conference on Emerging Technologies and Factory Automation (ETFA), 2024, arXiv:2407.20268.

[158] J. Zou, H. Wang, and J. Zhong, “Wafer defect image generation method based on improved StyleGANv3 network,” Micromachines, vol. 16, no. 8, p. 844, 2025.

[159] C. Wu and X. Li, “SinSEMI: A one-shot image generation model and data-efficient evaluation framework for semiconductor inspection equipment,” arXiv preprint, 2025, arXiv:2511.06740.

[160] T.-H. Tsai and C.-Y. Wang, “Wafer map defect classification using deep learning framework with data augmentation on imbalance datasets,” Journal of Image and Video Processing, vol. 2025, p. 6, 2025.

[161] A. Dobrovsky, K. Schekotihin, and C. Burmer, “Intelligent assistants for the semiconductor failure analysis with LLM-based planning agents,” in Proceedings of ISTFA 2025: 51st International Symposium for Testing and Failure Analysis, 2025, pp. 41–58, also available as arXiv:2506.15567.

[162] P. Barry, “Automating the network lifecycle: How agentic AI is transforming root cause analysis,” Spirent Blog, Jan. 2026. [Online]. Available: https://www.spirent.com/blogs/automating-the-network-lifecycle-how-agentic-ai-is-transforming-root-cause-analysis

[163] OpenClaw, “OpenClaw Foundation – GitHub repository,” GitHub, 2026. [Online]. Available: https://github.com/openclaw/openclaw

[164] N. Khan, “Fix for stale authentication profile cooldowns in OpenClaw,” GitHub Pull Request #17853, openclaw/openclaw, Feb. 2026, merged Feb 16, 2026; commit message: fix(auth): auto-expire stale auth profile cooldowns and reset error count. [Online]. Available: https://github.com/openclaw/openclaw/pull/17853

[165] ———, “Honored to announce my second contribution to the OpenClaw project,” LinkedIn, Feb. 2026. [Online]. Available: https://www.linkedin.com/posts/nabbil_honored-to-announce-my-second-contribution-activity-7429587455907115008-kRA-/

[166] Aitomatic, “Aitomatic unveils SemiKong AI breakthrough set to reshape $500b semiconductor industry,” PR Newswire, Jul. 2024. [Online]. Available: https://www.prnewswire.com/news-releases/aitomatic-unveils-semikong-ai-breakthrough-set-to-reshape-500b-semiconductor-industry-302194215.html

[167] C. Nguyen, W. Nguyen, A. Suzuki, D. Oku, H. A. Phan, S. Dinh, Z. Nguyen, A. Ha, S. Raghavan, H. Vo, T. Nguyen, L. Nguyen, and Y. Hirayama, “SemiKong: Curating, training, and evaluating a semiconductor industry-specific large language model,” arXiv preprint, 2024, arXiv:2411.13802.

[168] Intel Corporation, “Using natural language processing to streamline manufacturing failure mode and effects analysis,” Intel IT, White Paper, 2024. [Online]. Available: https://www.intel.com/content/dam/www/central-libraries/us/en/documents/2024-07/intel-it-nlp-streamline-manufacturing-analysis-paper.pdf

[169] C. I. Garcia, M. A. DiBattista, T. A. Letelier, H. D. Halloran, and J. A. Camelio, “Framework for LLM applications in manufacturing,” Manufacturing Letters, vol. 41, pp. 253–263, 2024.

[170] P. S. Gouripeddi et al., “LLM-inspired approach for semiconductor recipe modeling,” in SEMICON West Conference Proceedings, 2025. [Online]. Available: https://semiconwest2025.eventscribe.net/fsPopup.asp?PresentationID=1675813&mode=presInfo

[171] R. Khurana, “Agentic AI in manufacturing: The 5-stage blueprint for an autonomous industry,” WNS Global Services, 2025. [Online]. Available: https://www.wns.com/perspectives/articles/agentic-ai-in-manufacturing-the-5-stage-blueprint-for-an-autonomous-industry

[172] Siemens AG, “Siemens launches Fuse EDA AI agent for automation across semiconductor workflows,” MarketWatch Press Release, Mar. 2026. [Online]. Available: https://www.marketwatch.com/press-release/siemens-launches-fuse-eda-ai-agent-for-automation-across-semiconductor-3d-ic-and-pcb-system-workflows-7658eabe

[173] P. Saxena, “A roadmap to agentic AI in manufacturing,” HCLTech, Google Business Unit, 2026. [Online]. Available: https://www.hcltech.com/de-de/trends-and-insights/agentic-ai-roadmap-manufacturing

[174] InstruNEXT GmbH, “AI in high-tech manufacturing,” Conference Presentation, Bavaria–Japan CONNECT, Munich, Nov. 2025. [Online]. Available: https://kk.htcm.de/press-releases/wuerth/wth1pi1721/

[175] Y. Gao, S. W. Wang, T. Dragicevic, P. Wheeler, and P. Zanchetta, “Artificial intelligence techniques for enhancing the performance of controllers in power converter-based systems—an overview,” IEEE Open Journal on Industry Applications, vol. 4, pp. 366–375, 2023.

[176] L. Buchta, M. Kozovsky, and P. Blaha, “A dead-time compensation strategy based on an online learned artificial neural network,” IEEE Transactions on Industrial Electronics, vol. 72, no. 10, pp. 10 574–10 584, 2025.

[177] M. Zhang, P. I. Gómez, Q. Xu, and T. Dragicevic, “Review of online learning for control and diagnostics of power converters and drives: Algorithms, implementations and applications,” Renewable and Sustainable Energy Reviews, vol. 186, p. 113627, 2023. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S1364032123004847

[178] J. Liu, W. Guan, Y. Lu, and Y. Zhou, “Adaptive control strategy for the pi parameters of modular multilevel converters based on dual-agent deep reinforcement learning,” Electronics, vol. 14, no. 11, 2025. [Online]. Available: https://www.mdpi.com/2079-9292/14/11/2270

[179] D. Alfred, D. Czarkowski, and J. Teng, “Reinforcement learning-based control of a power electronic converter,” Mathematics, vol. 12, no. 5, 2024. [Online]. Available: https://www.mdpi.com/2227-7390/12/5/671

[180] A. Başkaya and B. Tamyurek, “Self-tuning current control via ann for enhanced harmonic mitigation in hybrid pv–battery storage systems utilizing the 3l-hanpc inverter,” Electronics, vol. 14, no. 23, 2025. [Online]. Available: https://www.mdpi.com/2079-9292/14/23/4617

[181] A. Jamal, “ANN-based control of a three-phase inverter,” p. 14, 2 2026. [Online]. Available: https://imperix.com/doc/implementation/ann-based-control-of-a-three-phase-inverter

[182] H. Maruta, H. Taniguchi, and F. Kurokawa, “A study on effects of different control period of neural network-based reference modified pid control for dc-dc converters,” in 2016 Proc. 15th IEEE Int. Conf. Mach. Learn. Appl., 2016, pp. 460–465.

[183] J. Liu, T. Wei, N. Chen, W. Liu, J. Wu, and P. Xiao, “A neural network pid controller with dynamic structure adjustment for dc-dc switching converters,” in 2022 Proc. IEEE 7th Int. Conf. Integr. Circuits Microsystems, 2022, pp. 356–360.

[184] J. Zhang, J. Xu, Y. Dai, Y. Miao, X. Zhang, and H. Wnag, “Artificial intelligence-based modeling and control strategy for dual active bridge converter with triple phase shift modulation,” IEEE Trans. on Power Electronics, vol. 41, no. 1, pp. 494 – 413, 2026.

[185] W. Wang, H. Chung, R. Cheng, C. Leung, X. Zhan, A. Lo, J. Kwok, C. Xue, and J. Zhang, “Training neural-network-based controller on distributed machine learning platform for power electronics systems,” in 2017 Proc. IEEE Energy Convers. Congr. Expo., 2017, pp. 3083 – 3089.

[186] G. N. Baltas, N. B. Lai, L. Marin, A. Tarraso, and P. Rodriguez, “Grid-forming power converters through artificial intelligence to damp subsynchronous interactions in electrical

grids," IEEE Access, vol. 8, pp. 93 369 – 93 379, 2020.

[187] W. Liu, T. Kerekes, T. Dragicevic, and R. Teodorescu, "Review of grid stability assessment based on ai and a new concept of converter dominated power system state of stability assessment," IEEE J. Emerg. Sel. Topics Ind. Electron., vol. 4, no. 3, pp. 928 – 938, 2023.

[188] Y. Fassi, V. Heiries, J. Boutet, and S. Boisseau, "Toward physics-informed machine-learning-based predictive maintenance for power converters—a review," IEEE Transactions on Power Electronics, vol. 39, no. 2, pp. 2692–2720, 2024.

[189] S. Zhao, Y. Peng, Y. Zhang, and H. Wang, "Parameter estimation of power electronic converters with physics-informed machine learning," IEEE Transactions on Power Electronics, vol. 37, no. 10, pp. 11 567–11 578, 2022.

[190] V. S. Bharath Kurukuru, K. Mirdoddi, R. Petrella, M. N. Hasan, and C. Mentin, "Validating junction temperature estimation of power modules using generative ai and fiber optic sensing," in 2024 IEEE Design Methodologies Conference (DMC), 2024, pp. 1–7.

[191] Z. Yang, X. Chen, B. Zhu, L. Zhang, and Y. Huang, "On fractional-order thermal network modeling and parameter extraction of igbt modules," IEEE Transactions on Power Electronics, vol. 41, no. 4, pp. 4756–4765, 2026.

[192] T. Henneron, W. Chen, L. Pace, J. Tomezyk, S. Clénet, and H. Taha, "Co-simulation of a printed circuit board modeled by a cauer ladder network approach combined with gan transistors," IEEE Transactions on Power Electronics, vol. 40, no. 5, pp. 7095–7105, 2025.

[193] B. Hashemi, S. Taheri, A.-M. Cretu, and E. Pouresmaeil, "Systematic photovoltaic system power losses calculation and modeling using computational intelligence techniques," Applied Energy, vol. 284, p. 116396, 2021. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S0306261920317670

[194] S. M. I. Rahman, A. Moghassemi, A. Arsalan, L. Timilsina, P. K. Chamarthi, B. Papari, G. Ozkan, and C. S. Edrington, "Emerging trends and challenges in thermal management of power electronic converters: A state of the art review," IEEE Access, vol. 12, pp. 50 633–50 672, 2024.

[195] Z. Zhao, F. Blaabjerg, and H. Wang, "Artificial intelligence-based digital twin for power electronic systems," IEEE Journal of Emerging and Selected Topics in Power Electronics, 2021.

[196] F. Blaabjerg and K. Ma, "Reliability of power electronics systems," IEEE Transactions on Power Electronics, vol. 36, no. 1, pp. 1–20, 2021.

[197] G. E. Karniadakis, I. G. Kevrekidis, L. Lu, P. Perdikaris, S. Wang, and L. Yang, "Physics-informed machine learning," Nature Reviews Physics, vol. 3, pp. 422–440, 2021.

[198] D. G. Luenberger, "An introduction to observers," IEEE Transactions on Automatic Control, vol. 16, no. 6, pp. 596–602, 1971.

[199] R. E. Kalman, “A new approach to linear filtering and prediction problems,” Journal of Basic Engineering, vol. 82, no. 1, pp. 35–45, 1960.

[200] A. G. Beccuti, S. Mariéthoz, S. Cliquennois, S. Wang, and M. Morari, “Explicit model predictive control of DC–DC switched-mode power supplies with extended kalman filtering,” IEEE Transactions on Industrial Electronics, vol. 56, no. 6, pp. 1864–1874, 2009.

[201] H. Renaudineau, J.-P. Martin, B. Nahid-Mobarakeh, and S. Pierfederici, “DC–DC converters dynamic modeling with state observer-based parameter estimation,” IEEE Transactions on Power Electronics, vol. 30, no. 6, pp. 3356–3363, 2015.

[202] M. Ahmeid, M. Armstrong, S. Gadoue, M. Al-Greer, and P. Missailidis, “Real-time parameter estimation of DC–DC converters using a self-tuned kalman filter,” IEEE Transactions on Power Electronics, vol. 32, no. 7, pp. 5666–5674, 2017.

[203] N. Hoffmann and F. W. Fuchs, “Minimal invasive equivalent grid impedance estimation in inductive–resistive power networks using extended kalman filter,” IEEE Transactions on Power Electronics, vol. 29, no. 2, pp. 631–641, 2014.

[204] J. Holtz, “Sensorless control of induction motor drives,” Proceedings of the IEEE, vol. 90, no. 8, pp. 1359–1394, 2002.

[205] D. S. Putra, S.-C. Chen, H.-H. Khong, and F. Cheng, “Design and implementation of a machine-learning observer for sensorless PMSM drive control,” Applied Sciences, vol. 12, no. 6, p. 2963, 2022.

[206] Q. Gao and C. Zong, “Rotor position estimation method of PMSM based on recurrent neural network,” Energy Reports, vol. 8, no. Supplement 1, pp. 883–889, 2022.

[207] V. Spinu, M. Dam, and M. Lazar, “Observer design for DC/DC power converters with bilinear averaged model,” in Proceedings of the 4th IFAC Conference on Analysis and Design of Hybrid Systems (ADHS 12), Eindhoven, The Netherlands, Jun. 2012, pp. 204–209.

[208] Q. Tong, C. Chen, Q. Zhang, and X. Zou, “A sensorless predictive current controlled boost converter by using an EKF with load variation effect elimination function,” Sensors, vol. 15, no. 5, pp. 9986–10 003, 2015.

[209] W. He, X. Wang, M. M. Namazi, W. Zhou, and J. M. Guerrero, “A reduced-order adaptive state observer for DC–DC converters with unknown constant power load,” Control Engineering Practice, vol. 143, p. 105785, 2024.

[210] M. Sun and Z. Sahinoglu, “Extended kalman filter based grid synchronization in the presence of voltage unbalance for smart grid,” in IEEE PES Innovative Smart Grid Technologies Conference (ISGT), 2011, pp. 1–4.

[211] X. Wang and E. E. Yaz, “Smart power grid synchronization with fault tolerant nonlinear estimation,” IEEE Transactions on Power Systems, vol. 31, no. 6, pp. 4806–4816, 2016.

[212] J. Kukkola and M. Hinkkanen, “State observer for grid-voltage sensorless control of a converter equipped with an LCL filter: Direct discrete-time design,” IEEE Transactions on Industry Applications, vol. 52, no. 4, pp. 3133–3145, 2016.

[213] H.-S. Kim and K.-H. Kim, “Voltage-sensorless control scheme for a grid connected inverter using disturbance observer,” Energies, vol. 10, no. 2, p. 166, 2017.

[214] M. A. Eleffendi and C. M. Johnson, “Application of kalman filter to estimate junction temperature in IGBT power modules,” IEEE Transactions on Power Electronics, vol. 31, no. 2, pp. 1576–1587, 2016.

[215] R. Saheba, M. Rotea, O. Wasynczuk, and S. Pekarek, “Real-time thermal observer for electric machines,” in SAE Technical Paper, no. 2006-01-3102, 2006.

[216] G. Revach, N. Shlezinger, X. Ni, A. L. Escoriza, R. J. G. van Sloun, and Y. C. Eldar, “Kalmannet: Neural network aided kalman filtering for partially known dynamics,” IEEE Transactions on Signal Processing, vol. 70, pp. 1532–1547, 2022.

[217] N. Shlezinger, G. Revach, A. Ghosh, S. Chatterjee, S. Tang, T. Imbiriba, J. Dunik, O. Straka, P. Closas, and Y. C. Eldar, “AI-aided kalman filters,” arXiv preprint, 2024.

[218] L. N. Tan, T. P. Cong, and D. P. Cong, “Neural network observers and sensorless robust optimal control for partially unknown PMSM with disturbances and saturating voltages,” IEEE Transactions on Power Electronics, vol. 36, no. 10, pp. 12 045–12 056, 2021.

[219] E. Ilten, H. Çalgan, and M. Demirtaş, “Design of induction motor speed observer based on long short-term memory,” Neural Computing and Applications, vol. 34, pp. 18 703–18 723, 2022.

[220] D. S. Putra, S.-C. Chen, H.-H. Khong, and C.-F. Chang, “Realization of intelligent observer for sensorless PMSM drive control,” Mathematics, vol. 11, no. 5, p. 1254, 2023.

[221] H. Li, R. Zhang, P. Shi, Y. Mei, K. Zheng, and T. Qiu, “Sensorless control of a PMSM based on an RBF neural network-optimized ADRC and SGHCKF-STF algorithm,” Measurement and Control, vol. 57, no. 3, pp. 266–279, 2024.

[222] R. İnan, B. Aksoy, and O. K. M. Salman, “Estimation performance of the novel hybrid estimator based on machine learning and extended kalman filter proposed for speed-sensorless direct torque control of brushless direct current motor,” Engineering Applications of Artificial Intelligence, vol. 126, p. 107083, 2023.

[223] M. Stender, O. Wallscheid, and J. Böcker, “Accurate torque estimation for induction motors by utilizing a hybrid machine learning approach,” in 2021 IEEE 19th International Power Electronics and Motion Control Conference (PEMC), 2021.

[224] M. Norambuena and D. Galvez, “Model free artificial neural network for an induction machine,” in 2023 IEEE Conference on Power Electronics and Renewable Energy (CPERE), 2023.

[225] G. Becerra, F. Ruiz, D. Patiño, M. T. Pham, and X. Lin-Shi, “Learning-based current estimation for power converters operating in continuous and discontinuous conduction modes,” Mathematics and Computers in Simulation, vol. 224, pp. 19–32, 2024.

[226] B. Jessie, T. Westergaard, B. Fahimi, and P. Balsara, “Development of digital twin for dc-dc converters under varying parameter conditions,” Electronics, vol. 14, no. 13, 2025.

[227] J. G. Berger, J. Lillo, F. Rojas, and C. M. Hackl, “Fixed-point recurrent neural network based observer for cell voltage estimation in modular multilevel cascade converters on fpga platforms,” in Annual Conference of the IEEE Industrial Electronics Society (IECON), 2025.

[228] S. Langarica, G. Pizarro, P. M. Poblete, F. Radrigán, J. Pereda, J. Rodriguez, and F. Núñez, “Denoising and voltage estimation in modular multilevel converters using deep neural-networks,” IEEE Access, vol. 8, pp. 207 973–207 981, 2020.

[229] P. Poblete, G. Pizarro, G. Droguett, F. Núñez, P. D. Judge, and J. Pereda, “Distributed neural network observer for submodule capacitor voltage estimation in modular multilevel converters,” IEEE Transactions on Power Electronics, vol. 37, no. 9, pp. 10 306–10 318, 2022.

[230] O. Babayomi, Z. Zhang, and Z. Li, “Model-free predictive control of dc–dc boost converters: Sensor noise suppression with hybrid extended state observers,” IEEE Transactions on Power Electronics, vol. 39, no. 1, pp. 245–259, 2024.

[231] B. Adineh, M. R. Habibi, A. N. Akpolat, and F. Blaabjerg, “Sensorless voltage estimation for total harmonic distortion calculation using artificial neural networks in microgrids,” IEEE Transactions on Circuits and Systems II: Express Briefs, vol. 68, no. 7, pp. 2583–2587, 2021.

[232] Q.-H. Ngo, B. L. Nguyen, T. V. Vu, J. Zhang, and T. Ngo, “Physics-informed graphical neural network for power system state estimation,” Applied Energy, vol. 358, p. 122602, 2024.

[233] P. Mack, M. de Koster, P. Lehnen, E. Waffenschmidt, and I. Stadler, “Power quality state estimation for distribution grids based on physics-aware neural networks—harmonic state estimation,” Energies, vol. 17, no. 21, 2024.

[234] T. A. Alghamdi, O. T. Abdusalam, F. Anayi, and M. Packianather, “An artificial neural network based harmonic distortions estimator for grid- connected power converter-based applications,” Ain Shams Engineering Journal, vol. 14, no. 4, p. 101916, 2023.

[235] W. Kirchgässner, O. Wallscheid, and J. Böcker, “Thermal neural networks: Lumped-parameter thermal modeling with state-space machine learning,” Engineering Applications of Artificial Intelligence, vol. 117, p. 105537, 2023.

[236] J. Yu, P. Alagarsamy, and O. Wallscheid, “Thermal neural networks for temperature estimation of traction inverters in electric vehicles,” in International Exhibition and Conference for Power Electronics, Intelligent Motion, Renewable Energy and Energy Management (PCIM), 2025.

[237] X. Liao, S. Chen, Y. Long, and S. Zhao, “Neural dynamics model for temperature estimation of permanent magnet synchronous motor,” IEEE Transactions on Vehicular Technology, vol. 74, no. 8, pp. 11 993–12 003, 2025.

[238] N. Wiese, K. Etzold, R. Reinhardt, and M. Henke, “Thermal neural networks for high-resolution temperature modeling of electric traction machines with oil spray cooling,” IEEE Transactions on Transportation Electrification, vol. 11, no. 1, pp. 870–879, 2025.

[239] S. Wang, H. Kwon, D. Grigoryan, H. Li, T. Guillod, C. R. Sullivan, and M. Chen, “Unified time domain foundation models for hysteretic passive components,” in IEEE Workshop on Control and Modeling for Power Electronics (COMPEL), 2025.

[240] S. Wang, H. Kwon, H. Li, Y. Elasser, G.-G. Kang, D. Zhou, D. Grigoryan, and M. Chen, “Magnetx: Foundation neural network models for simulating power magnetics in transient,” in IEEE Applied Power Electronics Conference and Exposition (APEC), 2025.

[241] H. Kwon, S. Wang, H. Li, Y. Elasser, G.-G. Kang, D. Zhou, D. Grigoryan, and M. Chen, “Magnetx: Extending the magnet database for modeling power magnetics in transient,” in IEEE Applied Power Electronics Conference and Exposition (APEC), 2025.

[242] A. Chandra, T. Kapoor, B. Daniels, M. Curti, K. Tiels, D. M. Tartakovsky, and E. A. Lomonova, “Generalizable models of magnetic hysteresis via physics-aware recurrent neural networks,” Computer Physics Communications, vol. 314, p. 109650, 2025.

[243] E. Cardelli, A. Faba, A. Laudani, G. M. Lozito, F. R. Fulginei, and A. Salvini, “Two-dimensional magnetic modeling of ferromagnetic materials by using a neural networks based hybrid approach,” Physica B: Condensed Matter, vol. 486, pp. 106–110, 2016.

[244] C. Grech, M. Buzio, M. Pentella, and N. Sammut, “Dynamic ferromagnetic hysteresis modelling using a preisach-recurrent neural network model,” Materials, vol. 13, no. 11, p. 2561, 2020.

[245] G. Choi et al., “Split-kalmannet: A robust model-based deep learning approach for state estimation,” arXiv preprint, 2022.

[246] I. Buchnik, D. Steger, G. Revach, R. J. G. van Sloun, T. Routtenberg, and N. Shlezinger, “Latent-kalmannet: Learned kalman filtering for tracking from high-dimensional signals,” arXiv preprint, 2023.

[247] D. C. Jiles and D. L. Atherton, “Theory of ferromagnetic hysteresis,” Journal of Magnetism and Magnetic Materials, vol. 61, no. 1–2, pp. 48–60, 1986.

[248] G. Bertotti, Hysteresis in Magnetism: For Physicists, Materials Scientists, and Engineers. San Diego, CA: Academic Press, 1998.

[249] A. Hubert and R. Schäfer, Magnetic Domains: The Analysis of Magnetic Microstructures. Berlin, Heidelberg: Springer, 1998.

[250] R. B. Diba, M. L. Plumer, and I. Saika-Voivod, “Simulating micromagnetism,” Advances in Physics: X, vol. 9, no. 1, p. 2409070, 2024.

[251] C. Wu, Z. Cui, Q. Xia, J. Yue, and F. Lyu, “An overview of digital twin technology for power electronics: State-of-the-art and future trends,” IEEE Transactions on Power Electronics, vol. 40, no. 9, pp. 13 337–13 362, 2025.

[252] V. S. B. Kurukuru, A. Haque, M. A. Khan, S. Sahoo, A. Malik, and F. Blaabjerg, “A review on artificial intelligence applications for grid-connected solar photovoltaic systems,” Energies, vol. 14, no. 15, 2021. [Online]. Available: https://www.mdpi.com/1996-1073/14/15/4690

[253] M. A. Khan, Overview and Impact of Faults in Grid-Connected Photovoltaic Systems. John Wiley & Sons, Ltd, 2022, ch. 1, pp. 1–42. [Online]. Available: https://onlinelibrary.wiley.com/doi/abs/10.1002/9781119873785.ch1

[254] F. Rojas, C. Jerez, C. M. Hackl, O. Kalmbach, J. Pereda, and J. Lillo, “Faults in modular multilevel cascade converters–part ii: Fault tolerance, fault detection and diagnosis, and system reconfiguration,” IEEE Open Journal of the Industrial Electronics Society, vol. 3, pp. 594–614, 2022.

[255] F. Huang, X. Zhang, G. Qin, J. Xie, J. Peng, S. Huang, Z. Long, and Y. Tang, “Demagnetization fault diagnosis of permanent magnet synchronous motors using magnetic leakage signals,” IEEE Transactions on Industrial Informatics, vol. 19, no. 4, pp. 6105–6116, 2023.

[256] M. A. Rezaei, A. Fathollahi, E. Akbari, M. Saki, E. Khorgami, A. R. Teimouri, A. T. Chronopou-los, and A. Mosavi, “Reliability calculation improvement of electrolytic capacitor banks used in energy storage applications based on internal capacitor faults and degradation,” IEEE Access, vol. 12, pp. 13 146–13 164, 2024.

[257] T. Ebel and M. Khan, “Lifetime assessment of capacitors - are the existing models correct? -a critical review,” in International Conference on Integrated Power Electronics Systems. VDE Verlag GmbH, Mar. 2026, international Conference on Integrated Power Electronics Systems : CIPS 2026 ; Conference date: 10-03-2026 Through 12-03-2026. [Online]. Available: https://www.cips.eu/en

[258] A. Malik, A. Haque, V. B. Kurukuru, M. A. Khan, and F. Blaabjerg, “Overview of fault detection approaches for grid connected photovoltaic inverters,” e-Prime - Advances in

Electrical Engineering, Electronics and Energy, vol. 2, p. 100035, 2022. [Online]. Available: https://www.sciencedirect.com/science/article/pii/S2772671122000079

[259] Q. Lin, L. Zheng, R. Huang, C.-M. Lin, and F. Wang, “Parametric fault diagnosis using transfer cerebellar model neural network for power electronic converter,” IEEE Transactions on Instrumentation and Measurement, vol. 74, pp. 1–13, 2025.

[260] V. S. B. Kurukuru, F. Blaabjerg, M. A. Khan, and A. Haque, “A novel fault classification approach for photovoltaic systems,” Energies, vol. 13, no. 2, 2020. [Online]. Available: https://www.mdpi.com/1996-1073/13/2/308

[261] T. G. Amaral, V. F. Pires, A. Cordeiro, D. Foito, J. F. Martins, J. Yamnenko, T. Tereschenko, L. Laikova, and I. Fedin, “Incipient fault diagnosis of a grid-connected t-type multilevel inverter using multilayer perceptron and walsh transform,” Energies, vol. 16, no. 6, 2023. [Online]. Available: https://www.mdpi.com/1996-1073/16/6/2668

[262] L. You, Z. Ling, Y. Cui, W. Cai, and S. He, “Open circuit fault detection of t-type grid connected inverters using fast s transform and random forest,” Entropy, vol. 25, no. 5, 2023. [Online]. Available: https://www.mdpi.com/1099-4300/25/5/778

[263] S. Peyghami, Z. Wang, and F. Blaabjerg, “A guideline for reliability prediction in power electronic converters,” IEEE Transactions on Power Electronics, vol. 35, no. 10, pp. 10 958–10 968, 2020.

[264] H. Wang and F. Blaabjerg, “Power electronics reliability: State of the art and outlook,” IEEE Journal of Emerging and Selected Topics in Power Electronics, vol. 9, no. 6, pp. 6476–6493, 2021.

[265] S. Zhao, Y. Peng, F. Yang, E. Ugur, B. Akin, and H. Wang, “Health state estimation and remaining useful life prediction of power devices subject to noisy and aperiodic condition monitoring,” IEEE Transactions on Instrumentation and Measurement, vol. 70, pp. 1–16, 2021.

[266] M. A. Eleffendi and C. M. Johnson, “In-service diagnostics for wire-bond lift-off and solder fatigue of power semiconductor packages,” IEEE Transactions on Power Electronics, vol. 32, no. 9, pp. 7187–7198, 2017.

[267] M. Ghadrdan, S. Peyghami, H. Mokhtari, and F. Blaabjerg, “Condition monitoring of dc-link electrolytic capacitor in back-to-back converters based on dissipation factor,” IEEE Transactions on Power Electronics, vol. 37, no. 8, pp. 9733–9744, 2022.

[268] Z. Shen, Q. Wang, Y. Shen, and H. Wang, “First observations in degradation testing of planar magnetics,” in 2019 IEEE Applied Power Electronics Conference and Exposition (APEC), 2019, pp. 1436–1443.

[269] H. Wang and F. Blaabjerg, “Reliability of capacitors for dc-link applications in power electronic converters—an overview,” IEEE Transactions on Industry Applications, vol. 50, no. 5,

pp. 3569– 3578, 2014.

[270] J. Gao, S. Chen, D. Wang, H. Wang, and S. Zhao, “Adaptive remaining useful life prediction for film capacitors in dc-link applications using degradation and failure data,” IEEE Transactions on Power Electronics, vol. 41, no. 4, pp. 5670–5683, 2026.

[271] Z. Lian, P. Shi, and M. Chen, “A survey on cyber-attacks for cyber-physical systems: Modeling, defense, and design,” IEEE Internet of Things Journal, vol. 12, no. 2, pp. 1471–1483, 2025.

[272] V. S. B. Kurukuru, M. A. Khan, and S. Sahoo, “Cybersecurity in power electronics using minimal data – a physics-informed spline learning approach,” IEEE Transactions on Power Electronics, vol. 37, no. 11, pp. 12 938–12 943, 2022.

[273] B. Ahn, T. Kim, S. Ahmad, S. K. Mazumder, J. Johnson, H. A. Mantooth, and C. Farnell, “An overview of cyber-resilient smart inverters based on practical attack models,” IEEE Transactions on Power Electronics, vol. 39, no. 4, pp. 4657–4673, 2024.

[274] F. Blaabjerg, K. Zhang, Y. Song, Y. Zhang, B. Yao, M. Novak, S. Zhao, S. Sahoo, A. Sangwongwanich, and H. Wang, “Advances in reliability and artificial intelligence for power electronic systems,” IEEE Transactions on Power Electronics, pp. 1–22, 2026.

[275] P. V. Dantas, W. Sabino da Silva, L. C. Cordeiro, and C. B. Carvalho, “A comprehensive review of model compression techniques in machine learning,” Applied Intelligence, vol. 54, no. 22, p. 11804–11844, Sep. 2024. [Online]. Available: http://dx.doi.org/10.1007/s10489-024-05747-w

[276] C. White, M. Safari, R. Sukthanker, B. Ru, T. Elsken, A. Zela, D. Dey, and F. Hutter, “Neural architecture search: Insights from 1000 papers,” 2023. [Online]. Available: https://arxiv.org/abs/2301.08727

[277] S. Han, H. Mao, and W. J. Dally, “Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding,” 2016. [Online]. Available: https://arxiv.org/abs/1510.00149

[278] I. Araus, D. Lorca, J. Pereda, and F. Rojas, “A hybrid architecture based on quantized and physics-informed neural network for high-fidelity shc-pwm,” IEEE Transactions on Power Electronics, pp. 1–11, 2026.

[279] G. Hinton, O. Vinyals, and J. Dean, “Distilling the knowledge in a neural network,” 2015. [Online]. Available: https://arxiv.org/abs/1503.02531

[280] M. Basavaraju, V. Rayapati, and M. Rao, “Exploring hardware activation function design: Cordic architecture in diverse floating formats,” in 2024 25th International Symposium on Quality Electronic Design (ISQED), 2024, pp. 1–8.

[281] EDN Editorial, “2024: The year when MCUs became AI-enabled,” EDN Network, Dec. 2024, industry overview covering ST, TI, Infineon, Renesas, NXP, and Arm Ethos-U55. Accessed: 2026-03-18. [Online]. Available: https://www.edn.com/2024-the-year-when-mcus-became-ai-enabled/

[282] STMicroelectronics, “X-CUBE-AI – AI expansion pack for STM32CubeMX,” STMicroelectronics Product Page, 2025, accessed: 2026-03-18. [Online]. Available: https://www.st.com/en/embedded-software/x-cube-ai.html

[283] L. Ljung, C. Andersson, K. Tiels, and T. B. Schön, “Deep learning and system identification,” IFAC-PapersOnLine, vol. 53, no. 2, pp. 1175–1181, 2020, 21st IFAC World Congress.

[284] J. Schoukens and L. Ljung, “Nonlinear system identification: A user-oriented road map,” IEEE Control Systems Magazine, vol. 39, no. 6, pp. 28–99, 2019.

[285] R. W. Erickson and D. Maksimovic, Fundamentals of Power Electronics, 2nd ed. Springer, 2001.

[286] C. J. M. Lasance, “Thermal modeling of power electronic systems,” IEEE Transactions on Components, Packaging and Manufacturing Technology, vol. 4, no. 2, pp. 199–210, 2014.

[287] P. W. Koh, S. Sagawa, H. Marklund, S. M. Xie, M. Zhang, A. Balsubramani, W. Hu, M. Yasunaga, R. L. Phillips, I. Gao et al., “WILDS: A benchmark of in-the-wild distribution shifts,” in Proceedings of the 38th International Conference on Machine Learning, 2021, pp. 5637–5664.

[288] J. C. Willems, P. Rapisarda, I. Markovsky, and B. L. M. De Moor, “A note on persistency of excitation,” Systems & Control Letters, vol. 54, no. 4, pp. 325–329, 2005.

[289] L. Pronzato, “Optimal experimental design and some related control problems,” Automatica, vol. 44, no. 2, pp. 303–325, 2008.

[290] M. Kiss, R. Tóth, and M. Schoukens, “Space-filling input design for nonlinear state-space identification,” IFAC-PapersOnLine, vol. 58, no. 15, pp. 562–567, 2024.

[291] V. Smits and O. Nelles, “Space-filling optimized excitation signals for nonlinear system identification of dynamic processes of a diesel engine,” Control Engineering Practice, vol. 144, p. 105821, 2024.

[292] H. Vater, M. Peña, and O. Wallscheid, “Optimal system excitation of a permanent magnet synchronous motor using differentiable model predictive excitation,” in IEEE International Electric Machines & Drives Conference (IEMDC), 2025, pp. 245–251.

[293] E. G. Gedlu, O. Wallscheid, J. Böcker, and O. Nelles, “Online system identification and excitation for thermal monitoring of electric machines using machine learning and model

predictive control,” in IEEE International Symposium on Diagnostics for Electrical Machines, Power Electronics and Drives (SDEMPED), 2023.

[294] K. Weiss, T. M. Khoshgoftaar, and D. Wang, “A survey of transfer learning,” Journal of Big Data, vol. 3, no. 1, p. 9, 2016. [Online]. Available: https://doi.org/10.1186/s40537-016-0043-6

[295] S. Cortes-Gomez, C. Patiño, Y. Byun, S. Wu, E. Horvitz, and B. Wilder, “Utility-directed conformal prediction: A decision-aware framework for actionable uncertainty quantification,” in International Conference on Learning Representations (ICLR), 2025.

[296] Y. Zhao, X. Yu, M. Sesia, J. V. Deshmukh, and L. Lindemann, “Conformal predictive programming for chance constrained optimization,” arXiv preprint arXiv:2402.07407, 2024.

[297] R. Li and A. Rodríguez, “Neural conformal control for time series forecasting,” arXiv preprint arXiv:2412.18144, 2024.

[298] Y. Yu, C. H. Ho, and Y. Wang, “A conformal prediction framework for uncertainty quantification in physics-informed neural networks,” arXiv preprint arXiv:2509.13717, 2025.

[299] A. Das, W. Kong, R. Sen, and Y. Zhou, “A decoder-only foundation model for time-series forecasting,” arXiv preprint arXiv:2310.10688, 2024.

[300] Z. Wang, Z. Zhang, T. Ma, N. V. Chawla, C. Zhang, and Y. Ye, “Towards graph foundation models: Learning generalities across graphs via task-trees,” arXiv preprint arXiv:2412.16441, 2025, accepted by ICML 2025.

[301] B. Holzschuh, Q. Liu, G. Kohl, and N. Thuerey, “Pde-transformer: Efficient and versatile transformers for physics simulations,” arXiv preprint arXiv:2505.24717, 2025.

[302] T. Nguyen, A. Koneru, S. Li, and A. Grover, “Physix: A foundation model for physics simulations,” arXiv preprint arXiv:2506.17774, 2025.

[303] D. Li, X. Liao, S. Chen, and S. Zhao, “Data-efficient motor condition monitoring with time series foundation models,” arXiv preprint arXiv:2511.23177, accepted on IEEE APEC, 2026.

[304] J. Kaiser, A. Eichler, and A. Lauscher, “Large language models for human-machine collabora-tive particle accelerator tuning through natural language,” arXiv preprint arXiv:2405.08888, 2024.

[305] S. Schmidgall, Y. Su, Z. Wang, X. Sun, J. Wu, X. Yu, J. Liu, M. Moor, Z. Liu, and E. Barsoum, “Agent laboratory: Using llm agents as research assistants,” arXiv preprint arXiv:2501.04227, 2025.

[306] K. Löwenmark, D. Strömbergsson, C. Liu, M. Liwicki, and F. Sandin, “Agent-based condition monitoring assistance with multimodal industrial database retrieval augmented generation,” arXiv preprint arXiv:2506.09247, 2025.

[307] A. Vriza, M. H. Prince, T. Zhou, H. Chan, and M. J. Cherukara, “Operating advanced scientific instruments with ai agents that learn on the job,” npj Computational Materials, 2026.

白皮书二：AI 支持的电力电子教育

原文：*ECPE White Paper — AI-supported Power Electronics Education*，1.0 版，2026 年 10 月 ECPE 欧洲电力电子中心（ECPE European Center for Power Electronics e.V.），德国纽伦堡，www.ecpe.org 标识符：DOI 10.5281/zenodo.23097242

目录

- I. 引言
- II. 电力电子教育中的 AI 基础
- III. 电力电子中的 AI 辅助教学与学习
- IV. 智能仿真与虚拟实验室
- V. 自适应评估与自动反馈系统
- VI. AI 在电力电子教育中的挑战、伦理与实施
- VII. 结论

ECPE《电力电子中的人工智能（AI）》白皮书由 ECPE 研究网络的一组专家编写，作为 ECPE 工作组（Task Force）的一部分，该工作组下设若干子小组（SG），于 2025 年 9 月开始研讨。该白皮书可在 ECPE 网站 www.ecpe.org 获取，追溯了 AI 方法和工具在电力电子产品整个生命周期中的应用——从早期开发阶段，到制造，直至产品的运行阶段。

工作组决定将 AI 方法和工具在人的学习、教育和高级培训中的应用这一跨领域问题，在这份单独的《AI 支持的电力电子教育》白皮书中加以阐述，该文件由子小组 SG 5 编写。

《电力电子教育中的 AI》文件作者及其单位：

- Prof. Dr. Ingmar Kallfass —— 斯图加特大学（University of Stuttgart），德国
- Dr. Mohammed Ali Khan —— 南丹麦大学森讷堡校区（SDU Sønderborg），丹麦
- Sven Klausnitzer —— Eurocomp Elektronik，德国
- Dr. Varaha S. Bharath Kurukuru —— 奥地利硅实验室（SAL Silicon Austria Labs），奥地利
- Prof. Dr. Ulf Schwalbe —— 富尔达应用科学大学（Univ. of Applied Sciences Fulda），德国
- Prof. Dr. Subham Sahoo —— 奥尔堡大学（Aalborg University），丹麦
- Prof. Dr. Huai Wang —— 奥尔堡大学（Aalborg University），丹麦

我们感谢各位作者的支持以及对本 ECPE 白皮书所作的宝贵贡献，本白皮书突出了 AI 在电力电子教育中的作用和重要性。

Prof. Dr. Leo Lorenz，ECPE 主席 Dipl.-Phys. Thomas Harder，ECPE 总经理

电力电子教育中的 AI

I. 引言

电力电子融合了电路理论、开关器件物理、控制、磁性元件、热设计和嵌入式实现。这使得该学科难以作为一系列孤立的主题来讲授。学生必须在平均模型与开关模型之间、在解析设计方程与非理想硬件行为之间、以及在仿真结果与实测波形之间来回切换。在实践中，教学不仅受到学科复杂性的限制，还受到实验课时有限、变换器硬件的成本和安全约束，以及难以对多步骤设计任务及时给予反馈等因素的限制 [3]、[5]。

在这一背景下，AI 最有用的角色是作为教学和评估的支持层，而不是学科专业知识的替代品。电力电子课程会产生结构化的技术数据，可用于支持诊断性反馈、自适应学习和评估。因此，其主要教育价值并不在于通用的文本生成，而在于能够将学生的作业与变换器运行的物理和数学约束联系起来。

关于智能导学系统和自适应教学支持的研究表明，当基于 AI 的辅导能够对学习者的状态进行建模并提供针对具体任务的反馈（而非泛泛的提示）时，效果最佳 [1]、[2]。虚拟实验室和远程实验室为 AI 支持的实验与反馈提供了另一种场景 [3]、[4]。因此，关键问题在于：AI 在哪些方面能够提供有用的教学支持，同时又不削弱物理理解、实验规范或学术诚信。

II. 电力电子教育中的 AI 基础

AI 支持的电力电子教育并不依赖于某一种单一技术。智能仿真、自适应评估、自动反馈和学习分析都借助于少数几类反复出现的 AI 方法族。确立这些基础非常重要，因为后文讨论的各项应用并不是孤立的工具；它们依赖于相同的底层方法、数据结构和领域约束。

电力电子有两个特点与 AI 的应用尤为相关。第一，它受明确定义的物理定律支配。一个变换器要么满足适用的电路关系和运行约束，要么不满足。因此，对电力电子系统进行推理的 AI 系统必须遵守这些约束，而不能仅凭统计模式对其进行近似。第二，该领域既是多模态的，也是多尺度的。它结合了原理图、波形、特性曲线、版图和控制器代码，其动态过程从纳秒级的开关事件一直延伸到慢得多的控制和热过程。因此，一个有用的教育 AI 系统必须将通用 AI 方法与明确的领域结构结合起来。

大多数教育应用都可以追溯到四大类 AI 方法。这些方法族在成熟度、成本、可解释性和数据需求方面各不相同。在许多情况下，同一应用中需要组合使用其中的几种。对它们加以区分是有益的，否则近来对大语言模型的关注可能会掩盖那些更成熟方法的持续重要性。例如，统计学习仍然是最透明、最经济的方法之一，并继续支撑着许多学习分析系统、风险指标和早期预警仪表板。相比之下，物理感知方法将 AI 更直接地与工程内容联系起来，有助于确保模型输出与底层系统行为保持一致。

四大方法族及其在电力电子教育中的作用如下：

- **统计与机器学习模型：** 回归、分类和聚类方法从结构化数据中学习，用于预测成绩、归类反复出现的错误、识别学习者画像并标记风险。这些方法总体上成熟、计算成本低且相对可解释。
- **大语言模型与多模态模型：** 语言模型可以生成讲解、审查推导过程、点评报告并分析控制器代码。多模态变体将这些能力扩展到原理图、波形和其他可视化表示，这在一个大量推理以图形而非仅以文字表达的学科中十分重要。

- **物理信息模型与代理模型：** 物理信息神经网络及相关混合方法将控制方程或物理约束融入学习过程。数据驱动的代理模型能够以远低于详细仿真的计算成本近似变换器行为。这两种方法都与智能仿真相关，因为它们可以支持对变换器运行进行交互式或超实时的探索。
- **知识表示与检索：** 课程知识图谱可以编码变换器拓扑、元器件、控制方法、运行模式与学习能力之间的关系。与检索增强生成（RAG）相结合时，这些结构可以使语言模型的输出立足于经过验证的来源，并使由此产生的讲解更具可追溯性。

通用模型往往是起点，但要使其适用于电力电子教育，还需要三个额外要素。第一是立足于经过验证的来源，包括教科书、标准、经验证的参考答案以及经教师审定的课程材料。这为检验所生成的讲解和计算提供了权威依据。第二是多模态能力，使原理图、实测波形和仿真结果被当作主要输入，而非次要的插图。第三是明确施加物理约束，使所生成的设计、讲解和建议与电路理论及允许的运行条件保持一致。

电力电子领域经过标注的教育数据十分有限，并且常常受到版权或机构限制的保护。因此，领域适配通常会依靠适度的微调并结合从精选知识库中检索，而不是大规模的模型训练。这种方法还能降低计算成本，并减轻各大学或培训机构的数据保护负担。

这些基础可以视为一个分层的技术栈，如图 1 所示。底层包含通用的 AI 方法族。其上是领域适配层，提供经过验证的来源、多模态处理、物理约束和课程结构。辅导、评估、仿真、实验和学习分析等教育功能则构建在这一公共基础之上。

> **图 1 内容示意（自上而下）：**
>
> | 层级 | 组成 |
> | --- | --- |
> | 教育功能层 | 讲解与辅导 · 评估与反馈 · 仿真与实验 · 学习分析 |
> | 领域适配层 | 经验证的来源 · 多模态理解 · 物理约束 · 课程知识结构 |
> | 通用 AI 方法层 | 机器学习模型 · 大语言模型 · 物理信息模型 · 知识图谱 |
>
> **图 1：** 电力电子教育 AI 基础的分层视图。教育功能构建在领域适配层之上，而领域适配层又构建在通用 AI 方法族之上。

由于电力电子中的许多论断都可以对照方程、运行极限或仿真结果进行验证，技术准确性可以被"设计"进系统之中，而不是被想当然地假定。通用模型的一种典型失效模式是给出流畅而自信、但技术上不正确的回答。在工程背景下，这并非一个微不足道的表述问题，因为学习者可能无法区分一个"看似合理"的解释和一个"真正有效"的解释。

一种实用的保障措施是"先生成、后验证"（generate-then-verify）的工作流程。AI 模型首先提出一个解释、推导或设计，然后由独立的验证环节在将结果呈现给学习者之前对其进行检查。根据任务的不同，这种检查可能涉及符号方程、电路约束、数值参考计算、仿真结果或教师定义的规则。这种运行时验证还应辅以系统化的模型评测。面向电力电子推理的共享基准和经过校准的题库，将使在共同技术任务上比较不同系统成为可能，而这在目前是困难的。

III. 电力电子中的 AI 辅助教学与学习

在第 II 节所述基础之上，AI 辅助教学可以直接作用于学生生成的技术成果物。一种有用的实现模式是将 AI 层视为作用于学生成果物的诊断引擎。例如，在变换器分析任务中，系统可以将学生提交的状态空间模型、开关函数推导或仿真波形与一个"参考答案族"（而不是单一的数值答案）进行比较。这使得系统能够识别错误究竟源自极性约定、占空比定义、器件非理想性、采样解读、控制器离散化，还是对连续导通模式与断续导通模式运行的误解。这种错误定位在教学上比单纯的答案核对更有价值。

第二个高价值的应用场景是在面向设计的练习中提供自适应支架（scaffolding）。电力电子任务通常是分层的：拓扑选择先于元件选型；元件选型先于控制整定；控制整定先于瞬态和热验证。AI 支持可以利用这种依赖结构有选择地释放提示。系统并不直接告诉学生如何求解整个问题，而是可以检测出哪个前置子问题出了错，并将注意力引导到那个阶段。例如，在 Buck 变换器设计练习中，导学系统可以根据纹波电流、占空比范围或环路带宽方面的错误推断学生是在电感选型、开关频率权衡，还是小信号控制假设方面遇到了困难。这与智能导学系统的教学逻辑相近，但在这里领域模型必须包含电力电子约束和允许的运行区域 [1]、[2]。这些要素之间的相互作用可以视为一个闭环教学回路：学生作业依据领域模型被解读，用于更新学习者模型，并被转化为适当的教学响应，如图 2 所示。

> **图 2 内容示意：**
>
> - **教师定义的领域模型：** 任务与评分细则；参考答案族；电力电子约束与运行区域。
> - **学生生成的技术成果物：** 推导与电路标注；状态空间与开关模型；仿真波形与频谱；控制器代码与设计计算；实验日志与测量数据。
> - **AI 诊断引擎（领域感知分析，与领域模型进行比较）：** 错误定位；波形与信号解读；自适应支架；基于评分细则的反馈。示例诊断：极性约定、占空比定义、CCM/DCM 与器件非理想性、控制器离散化与采样解读、波形对齐以及运行区域越限。
> - **学习者模型（由诊断结果更新）：** 知识状态；误解；学习进度历史。
> - **教学响应（由学习者模型提供信息）：** 针对性提示；诊断性反馈；下一步学习活动；安全操作指导。
> - **仿真与实验环境（产生成果物、引导活动）：** 实验前检查；引导式调试；波形解读；安全实验。
> - 闭环教学回路：学生作业依据领域模型被解读，并用于更新学习者模型；随后学习者状态被转化为适当的教学响应和后续活动。
>
> **图 2：** 电力电子中 AI 辅助教学与学习的概念框架。学生生成的技术成果物依据教师定义的领域模型进行分析，用于支持诊断性反馈、自适应支架以及后续学习活动的选择 [9]。

仿真与实验环境为 AI 支持的诊断和反馈提供了另一类结构化技术数据来源。它们在实验前检查、波形解读、引导式调试和安全实验中的应用将在第 IV 节讨论。

生成式 AI 也有其价值，但仅限于严格约束的角色。在电力电子中，不受限制的文本生成远不如限定于领域范围内的生成有用。更站得住脚的应用场景包括：生成参数化的习题变体、实验指导书初稿、与评分细则一致的形成性评语，以及与任务中已有方程或波形相关联的引导式讲解。以这种方式使用时，生成式模型可以减少编写工作量，同时仍遵循第 II 节所述的"立足来源"和"验证"原则。

为保持本节简洁，表 I 总结了在电力电子教育中技术上有用的实现角色，不再重复上文的讨论。

表 I：电力电子教育中的 AI 角色及相应的技术输入成果物

AI 角色	主要成果物	输出类型	主要技术约束
概念诊断导师	推导、电路标注、符号模型	错误定位、针对性提示	领域规则编码
波形反馈引擎	时域波形、频谱、开关状态	误解分类	信号对齐与标注
自适应练习编排器	测验历史、实验日志、仿真结果	难度递进	可靠的学习者状态估计
实验安全助手	指令序列、设定值、联锁状态	不安全操作拦截	硬约束执行
基于评分细则的反馈生成器	报告、代码、设计计算	形成性评语	立足于教师评分细则

IV. 智能仿真与虚拟实验室

仿真和实验工作是电力电子教育的核心，因为开关瞬态、热极限、控制交互以及器件的非理想行为仅凭解析方程难以理解。实体实验室能够直接呈现这些效应，但其使用受到设备成本、安全要求、实验室容量以及损坏硬件风险的限制。常规电路仿真消除了其中部分约束，但仿真器本身仍然是被动的：它计算学习者给定的模型，但不会解释设计为何失败，也不会指出应当检查结果的哪个方面。AI 可以在两个相关方向上扩展仿真。第一，它可以降低重复性或交互式研究所需的计算量。第二，它可以增加一个教学层，解读学习者的操作并在实验过程中提供指导。其结果不仅仅是一个更快的仿真器，而是一个可以在结构化反馈下探索参数变化、运行极限和设计权衡的环境。有三项进展尤为相关：

- **降阶模型与代理模型：** 机器学习模型能够以详细开关仿真计算成本的一小部分来近似变换器、热或系统级行为。这使交互式探索成为可能，学习者可以改变某个参数并观察其效果，而无需等待完整的仿真运行。只要明确界定了其有效运行范围，此类模型在反复扫描、灵敏度研究和实时可视化中尤其有用。
- **数字孪生：** 经过校准的数字孪生利用根据实测数据进行更新或验证的模型，提供变换器或电力电子系统的虚拟表示。学习者可以改变负载、开关频率、控制参数和环境条件，注入扰动，并检查相应的电气和热响应。这在理想化仿真与实体硬件行为之间建立了有益的联系。
- **引导式设计空间探索：** AI 可以帮助选择需要研究的参数和工作点。系统不是让学习者在庞大的设计空间中漫无方向地搜索，而是可以识别不稳定区域、约束边界以及能够说明相关权衡的工作点，例如效率与开关频率之间、或瞬态响应与控制带宽之间的权衡。

图 3 展示了一种可能的架构。学习者与 AI 支持的教学层进行交互，而底层的数值计算仍留在仿真、代理模型、数字孪生或硬件在环环境中完成。AI 层可以生成场景、解读中间结果并选择合适的提示，但不应取代显式的求解器检查、安全限值或经验证的参考模型。

虚拟实验室扩展了这一概念，它管理的是整个实验过程，而不仅仅是加速仿真。它可以定义任务、监控学习者的操作序列、在测量之前要求学习者先给出预测，并在操作流程变得不安全或在技术上徒劳无益时进行干预。在这一角色中，系统承担了通常由实验助教提供的部分常规指导，而技术责任和最终评价仍由教师负责。最有用的能力如下：

- **场景生成与故障注入：** 系统可以创建参数化的运行条件，并引入真实的故障或扰动，例如死区时间过长、控制器参数不稳定、传感器偏置、负载阶跃或热极限越限。学习者随后可以根据由此产生的测量结果诊断原因。
- **流程支架：** AI 导师可以引导实验步骤、要求学习者提出假设、建议测量项目，并提供逐步更明确的提示。与安全相关的干预应当是即时的，而概念性的指导则应给学习者留出时间去审视证据并修正思路。
- **与工程工具集成：** 实验室应与成熟的软硬件环境相连接，例如 LTspice、PLECS、MATLAB/Simulink、数字控制平台和硬件在环系统。这使学习任务贴近工业实践中使用的工作流程，并避免使 AI 组件与工程工具链相隔离。

当实体设备的使用受限时，这些环境尤其有用。它们使学习者能够在接触硬件之前练习测量规划、控制器调节、故障诊断和变换器行为解读。它们还提供了一个受控的环境，在其中可以研究严重的设计或操作错误，而不会对设备造成风险。然而，其教育价值取决于是否保持了仿真与实验之间的区别：虚拟实验室应为学习者进行实体测量做好准备，而不应造成"模型能够完全代表真实硬件"的印象。

> **图 3 内容示意：**
>
> - ① **学习者：** 探索、交互、决策、观察结果；向 AI 导师发出"操作"，并接收"反馈"。
> - ② **AI 导师：** 教学推理、领域知识、学习进度记忆；场景生成、流程框架、评价与反馈。
> - ③ **仿真与数字孪生：** 降阶模型（ROM）、PSpice/PLECS、变换器数字孪生、硬件在环；AI 导师对其进行"配置与运行"，并获取"结果与数据"。
> - **大语言模型集成：** 自然语言交互 · 讲解 · 总结 · 知识增强。
>
> **图 3：** 面向电力电子教育的 AI 支持虚拟实验室架构。教学层通过生成场景、监控进度并提供有依据的反馈，在学习者与仿真、数字孪生或硬件在环环境之间起中介作用。

V. 自适应评估与自动反馈系统

A. 背景与动机

无论是在本科专业中还是在工业继续教育中，进入电力电子课程的学习者都具有参差不齐的先备知识。传统的"一刀切"式评估和练习形式难以应对这种差异性：它们对某些子群体要求过低或过高，通常只在后期以总结性方式提供反馈，并且在评分上消耗大量的教学资源。自适应评估和 AI 支持的反馈恰好针对这些弱点。自适应评估和 AI 支持的反馈可以提供数据驱动的个性化、及时的形成性反馈，并减少重复性的评分和命题工作量。

B. 自适应评估与评分方法

自适应评估（计算机自适应测试，CAT）根据之前的作答情况选择下一道题目。它通常以项目反应理论（IRT）为基础：题目通过难度、区分度和猜测概率等参数进行校准，学习者的能力则被持续估计。由于题目被定位在对每个个体信息量最大的难度区间，这种方法能够用更少的题目获得更准确、更公平的能力估计。

对于电力电子，以下方法尤其可行：

- **以能力和学习成果为导向的评分：** 按学习成果分类法（如布鲁姆分类法：理解、应用、分析、评价、设计）为题目打标签，并映射到能力模型，从而不只得到一个分数，而是得到一份有区分度的能力画像（例如"输出滤波器设计：扎实"与"开关损耗估算：不完整"）。
- **知识追踪：** 诸如贝叶斯知识追踪或较新的基于学习曲线的方法等模型，能够随时间估计各子能力的掌握程度，并据此驱动选题。
- **参数化题目生成器：** 基于一个题目模板（例如 Buck 变换器设计），通过改变参数——输入电压、开关频率、纹波目标、负载范围——即可生成几乎无限多、彼此各不相同的变体，且每个变体都有可唯一计算的参考答案。这既可以抑制不正当的抄袭，又能针对特定能力进行有目标的练习。

题库的仔细校准至关重要：题目参数必须在充分的数据基础上进行估计，并定期检查是否发生漂移。尤其是在小规模班级中（这是高级电力电子课程模块的典型情况），建议采用将教师的专家估计与现有作答数据相结合的混合方法。

C. AI 生成的自动反馈

生成式 AI 在教学中最直接的益处在于形成性的、过程中的反馈。传统的电子化评估系统只能对封闭式题型（选择题、数值填空）进行自动评分，而大语言模型首次使得对开放式回答、推导过程和设计决策给出稳健的、解释性的反馈成为可能——而且是即时的、全天候的，并且使用学习者自己的语言。

电力电子中的典型应用场景：

- **评阅推导过程与解题路径：** 系统不仅检查最终结果，还能识别出错误发生在哪一步（例如在电感选型中错误地应用了伏秒平衡），并给出针对性提示而非完整答案。
- **针对仿真结果的反馈：** 可以从常用工具（如 LTspice、PLECS、GeckoCIRCUITS）的输出中提取关键指标并与目标值进行比较；系统会对异常情况（开关损耗过大、控制不稳定、死区时间错误）进行点评，并将其与底层原理联系起来。
- **评阅实验报告和设计：** 依据预先定义的标准（完整性、合理性、误差讨论）进行基于评分细则的打分，并给出语言和结构方面的提示。
- **审查控制或嵌入式代码**（例如用于数字控制器的 C 或 HDL）：针对典型错误给出提示，如缩放错误、饱和问题或采样时间问题。

自动反馈应遵循第 II 节提出的"立足来源"和"验证"原则。必须明确区分形成性（支持学习的）反馈与总结性（与成绩相关的）评估——后者仍须由人来负责。

D. 学习过程的个性化

在能力估计和反馈的基础上，可以设计个性化的学习路径。自适应系统能够诊断先备知识的缺口（例如傅里叶分析或控制理论基础的欠缺），推荐有针对性的预备单元，并调整学习顺序、难度和例题背景。智能导学系统可以通过对话引导学习者完成电路设计，而不直接给出答案——相当于一位随时可用的导师。

这种个性化对于工作组所设想的、面向工业界工程师继续教育的 ECPE 教程尤其有价值：背景差异很大的参与者可以以适合各自的深度和节奏学习同一门课程。由此，电力电子能力的教学变得可规模化——这直接有助于实现工作组"加强电力电子专业人员教育与培训"的目标。

E. 对教育者的效率提升

自适应评估和自动反馈不仅对学习者，而且对教育者也是一个重要的杠杆。具体的减负效果包括：

- **命题：** AI 支持生成和变换练习题与考试题，包括参考答案和评分细则；教师负责筛选和核实，而不必事事亲力亲为。
- **评分：** 对开放式回答进行带有理由说明的预评分；由教师确认、修正或否决（人在回路）。工作重心从常规评分转向质量保证。
- **教学/学习分析：** 仪表板以汇总形式揭示一个班级在哪些概念上存在困难（例如换流、损耗计算），从而能够在课堂上进行有针对性的调整，并及早识别存在风险的学习者。

真正实现效率提升的前提是设计良好的人在回路流程和持续的质量控制（抽检、校准、申诉程序）。否则，工作量只是从评分转移到核查自动化输出，并没有真正减轻负担。

F. 参考架构与实际实施

为实现稳健的部署，建议采用能够融入现有大学或继续教育 IT 系统的模块化架构：

- 通过成熟标准集成到学习管理系统（如 Moodle、ILIAS）中，例如用 LTI 进行工具集成，用 xAPI/Caliper 处理学习过程数据。
- 清晰的数据流：题库与校准数据、学习者模型、反馈服务（带有已存储参考答案的语言模型）以及分析层，作为相互独立、可审计的组件。
- 从一开始就贯彻数据最小化和数据主权：假名化的学习者画像、清晰的删除方案，优先采用本地部署或在欧洲托管的模型（见第 VI 节）。

这样的架构允许循序渐进地起步——例如先在单个课程模块中提供形成性反馈——并在之后进行扩展，而不会被锁定在单一供应商上。

VI. AI 在电力电子教育中的挑战、伦理与实施

A. 技术与教学挑战

正如第 II 节所讨论的，电力电子将多模态技术成果物与明确的物理约束结合在一起。因此，实施中的挑战在于：AI 能否可靠地解读这些成果物，并支持（而不是简化）工程能力的形成。

第二个挑战是在领域特定的模糊性下模型的可靠性。在电力电子中，根据对寄生参数、开关频率、调制策略或可接受的纹波与热裕量所作假设的不同，可能存在多条有效的求解路径。这意味着 AI 辅助的反馈必须是"约束感知"的，而不是"模板匹配"的。否则，系统会惩罚技术上有效的替代方案，或者更糟糕的是，认可那些与训练样例相似但实际错误的方案。在开放式设计任务中，这一问题会变得更加严重，因为欠设计、过设计与最优设计之间的区别取决于具体情境，并且往往是多目标的。

在电力电子教育中使用 AI，除了通用教育应用的要求之外，还提出了特定的技术要求：

- **数据稀缺与领域适配：** 电力电子领域高质量、带标注的教学与评估数据十分稀缺，且常常受版权约束。模型必须经过领域适配和评测；（在 ECPE 内部）共同创建、共享的题目和评分数据集将带来可观的附加价值。

- **集成与运维：** 对接异构的大学 IT 系统、模型版本管理、评分的可复现性以及长期可用性，都是不容小觑的运维课题。

B. 学术诚信与评估设计

因此，伦理讨论并不局限于抄袭问题。学术诚信当然是核心问题，特别是生成式 AI 系统能够产出精美的报告和代码，但在电力电子中更隐蔽的风险是"认知外包"：学生可能提交技术上看似合理的推理，却无法在改变的运行条件下复现、辩护或调整这些推理。近期的高等教育文献一致指出，学术诚信、透明度、隐私、偏见和过度依赖是部署生成式 AI 时的主要关切 [6]–[8]。在一个以实验为主的学科中，这些关切应当通过评估设计而不仅仅是检测来解决。最稳健的方法是要求中间成果物与最终结论之间具有可追溯性：例如，设计论证与波形证据相关联，控制器整定与实测瞬态响应相关联，口头答辩与提交的仿真文件相关联。

抄袭与学术诚信： 生成式 AI 削弱了传统"课后作业"作为评估形式的有效性。可靠的 AI 检测器并不存在；仅靠禁令也无法执行。更有效的应对方式是将评估重新设计为以能力和过程为导向的形式（口试、设计答辩、与实验绑定的个性化任务），在这些形式中，学习者亲自展示的能力居于核心地位，而熟练使用 AI 工具本身也可以被明确列为学习成果的一部分。

最后，只有当教学契约明确时，实施才能成功。学生需要知道允许使用哪些形式的 AI 辅助、哪些成果物必须能够证明是自己完成的，以及在生成的输出之外，将如何检验他们的技术理解。在电力电子教育中，这通常意味着保留以下几种方式的某种组合：答辩式提问、现场调试、实验操作考核，以及手写或在受控环境下完成的推导。目标不是排斥 AI，而是确保 AI 支持的工作始终与可展示的工程判断力相结合。

C. 数据保护与法律框架

数据治理同样值得关注。技术课程中使用的 AI 平台通常会处理学生代码、电路文件、波形图像和实验记录。这些不仅仅是教育记录；它们可能暴露学生的解题习惯和错误，在某些情况下还可能涉及专有工具链或机构数据集。因此，任何部署都应明确：数据存储在何处，提示词和上传内容是否会被保留用于模型训练，成果物可被访问多长时间，以及学生是否拥有不使用 AI 完成考核作业的途径。在这里，隐私和治理并不是行政上的附加事项；它们决定了系统可采用的架构。

学习数据属于个人数据，其中一部分属于特别敏感的数据。在欧洲适用《通用数据保护条例》（GDPR），其原则包括数据最小化、目的限制和透明度。此外，欧盟《人工智能法案》（EU AI Act）将用于评估学习成果和控制教育准入的 AI 系统归类为高风险应用，并在风险管理、文档记录、人工监督和透明度方面提出了更高的要求。

对大学和培训机构的实际影响：

- 优先采用本地部署或在欧洲托管的模型或本地化（on-premise）解决方案，以避免数据传输到第三国。
- 在正式投入使用之前进行数据保护影响评估，制定清晰的同意、保留和删除方案。
- 获得人工决策的权利：与成绩相关的决定不得仅由自动化手段作出。

D. 伦理方面

偏见与公平： AI 系统可能复制或放大现有偏见。在评分中，这可能使某些群体处于不利地位——例如由于对非母语者的语言偏见，或由于训练数据不平衡。需要开展公平性检查、提供对评估结果提出申诉的途径，

并有意识地进行多样化的题目设计。

版权与知识产权： 必须区分三个层面——训练数据和输入数据（教学材料、讲义、第三方考题）的权利、生成内容的法律地位，以及商业模型的许可条款。不得未经审查就将第三方教学材料输入 AI 系统；对于自有及共同创建的内容，应约定清晰的（最好是开放的）许可协议。

透明度、问责与技能退化： AI 的输出必须能够被识别为 AI 输出；技术和法律责任仍由教师和机构承担。一个突出的风险是过度依赖——无论是学习者还是教师，都不应将核心能力委托给机器。AI 应当帮助建立理解，而不是取代理解。

E. 行政与组织方面的挑战

在实践中，采用 AI 很少仅因技术而失败，而往往是因为组织因素：

- **采购与成本：** 许可、运营和算力成本，供应商锁定，开源替代方案的评估。
- **治理：** 将其纳入考试规章和机构政策，让数据保护官和员工代表参与，明确责任归属。
- **教育者资质：** AI 素养是前提条件。如果没有配套的培训和激励措施，接受度会一直很低。
- **变革管理：** 循序渐进地引入，与学习者进行透明的沟通，持续开展评估。
- **可持续性：** 必须权衡大模型的能源和资源足迹；通常较小的专用模型就已足够。

F. 实施路线图

建议采用分阶段、低风险的方法：

1. **第 0 阶段——治理与准备：** 制定指南，开展数据保护影响评估，选择一个边界清晰的试点课程模块，定义成功标准。
2. **第 1 阶段——低风险试点：** 仅在一个课程模块中用于形成性的、与成绩无关的反馈；密切监督并开展评估。
3. **第 2 阶段——扩展与集成：** 对接学习管理系统，建设并校准题库，开展教育者培训，推广到更多课程模块。
4. **第 3 阶段——受监督的自适应总结性评估要素：** 在由人承担最终责任、并持续进行公平性和质量检查的前提下，受控地使用自适应评估要素。

一个描述每个课程模块/机构所处状态（从"无 AI"到"形成性 AI 反馈"，再到"受监督的自适应评估"）的成熟度模型很有帮助，它能实现可比性并有助于设定切合实际的目标。

G. 对 ECPE 及产学合作网络的建议

从子小组 5 的角度看，以下内容与工作组的目标存在具体关联：

- **共享资源：** 在 ECPE 网络内建立经过校准、许可清晰的电力电子题目与评分库——这是应对数据稀缺的有效手段。
- **基准与标准化：** 为电力电子中 AI 支持的反馈制定共同的评估标准，使技术可靠性具有可比性。
- **教程与研讨会：** 以计划中的 ECPE 教程作为自适应、个性化继续教育的试点；将 AI 支持的教学作为 2026 年计划举办的某场 ECPE 研讨会的主题。

- **科研资助：** 在公共资助计划中将 AI 支持的工程教育定位为一个研究方向——这与工作组"引导研究方向"的目标相一致。

VII. 结论

人工智能在电力电子教育中的重要性日益增长，特别是在教学涉及支配变换器运行的物理和数学约束的场合。电力电子融合了方程、电路模型、控制结构、波形、测量以及发生在不同时间尺度和系统尺度上的各种现象。因此，有效的 AI 辅助学习依赖于经过技术验证的来源、对多模态工程信息的恰当解读，以及对物理与设计约束的明确纳入。第 II 节提出的"先生成、后验证"工作流程为这一过程提供了一个实用框架，它将 AI 生成的输出与工程验证和技术推理联系起来。

在教学、仿真和评估各方面，最相关的应用包括：识别解析推导中的错误、在分层的变换器设计过程中提供指导、自动解读仿真和实验结果，以及利用代理模型和数字孪生加速分析。这些应用可以支持更加个性化的学习，同时使技术评价保持为教育过程中不可或缺的一部分。它们的更广泛采用将取决于合适教育数据集的可获得性、与机构 IT 基础设施的集成、对 GDPR 要求的遵守，以及在欧盟《人工智能法案》为教育类 AI 所建立的监管框架内的实施。

对于 ECPE 及其更广泛的网络而言，眼前的机遇包括：开发共享的、许可清晰的题目与评分库，建立评估 AI 支持反馈的共同基准，以及将计划中的教程用作自适应继续教育的初始平台。这些活动可以为在真实的电力电子培训环境中评估 AI 方法、并在整个社区中建立共同实践提供切实的基础。

参考文献

（参考文献保留原文）

1. K. VanLehn, "The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems," *Educational Psychologist*, vol. 46, no. 4, pp. 197–221, 2011.
2. J. A. Kulik and J. D. Fletcher, "Effectiveness of Intelligent Tutoring Systems: A Meta-Analytic Review," *Review of Educational Research*, vol. 86, no. 1, pp. 42–78, 2016.
3. K. W. E. Cheng, C. L. Chan, N. C. Cheung, D. Sutanto, and K. F. Kwok, "Remote Hardware Controlled Experiment Virtual Laboratory for Undergraduate Teaching in Power Electronics," *Education Sciences*, vol. 9, no. 3, art. 222, 2019.
4. G. Singh, A. Mantri, O. Sharma, and R. Kaur, "Virtual Reality Learning Environment for Enhancing Electronics Engineering Laboratory Experience," *Computer Applications in Engineering Education*, vol. 29, no. 1, pp. 229–243, 2021.
5. T. Wray, M. P. Foster, D. C. Gladwin, and S. J. Galloway, "A Compact and Modular Remote Access Platform for Enhanced Practical Education in Power Electronics, Machines, and Drives," in *Proc. PEMD*, 2024.
6. J. Batista, C. Nunes, A. F. Martins, and J. Morgado, "Generative AI and Higher Education: Trends, Challenges, and Opportunities," *Information*, vol. 15, no. 11, art. 676, 2024.
7. M. Bobula, "Generative Artificial Intelligence (AI) in Higher Education: Opportunities and Challenges," *Journal of Learning Development in Higher Education*, no. 31, 2024.

8. K. Bittle, P. Frías, and J. P. Salazar, "Generative AI and Academic Integrity in Higher Education," *Information*, vol. 16, no. 4, art. 296, 2025.
9. W. Xu and F. Ouyang, "The Application of AI Technologies in STEM Education: A Systematic Review from 2011 to 2021," *International Journal of STEM Education*, vol. 9, art. 59, 2022.